

DQ인증(데이터 품질인증) 가이드라인

데이터 내용 인증

2026.02



2



과학기술정보통신부 · Kdata 한국데이터산업진흥원

DQ인증(데이터 품질인증) 가이드라인 데이터 내용 인증

I	데이터 내용 인증 개요	1
	1. 데이터 내용 인증	2
	2. 인증대상	4
	3. 인증 등급 및 유효기간	16
II	인증심사	17
	1. 심사절차	18
	2. 심사 기준	23
	3. 정형 데이터 심사	25
	4. 비정형 데이터 심사	59
III	인증 판정	197
	1. 인증 판정 기준	198
IV	인증심의	214
	1. 인증심의위원회	215
	2. 인증심의 기준 및 의결	216
	부록1 자주하는 질문(FAQ)	219
	부록2 용어집	223
	부록3 참고문헌	226

■ 가이드라인의 목적

이 가이드라인은 DQ인증(데이터 품질인증)을 준비하는 기업과 담당자가 인증 제도의 개념과 절차를 명확히 이해하고 효과적으로 준비할 수 있도록 설계되었다. 데이터 품질 관리 경험이 부족한 비전문가도 활용할 수 있도록 사례와 구체적인 설명을 중심으로 구성하였으며, 인증 준비 과정을 체계적이고 쉽게 진행할 수 있도록 지원하는 것을 목표로 한다. 이를 통해 인증 요구사항에 대한 이해를 높이고, 조직 내 데이터 품질 관리체계를 구축하는 데 필요한 실질적인 가이드를 제공하고자 한다.

■ 가이드라인의 구성

이 가이드라인은 DQ인증의 이해와 준비를 돕기 위해 다음과 같이 세 권으로 구성되었다.

▶ 1권: DQ인증 제도 소개

DQ인증 제도와 필요성, 인증 체계 및 획득 효과를 소개한다. 인증대상과 인증 기준을 자세히 설명하며, 인증절차를 단계별로 안내한다. 또한, 우수 사례를 통해 실제 인증 준비와 활용에 필요한 정보를 제공한다.

▶ 2권: 데이터 내용 인증

데이터 내용 인증의 대상과 심사절차를 설명하고, 인증 신청 시 필요한 제출 문서를 안내한다. 또한 사례를 통해 데이터 유형별 심사 기준과 방법, 인증 유형 및 등급 기준을 설명한다.

▶ 3권: 데이터 관리체계 인증

데이터 관리체계 인증의 대상과 심사절차를 설명하고, 인증 신청 시 제출 문서를 안내한다. 또한 데이터 품질 관리 원칙, 조직, 절차를 평가하는 심사 기준과 인증 등급별 판정 기준을 설명한다.

■ 가이드라인의 기대 효과

DQ인증 가이드라인은 명확한 인증절차와 심사 기준을 제공함으로써 인증 준비 과정에서 발생할 수 있는 혼선을 줄이고, 시간과 비용을 절감하여 인증 준비 과정의 효율성을 높일 수 있다. 또한, 구체적인 사례와 실질적인 설명을 포함하여 데이터 품질 관리 경험이 부족한 담당자도 쉽게 이해하고 활용할 수 있도록 구성되어 있어, 조직 내부적으로도 인증 준비를 원활히 진행할 수 있다.

이 가이드라인은 인증 준비 과정에서 데이터 내용 및 데이터 관리체계를 점검하고 개선하도록 돕는다. 또한 인증 획득을 성공적으로 지원하고, 인증 획득 이후에도 지속 가능한 관리체계를 마련할 수 있다.

I

데이터 내용 인증 개요

1. 데이터 내용 인증
2. 인증대상
3. 인증 등급 및 유효기간

I

데이터 내용 인증 개요

1 데이터 내용 인증

1.1 인증 제도 개요

DQ인증(Data Quality Certification, 데이터 품질인증)은 데이터 내용 인증과 데이터 관리체계 인증의 두 가지 유형으로 구성된다. 본 권에서는 이 중 데이터 내용 인증에 대한 가이드라인을 설명한다.

데이터 내용 인증은 데이터 자체의 품질을 평가하는 제도다. 데이터베이스의 구조 및 레코드·필드 값뿐 아니라 텍스트, 이미지, 동영상, 음성 등 다양한 유형의 객체 데이터를 포함한 데이터 내용과 데이터 구조의 품질(정확성, 완전성, 일관성 등)을 심사한다.

평가 기준은 과학기술정보통신부 공고 제2023-0457호 「데이터 품질 인증기관 지정 및 운영에 관한 지침」에서 정의한 10가지 품질기준 중 데이터 내용에 해당하는 6개 기준을 적용한다.

▶ 데이터 내용 품질기준

기준	내용
완전성	사용목적에 맞게 설계된 데이터가 필수항목을 누락 없이 포함하여 완전한지 진단하는 기준
유효성	데이터가 규정된 형식과 의미, 관계 규칙을 준수하고 논리적으로 타당한지 진단하는 기준
일관성	준수해야 하는 표준, 규칙, 기준에 따라 데이터가 일관되게 입력되어 있는지 진단하는 기준
정확성	데이터가 업무규정 또는 논리에 따라 구조적, 의미적으로 정확한지 진단하는 기준
접근성	데이터가 쉽게 접근할 수 있고 사용하기에 편리한지 진단하는 기준
유일성	데이터가 중복되지 않고 유일한지 진단하는 기준

1.2 인증심사 방법

데이터 내용 인증심사는 앞서 제시한 ‘데이터 내용 품질기준’을 기반으로 수행되며, 심사 시 국제표준 및 국내 가이드를 준용한다. 본 문서에는 데이터 품질을 측정하기 위한 구체적인 심사 기준, 절차, 항목이 정의되어 있으며, 심사기관은 이를 근거로 데이터 품질을 심사한다.

▶ 데이터 내용 인증 준용 표준

구분	표준 번호	표준명	설명
국제 표준	ISO/IEC 25012	Software engineering – Software product Quality Requirements and Evaluation (SQuaRE) – Data quality model	데이터 품질 모델을 정의한 표준으로, 데이터 품질 평가를 위한 15가지 품질 특성을 정의한 표준
	ISO/IEC 25024	Software engineering – Software product Quality Requirements and Evaluation (SQuaRE) – Data quality measurement	데이터 품질의 측정 항목과 방법을 정의한 표준
	ISO/IEC 5259-2	Artificial intelligence – Data quality for analytics and machine learning (ML) – Part 2: Data quality measures	인공지능 및 머신러닝을 위한 학습용 데이터 품질의 측정 방법을 정의한 표준
국내 단체 표준	TTAK.KO-10.1344-Part2	유통·활용 데이터 점검 방법 – 제2부: 비정형 데이터 품질지표	비정형 데이터의 분류, 비정형 데이터의 품질지표, 비정형 데이터 분류별 품질지표의 적용 및 품질기준 설정 절차와 방법을 제시하는 표준

▶ 데이터 내용 인증 준용 국내 가이드

문서명	설명
NIA 인공지능 학습용 데이터 품질관리 가이드 3.1	인공지능 학습용 데이터 구축 사업 내 품질관리 거버넌스 및 프레임워크, 품질검증 지표에 대해 기술된 가이드
NIA 빅데이터 플랫폼 및 센터 품질관리 가이드	빅데이터 플랫폼 및 센터의 데이터 품질관리 모델과 체계를 제시하고, 데이터 품질관리 지표와 진단기법을 통해 품질을 향상시키기 위한 절차와 각 단계에서 고려해야 할 사항을 제공하는 가이드

2

인증대상

데이터 내용 인증의 대상은 데이터 내용 및 데이터 구조 전반이다. 여기에는 데이터베이스 내 레코드와 필드 값뿐 아니라 텍스트, 이미지, 동영상, 음성 등 비정형 데이터와 해당 데이터의 속성값과 메타데이터까지 포함된다.

2.1 인증대상

데이터 내용 인증은 데이터의 내용 자체와 구조를 대상으로 한다.

■ 심사대상

데이터 구조	데이터의 효율적인 처리를 위한 개념적, 논리적, 물리적 데이터 모델과 저장 형식
데이터 내용	데이터 레코드, 필드에 입력되어 있는 문자, 숫자 등 값과 집합 또는 텍스트, 이미지, 동영상, 음성 등의 원천 데이터와 속성값 등

2.2 데이터 유형

■ 데이터 유형

데이터 내용은 유형에 따라 심사 항목이 달라지며, 정형 데이터와 비정형 데이터로 구분한다.

▶ 정형 데이터

정형 데이터는 고정된 구조와 명확한 스키마를 가진 데이터로, 일반적으로 RDBMS(Oracle, MySQL, SQL Server 등) 또는 CSV 형태로 저장된다. 또한, 구조가 명확해 관리가 용이하다.

▶ 비정형 데이터

비정형 데이터는 고정된 구조나 스키마가 없는 데이터로, 텍스트, 이미지, 동영상, 음성 등 다양한 형식이 있다. 복잡성과 형태가 다양하기 때문에 메타데이터와 어노테이션 정의가 필수적이며, 정형 데이터와는 다른 심사 접근이 요구된다.

데이터 유형별 심사 방법

정형 데이터	필드와 레코드, 데이터 값에 대한 완전성, 유효성, 일관성, 정확성 등을 심사
비정형 데이터	텍스트, 이미지, 동영상, 음성 등 다양한 객체와 메타데이터, 어노테이션 데이터에 대한 완전성, 유효성, 일관성, 정확성 등을 심사

※ 반정형 데이터의 경우, 데이터의 목적과 특성에 따라 정형 데이터 또는 비정형 데이터 심사 항목을 적용한다. 데이터가 독립적이며, 정형화할 수 있는 경우에는 정형 데이터 심사 항목을 적용하고, 비정형 데이터의 메타데이터나 어노테이션 데이터인 경우에는 비정형 데이터의 세부 심사 항목으로 심사한다.

2.23 데이터 내용 특징

데이터 내용은 다음과 같은 특징을 가진다.

구분	설명
다양한 유형	데이터 내용은 문자, 숫자, 텍스트, 이미지, 동영상, 음성 등 다양한 형태로 존재하며, 사용 목적과 활용 환경에 따라 서로 다른 포맷으로 관리된다.
구조적 분류	데이터는 구조화 데이터, 반구조화 데이터, 비구조화 데이터로 구분된다. 구조화 데이터는 고정된 스키마를 가지고 있으며, 반구조화 데이터는 태그와 계층 구조를 포함하고, 비구조화 데이터는 일정한 형식 없이 텍스트·이미지 등 자유로운 형태로 존재한다.
메타데이터 및 속성값	데이터 내용에는 본 데이터 외에도 문맥과 의미를 보완하는 메타데이터와 속성값이 포함되며, 이는 데이터의 이해도와 활용성을 높이는 핵심 요소이다.
목적에 따른 생성·관리	데이터는 학습용, 운영용, 유통·거래용 등 목적에 따라 생성되며, 활용 목적과 환경에 부합하도록 관리해야 한다.
지속적 관리 필요성	데이터 내용은 시간이 지나면서 추가·변경·삭제가 발생할 수 있으므로, 최신성을 유지하기 위한 지속적인 관리와 정기적인 검증이 필요하다.

다양한 기준별 데이터 분류

데이터는 목적·형태·저장 구조·활용 방식에 따라 여러 방식으로 분류되며, 이는 데이터 품질관리 및 DQ인증 과정에서 핵심적인 기준이 된다.

데이터 유형별 분류(구조적 분류)

데이터 내용은 유형에 따라 정형 데이터, 반정형 데이터, 비정형 데이터로 구분된다. 정형 데이터는 고정된 스키마를 갖고 구조가 명확하며, 반정형 데이터는 태그와 계층 구조로 일정 수준의 구조성을 유지한다. 비정형 데이터는 텍스트, 이미지, 동영상, 음성 등 형식이 없는 자유로운 데이터를 포함하며 다양한 환경에서 활용된다.

• 정형 데이터(Structured Data)

정형 데이터는 테이블, 스프레드시트, DB 등과 같이 명확한 스키마와 고정된 필드 구조를 갖는다. 수치·날짜·주소 등 분석 가능한 속성을 포함하며, 데이터베이스 관리 시스템(DBMS, Database Management System)을 통해 효율적인 처리와 관리가 가능하다.

구분	정의	예시
CSV 파일	데이터를 쉼표로 구분하여 각 행을 하나의 데이터 레코드로 저장하는 텍스트 기반 파일 형식으로 주로 간단한 데이터 저장과 교환에 사용되는 데이터	• 센서 데이터 • 로그 데이터
관계형 데이터베이스 (RDB, Relational Database)	데이터를 테이블 형태로 구조화하여 행과 열로 구성된 관계를 통해 데이터를 저장하고 관리하는 데이터	• 고객 정보 관리 데이터 • 쇼핑몰 주문 관리 데이터 • 병원의 환자 기록 관리 데이터 • 금융 거래 데이터 관리 데이터 • 도서관의 대출 및 반납 관리 데이터
스프레드시트	데이터를 행과 열로 구성된 표 형태로 저장하고, 수식과 함수를 통해 데이터를 계산 및 분석할 수 있는 데이터	• 월별 재무 데이터 • 제품 재고 데이터 • 설문 결과 분석 데이터 • 판매 실적 데이터

• 비정형 데이터(Unstructured Data)

비정형 데이터는 구조나 형식이 일정하지 않은 데이터로 텍스트·이미지·동영상·음성 등 객체 데이터와 이를 설명하는 메타데이터(객체 설명 또는 태깅·라벨링 등의 작업 내용 설명)로 구성된다.

구분	정의	예시
텍스트	문서 파일과 문서의 정보를 포함한 메타데이터로 구성된 데이터	DOC, PPT, HWP, TXT 등
이미지	이미지 파일과 이미지의 정보를 포함한 메타데이터로 구성된 데이터	BMP, JPG, JPEG, PNG 등
동영상	영상 파일과 영상 정보를 포함한 메타데이터로 구성된 데이터	MP4, M4V, AVI, MOV 등
음성	사운드 파일과 사운드 파일 정보를 포함한 메타데이터로 구성된 데이터	MP3, M4A, AAC 등

• 반정형 데이터(Semi-structured Data)

반정형 데이터는 완전히 고정된 구조는 없지만 JSON, XML 등의 형식으로 저장되며, 마크업이나 특정 구조로 표현되어 있고 필드·값에서 일부 정보 추출이 가능한 데이터이다.

구분	정의	예시
JSON	데이터를 속성-값 쌍 또는 배열로 저장하는 경량화된 데이터 형식	API 응답 데이터, 구성 파일
XML	태그로 데이터를 구조화하여 계층적으로 표현하는 마크업 언어	전자 문서, RSS 피드

▶ 데이터 목적별 데이터 분류

데이터는 활용 목적에 따라 학습용, 운영용, 유통·거래용 데이터로 분류된다.

학습용 데이터: AI·머신러닝 모델 학습을 위해 구축된 데이터로, 품질·정합성·정확한 라벨링이 중요

운영 데이터: 조직의 업무 운영 과정에서 실시간으로 생성·활용되는 데이터

유통·거래용 데이터: 데이터 상품 형태로 유통·판매로 제공되는 데이터로, 표준화·정제·가공이 이루어진 형태로 거래

데이터 유형	정의 및 특징	예시
학습용 데이터	- 인공지능 및 머신러닝 모델이 특정 작업을 수행하기 위해 필요한 패턴을 학습하도록 지원하는 데이터 - 데이터의 품질(다양성, 정확성)은 모델 성능에 직접적으로 영향을 미침 - 원천 데이터를 기반으로 객체, 텍스트, 음성 등에 라벨이나 주석이 추가된 라벨링 데이터가 포함될 수 있음	- 이미지 데이터: 자율주행 차량 학습용 도로 표지판 및 차량 이미지 - 텍스트 데이터: 자연어 처리 모델 학습용 번역 데이터 - 오디오 데이터: 음성 합성 모델 학습을 위한 다양한 억양 및 발음 데이터 - 시계열 데이터: 주식 가격 예측을 위한 과거 주가 데이터 - 동영상 데이터: 동작 인식 모델 학습용 체육 동작 영상
유통 및 거래용 데이터	- 데이터 거래소에서 상품화된 형태로 거래되며, 다양한 산업 및 목적에 활용할 수 있도록 표준화, 정제 또는 가공된 데이터 - 특정 용도로 사용하기 쉽게 정제되고 구조화된 데이터 - 표준화된 텍스트 데이터, 이미지 데이터, 통계 데이터 등 다양한 형태로 제공	- 소비자 분석 데이터: 고객의 온라인 쇼핑 구매 기록과 선호도 데이터 - 교통 데이터: 도시 교통 혼잡도를 분석하기 위한 교통량 데이터 - 헬스케어 데이터: 특정 질병에 대한 환자 통계 및 임상 실험 데이터 - 환경 데이터: 공기질 지수, 온도, 습도 데이터를 포함한 기상 관측 데이터 - 농업 데이터: 특정 지역의 토양 상태 및 작물 생산량 데이터
운영 데이터	- 조직의 일상적 운영과 업무 프로세스를 실시간으로 지원하기 위한 데이터 - 빠른 처리와 접근성이 중요하며, 정확성과 최신성을 유지하는 것이 중요함	- 금융 데이터: 카드 결제 실시간 승인 정보 - 제조 데이터: 공장의 생산 설비에서 수집된 기계 가동 상태 데이터 - 유통 데이터: 창고 재고 상태 데이터 - 인력 관리 데이터: 직원 근태 기록 및 급여 계산 데이터

▶ DBMS별 데이터 분류

데이터 저장·관리 방식에 따라 다음과 같이 분류된다.

관계형 데이터베이스(RDBMS): 정형 데이터를 테이블 형태로 저장하며 SQL 기반으로 처리

비관계형 데이터베이스(NoSQL): 문서형·키값형·그래프형 등 유연한 구조의 데이터를 저장

분석용 데이터베이스(OLAP): 대용량 분석 작업에 최적화된 구조

분산 데이터베이스: 여러 노드에 데이터를 분산하여 저장·처리하는 구조

데이터베이스 유형	정의 및 특징	예시
관계형 데이터베이스 (RDBMS)	- 데이터를 정형화된 테이블 구조로 관리하며, 행(Row)과 열(Column) 형태로 데이터를 표현 - 데이터 무결성과 트랜잭션 관리를 지원하며, SQL 언어를 통해 데이터를 조작	MySQL, Oracle, PostgreSQL, SQL Server
비관계형 데이터베이스 (NoSQL)	- 유연한 스키마를 통해 비정형 및 반정형 데이터를 효율적으로 관리 - 문서, 키-값, 컬럼형, 그래프 등 다양한 데이터 모델을 지원하며, 대규모 데이터를 빠르게 처리 가능	MongoDB, Cassandra, Couchbase, DynamoDB
OLAP 데이터베이스	- 비즈니스 분석 및 의사결정을 위한 데이터 분석에 최적화 - 대량 데이터 집계와 복잡한 쿼리를 효율적으로 처리하며, 주로 다차원 데이터 분석에 사용	Amazon Redshift, Snowflake, Google BigQuery
분산 데이터베이스	- 데이터를 여러 노드에 분산 저장하여 성능, 가용성, 확장성을 제공 - 노드 간 데이터 동기화와고가용성 환경을 지원하며, 빅데이터 처리에 적합	Apache Hadoop HDFS, Google Spanner
파일 기반 데이터베이스	- 단순 데이터 저장을 위해 파일 시스템을 기반으로 데이터를 관리 - 구조화된 데이터는 CSV로, 반정형 데이터는 XML 또는 JSON 파일로 저장하여 활용	CSV, XML, JSON 파일

▶ 학습용 데이터의 분류

학습용 데이터는 모델 학습 목적과 구성 방식에 따라 다양한 기준으로 분류된다. 이는 데이터의 구조와 활용 방식을 규정하고, 데이터 품질관리 및 검증 기준 설정에 활용된다.

분류 기준	데이터 유형	정의	예시
데이터 표현 형식 (모달리티)	단일모달 데이터 (Single-modal)	하나의 모달리티(텍스트, 이미지, 오디오 등)로 구성된 데이터	- 뉴스 기사(텍스트) - 인물 사진(이미지) - 음성 인터뷰(오디오)
	멀티모달 데이터 (Multimodal)	텍스트·이미지·음성 등 둘 이상의 모달리티가 결합된 데이터	- 영상과 자막 - 이미지와 설명문 - 음성과 텍스트 대화
학습 방식	지도 학습용 데이터 (Supervised)	입력에 대한 정답이 제공되는 데이터	- 이미지 분류용 라벨 데이터 - 감성 분석용 문장 라벨
	비지도 학습용 데이터 (Unsupervised)	정답이 없이 데이터의 패턴·구조를 학습하는 데이터	- 문서 클러스터링용 뉴스 기사 - 음성 특징 추출 데이터
	자기 지도 학습용 데이터 (Self-supervised)	라벨이 없으나 입력 일부를 제거하거나 변형하여 스스로 학습 과제를 생성하는 데이터	- 마스크드 언어모델(MLM) - 비디오 프레임 예측용 영상
학습 목적	머신러닝 학습용 데이터	분류·회귀 등 전통적 ML 알고리즘 학습에 사용되는 데이터	예측/분류 목적 표형 데이터셋
	생성형 AI 학습용 데이터	새로운 콘텐츠를 생성하는 모델 학습에 활용되는 데이터	요약, 번역, 이미지 생성, 코드 생성 데이터
어노테이션 유형	라벨 데이터	입력 데이터에 대해 정답(Label)이 존재하는 데이터	- 이미지 객체 검출용 바운딩박스 - 텍스트의 감성 라벨 - 음성 전사 텍스트
	비라벨 데이터	입력 데이터에 대해 명확히 정의한 정답(Label)은 존재하지 않으며, 대신 참조(reference)가 존재하는 데이터	- 요약·번역 모델 입력 텍스트 - 프롬프트 데이터

• 라벨 데이터(Label Data) / 비라벨 데이터(Unlabeled Data)

학습용 데이터는 정답(Label)의 존재 여부에 따라 라벨 데이터와 비라벨 데이터로 구분된다.

라벨 데이터: 입력 데이터에 대해 실제값(ground truth)을 바탕으로 단일한 정답(Label)이 명확히 정의된 데이터를 말한다. 즉, 현실의 참값을 사람이 해석·판단하여 정답(Label)으로 부여한 데이터를 의미하며, 분류, 개체명 인식, 문장 판별 등 정답이 하나로 특정될 수 있는 태스크가 이에 해당한다.

비라벨 데이터: 입력 데이터에 대해 실제값(ground truth) 기반의 단일 정답(Label)을 정의할 수 없는 데이터로, 요약문, 생성형 질의응답, 이미지·영상 캡셔닝 등 다양한 표현이 모두 정답으로 인정될 수 있는 생성형 데이터가 이에 해당한다. 이러한 데이터는 평가를 위한 참조문(reference)을 제공하지만 단일 정답(Label)이 존재하지 않고 참조문이 정답 하나로 고정되지 않기 때문에 라벨 데이터로 보지 않는다.

데이터 유형	라벨 데이터	비라벨 데이터
정의	입력 데이터에 대해 명확히 정의한 정답(Label)이 존재하는 데이터	입력 데이터에 대해 단일 정답(Label)이 존재하지 않는 대신 참조(reference)가 존재하는 데이터
유형	• 분류(Classification) • 검출(Detection) • 세그멘테이션(Segmentation) • 회귀(Regression) • 순위/랭킹(Ranking)	• 요약(Summarization) • 질의응답(QA) • 번역(Translation) • 대화 응답(Dialogue Response) • 캡셔닝(Captioning) • 창작형(Creative Generation)
특징	• 명확히 정의된 단일 정답 존재(Label, Class, Value) • “정답 일치” 여부로 성능 평가 • 지도학습(Supervised Learning)에 활용	• 단일 정답 없음 • 참조(reference) 데이터 • 다양 표현 허용 • “정답 유사도” 또는 “텍스트 품질”로 평가 • 비지도학습 및 생성형 모델(LLM/LMM) 학습에 활용
적용 예시	• 분류(Classification): 사진을 보고 “이건 고양이이다”처럼 단 하나의 정답을 붙이는 작업 • 검출(Detection): 사진 속 “사람이 어디 있는지” 네모 박스로 표시하는 작업 • 세그멘테이션(Segmentation): 이미지의 픽셀 하나하나에 “여기는 도로, 여기는 사람”처럼 구역을 색으로 나누는 작업 • 회귀(Regression): “내일 온도는 23.4도”처럼 숫자 하나가 정답인 문제 • 순위/랭킹(Ranking): “상품 A가 B보다 더 인기 있다”처럼 순서를 정하는 문제	• 요약(Summarization): 같은 글을 요약해도 사람이 다르게 요약할 수 있어 정답이 여러 개일 수 있음 • 질의응답(QA): “내일 뭐 입을까?”처럼 여러 답이 가능한 경우 • 번역(Translation): 같은 문장을 번역해도 표현 방식이 다양할 수 있음 • 대화 응답(Dialogue Response): 챗봇 답변처럼 여러 문장이 모두 자연스럽다면 정답이 하나가 아님 • 캡셔닝(Captioning): 사진을 보고 “강아지가 뛰고 있다”, “강아지가 들판에서 달리고 있다”처럼 여러 문장이 모두 맞을 수 있음

산업별 데이터 분류 예시

의료 데이터

의료 데이터는 병원, 의료 기관, 개인 건강 관리 기기 등과 관련된 정보를 포함하는 데이터이다. 이는 환자의 건강과 관련된 의사결정을 지원하고, 의료 서비스의 효율성을 개선하며, 연구 및 혁신을 촉진한다.

데이터 유형	정의	예시	활용 사례
환자 데이터	환자 건강 상태 및 개인 정보	전자의무기록(EMR), 바이탈 사인	질병 진단, 맞춤형 건강 관리
의료 기기 데이터	의료 기기에서 수집된 상태 정보	심전도, CT/MRI 이미지	질병 예측, 원격 진료
진료 및 진단 데이터	병원에서 생성된 진료 및 검사 데이터	혈액 검사, 처방 이력	정밀 의학, 약물 분석
공공 의료 데이터	지역 사회 보건 통계	감염병 현황, 비만율, 병상 수	보건 정책 수립, 의료 서비스 최적화
연구 데이터	임상 시험 및 연구 데이터	임상 시험 결과, 유전자 데이터	신약 개발, 유전자 기반 예방 연구

예시	구강 이미지 학습 데이터				
	<table> <tr> <th>이미지 데이터</th><th>라벨링 데이터</th></tr> <tr> <td>  </td><td> <pre>{ "image_filepath": "front_16227.png", "tooth": [{ "teeth_num": 11, "segmentation": [[805, 76], [803, 76], [802, 75], [800, 75], [799, 74], [794, 74], [793, 75], [773, 75], [772, 76]] }, { "teeth_num": 12, "segmentation": [[528, 121], [516, 121], [515, 120], [509, 120], [508, 121], [502, 121], [501, 122], [495, 122], [494, 123]] }, { "teeth_num": 13, "segmentation": [[272, 149], [271, 150], [266, 150], [265, 151], [263, 151], [262, 152], [261, 152], [260, 153]] }]}...</pre> </td></tr> </table>	이미지 데이터	라벨링 데이터		<pre>{ "image_filepath": "front_16227.png", "tooth": [{ "teeth_num": 11, "segmentation": [[805, 76], [803, 76], [802, 75], [800, 75], [799, 74], [794, 74], [793, 75], [773, 75], [772, 76]] }, { "teeth_num": 12, "segmentation": [[528, 121], [516, 121], [515, 120], [509, 120], [508, 121], [502, 121], [501, 122], [495, 122], [494, 123]] }, { "teeth_num": 13, "segmentation": [[272, 149], [271, 150], [266, 150], [265, 151], [263, 151], [262, 152], [261, 152], [260, 153]] }]}...</pre>
이미지 데이터	라벨링 데이터				
	<pre>{ "image_filepath": "front_16227.png", "tooth": [{ "teeth_num": 11, "segmentation": [[805, 76], [803, 76], [802, 75], [800, 75], [799, 74], [794, 74], [793, 75], [773, 75], [772, 76]] }, { "teeth_num": 12, "segmentation": [[528, 121], [516, 121], [515, 120], [509, 120], [508, 121], [502, 121], [501, 122], [495, 122], [494, 123]] }, { "teeth_num": 13, "segmentation": [[272, 149], [271, 150], [266, 150], [265, 151], [263, 151], [262, 152], [261, 152], [260, 153]] }]}...</pre>				

▶ 금융 데이터

금융 데이터는 금융 활동과 관련된 고객 정보, 거래 내역, 시장 변화, 대출 및 신용 기록, 보험 계약 등 다양한 유형의 데이터를 포함하며 금융 기관, 기업, 정부 기관, 투자자들이 필수적으로 사용하는 자원이다.

데이터 유형	정의	예시	활용 사례
거래 데이터	금융 기관에서 발생하는 거래 기록	은행 계좌 이체, 카드 결제 내역, ATM 인출 기록	고객 소비 패턴 분석, 사기 탐지, 리스크 관리
고객 데이터	금융 상품을 이용하는 고객의 정보	이름, 나이, 신용 등급, 직업	신용 평가, 맞춤형 금융 상품 추천
시장 데이터	금융 시장에서의 실시간 정보 및 기록	주식 가격, 채권 수익률, 환율, 유가 변동	투자 전략 수립, 포트폴리오 관리
신용 데이터	대출 및 신용과 관련된 정보	대출 기록, 상환 내역, 신용 점수	대출 심사, 부실 위험 예측, 고객 신용 분석

예시

금융 OCR 데이터

이미지 데이터	라벨링 데이터
	<pre>{ "Annotation": { "object_recognition": 1, "text_language": 0 }, "Dataset": { "category": 0, "identifier": "IMG_OCR_6_F", "type": 1 }, "Images": { "data_captured": "2022.11.07", "device_model": 0, "device_type": 1, "form_industry": 0, "form_type": "신청서", "height": 3508, "identifier": "IMG-0002604", "type": "PNG", "width": 2479, "writer_age": 4, "writer_body": 1, "writer_experienced": 1, "writer_sex": 0 }, "bbox": [{ "data": "홍길동", "data_type": 0, "id": 1, "x": [959, 959, 1124, 1124], "y": [602, 651, 602, 651] }] }</pre>

▶ 자율주행 데이터

자율주행 데이터는 자율주행 차량이 안전하고 효율적으로 운행하기 위해 수집하고 처리하는 다양한 형태의 데이터이다. 차량의 인공지능 시스템이 도로 환경을 이해하고 판단하며, 적절한 주행 결정을 내린다.


데이터 유형	정의	예시	활용 사례
환경 데이터	자율주행 차량이 주행 중 인식하는 주변 환경 정보	도로, 교차로, 신호등, 도로 표지판 등의 정보	도로 인식, 신호등 변화 감지, 장애물 회피
교통 데이터	주변 차량 및 보행자, 자전거 등의 교통 흐름 정보	차량 위치, 보행자 데이터, 다른 차량의 속도	교통 예측, 주행 경로 설정, 사고 예방
위치 데이터	GPS 및 기타 시스템을 통한 차량의 위치 정보	GPS 좌표, 지도 데이터, 고도 정보	경로 최적화, 위치 기반 서비스 제공
차량 상태 데이터	차량 내부 상태 및 동작에 관한 데이터	속도, 가속도, 브레이크 상태, 엔진 온도	차량 성능 모니터링, 경로 및 속도 조절

예시	생활도로 객체인식 자율주행 데이터
이미지 데이터	
라벨링 데이터	<pre>{ "info": { "description": "Exported from Superb AI Suite", "contributor": "LFIT .Inc", "url": "www.lfit.co.kr", "date_created": "2024-00-00T09:31:48.940000" }, "category": [{ "id": 3, "name": "Car", "category_id": "36e54347-aa45-4a9b-8c85-f29b10fd962e", "supercategory": "Vehicle" }, { "id": 2, "name": "Two-wheel Vehicle", "category_id": "e90a7f26-4925-48ae-b07c-421d766b8eaa", "supercategory": "Vehicle" }] }</pre>

▶ 교육 데이터

교육 데이터는 학습자, 교육 과정, 평가, 교육 환경 등과 관련된 데이터를 포함하며, 교육의 질 향상과 개인 맞춤형 학습을 지원하는 데 활용된다.

데이터 유형	정의	예시	활용 사례
학생 데이터	학생의 학업 성과 및 행동에 관한 데이터	성적, 출결, 학습 이력, 참여도	학습 성과 분석, 맞춤형 학습 경로 제공
교육 콘텐츠 데이터	교육 과정 및 교재, 학습 자료	강의 영상, 문제은행, 수업 자료	온라인 학습 플랫폼, 교사와 학생의 상호작용
평가 데이터	학생의 학습 진척도와 평가 기록	시험 결과, 과제 점수, 자기 평가	학습 진단, 성과 예측, 학습 계획 수립
교육 환경 데이터	교육 시설 및 학습 환경에 관한 정보	학급 환경, 교실 설비, 기술적 도구 사용 기록	시설 관리, 교육적 효율성 향상

예시	수학 과목 문제 생성 데이터
이미지 데이터	
라벨링 데이터	<pre>{ "question_filename": "고등수학005.png", "id": "26267_97189", "question_info": [{ "question_grade": "H", "question_term": 1, "question_topic_name": "인수정리", "question_type1": "단답형", "question_sector1": "이해", "question_sector2": "변화와 관계", "question_step": "기본", }], "OCR_info": [{ "figure_text": null, "question_text": "다항식 \$x^3+ax^2+bx-2\$가 \$x^2+3x+2\$로 나누어떨어질 때, 상수 \$a,b\$에 대하여 \$ab\$의 값을 구하십시오.", "question_bbox": [{ "type": "line", "bbox": [1, 1, 583, 25], "text": null }], }], ... }</pre>

▶ 법률 데이터

법률 문서, 판례, 계약서, 규제 정보 등과 같이 법적 판단 및 해석에 필요한 데이터를 포함하며, 법률 서비스의 자동화와 효율화를 지원한다.

데이터 유형	정의	예시	활용 사례
법령 및 규제 데이터	국가 및 지역별 법률과 규제에 관한 정보	민법, 상법, 환경법, 정부 규제 문서	법률 연구, 규제 준수, 법률 정책 개발
판례 데이터	법원에서 내려진 판결 관련 문서	판결문, 재판 기록, 법원 의견서	법률 자문, 사례 분석, 판례 연구
계약서 및 문서 데이터	법적 계약 관련 서류	계약서 초안, 계약 조건, 계약서 수정 기록	계약 자동화, 계약 검토, 법적 리스크 평가
법률 상담 데이터	법률 자문 및 상담 기록	고객 상담 기록, 법률 상담 결과	법률 서비스 개선, 고객 관리 시스템 구축

예시

법률 번역 데이터

텍스트 데이터

[illegible]

라벨링 데이터

```
{
  "Dataset": {
    "DataSetNum": "90-1",
    "original_lang": "KOR",
    "trans_lang": "cn",
    "Sentence_cnt": 36
  },
  "info": {
    "DocType": "결정",
    "Sentencing": "친족법",
    "Precedent": {
      "PrecedentID": 179453,
      "PrecedentDate": 20150709,
      "PrecedentName": "친양자입양신청",
      "PrecedentKinds": "가사",
      "PrecedentCourt": "창원지법",
      "PrecedentPlaintiff": null,
    }
  },
  "Annotations": [
    {
      "Annotation_type": "판시사항",
      "Unique_num": 358860,
      "Origin_Sentence": "甲과 乙이 협의이혼을 하면서 丙에 대한 친권자 및 양육자로 甲을 지정하고 양육비의 지급이나 면접교섭권 등에 대하여는 별도로 정하지 않음",
      "Trans_Sentence":
        "当甲方和乙方协商离婚时，他们指定甲方为丙方的父母和监护人，并没有指定子女抚养费的支付或协商面谈的权利。",
    }
  ]
}
```

3 인증 등급 및 유효기간

3.1 인증 등급

데이터 내용 인증은 데이터 구조 유형과 인증 등급을 구분하여 판정한다. 데이터 구조 유형은 데이터의 복잡도에 따라 구분하며, 데이터 인증 등급은 데이터의 품질기준에 따라 등급을 부여한다.

■ 데이터 구조 유형

데이터 구조 유형은 심사에 적용된 심사 항목을 기준으로 데이터의 복잡도를 평가하여 분류한다.

데이터 구조 유형	설명	기준
Complex-Type	데이터 구조가 매우 복잡하여 모든 필수 심사 항목과 여러 선택 심사 항목이 적용되는 유형이다. 다수의 관계, 규칙, 조건이 요구되며, 데이터 관리와 분석이 고도화된 환경에서 주로 사용된다.	- 적용 가능 필수 항목 모두 적용 - 선택 항목 3개 이상 적용
Normal-Type	데이터 구조가 중간 수준의 복잡도를 가지며, 모든 필수 심사 항목이 적용되지만, 선택 심사 항목은 일부만 적용되는 유형이다. 기본적인 관계와 규칙이 요구되며, 표준적인 데이터 관리 환경에 적합하다.	- 적용 가능 필수 항목 모두 적용 - 선택 항목 3개 미만 적용
Simple-Type	데이터 구조가 단순하며, 필수 심사 항목 중 일부만 적용되는 유형이다. 데이터의 관계와 조건이 단순하고 관리가 비교적 용이한 데이터에 해당한다.	필수 항목 일부 적용

■ 인증 등급

데이터 내용 인증은 심사 결과에 따라 데이터 품질 수준을 평가하고, 인증 등급은 Class A, Class B, Class C로 구분되며, 기준 및 세부 내용은 다음과 같다.

인증 등급	설명	기준
Class A	가장 높은 등급으로, 데이터 품질이 최고 수준이며 데이터 정합률이 높아 정확성과 일관성이 뛰어나다. 신뢰도 높은 데이터를 제공하여 다양한 목적으로 활용하기에 적합하다.	- 개별 심사 항목 점수 0.95 이상 - 데이터 품질 점수 0.99 이상
Class B	데이터 품질이 우수하며, 데이터 정합률이 높은 수준을 유지한다. 데이터는 안정적이고 유용하며, 신뢰할 수 있는 품질을 제공한다.	- 개별 심사 항목 점수 0.95 이상 - 데이터 품질 점수 0.97 이상
Class C	기본적인 품질 요건을 충족하며, 데이터 정합률이 사용 가능한 수준을 유지한다. 다만, 추가적인 품질 개선이 필요한 경우도 있을 수 있다.	- 개별 심사 항목 점수 0.95 이상 - 데이터 품질 점수 0.95 이상

3.2 인증 유효기간

데이터 내용 인증의 유효기간은 1년이다. 이는 데이터가 시간이 경과함에 따라 추가·수정·삭제 등으로 내용이 변경될 수 있기 때문이다. 신청기관은 1년마다 DQ인증을 통해 데이터의 신뢰성과 최신성을 다시 확인하며, 인증받은 데이터가 요구 수준의 품질을 유지하도록 관리한다.

II

인증심사


1. 심사절차
2. 심사 기준
3. 정형 데이터 심사
4. 비정형 데이터 심사

II 인증심사

1 심사절차

1.1 개요

데이터 내용 인증심사는 인증 신청 이후 다음과 같은 절차에 따라 진행한다.



1.2 절차별 수행 내용

■ 심사팀 구성

심사의 공정성과 객관성을 확보하기 위해, 심사팀은 인증심사팀장 및 인증심사원 등 과기정통부 전문심사원 자격을 갖춘 2인 이상으로 구성한다. 인증기관은 효율적인 심사를 위해 신청기관의 산업 특성, 인증대상 데이터의 범위 및 데이터 유형, 데이터 활용 목적, 데이터 관련 기술의 다양성, 개별 심사원의 심사 수행 경험(심사 횟수 등)을 고려하여 심사원을 배정한다.

■ 심사계획 수립

인증기관은 인증신청서 및 제출 서류를 기반으로 심사팀 구성, 심사 일정, 심사 범위 및 심사 방법, 심사 공간 및 환경을 포함한 심사계획을 수립한다. 필요 시 신청기관과 협의하여 현장 심사 여부, 심사 공간 확보, DB 접근 권한 및 계정 부여 방식, 기타 심사에 필요한 사항을 조정·확정한다.

▶ 인증대상 분석 및 심사 항목 선정

인증심사원은 데이터 명세서를 분석하여 데이터의 구조 및 특성에 따라 해당 데이터에 적합한 심사 항목을 선정한다. 선정된 심사 항목을 기준으로 데이터 유형(정형·비정형)과 데이터 구조 유형(Simple/Normal/Complex)을 판정한다.

필수항목	데이터의 특성에 따라 선정 기준에 충족되면 심사 항목으로 선정
선택항목	데이터의 특성에 따라 선택적으로 심사 항목으로 선정

▶ 심사 환경 검토

인증심사원은 심사의 신뢰성과 효율성을 확보하기 위해 다음 요소를 검토한다.

심사 도구 사용 및 심사대상 접근 가능 환경	- 심사 도구를 설치·사용할 수 있는 심사 장비(H/W 및 OS) 구성 가능 여부 검토 - 심사대상에 접근 가능한 환경 구성 가능 여부 검토
기술 기록 수집·관리 환경	- 심사에 관한 기술 기록 보관·유지·관리 가능 환경 구성 가능 여부 검토 - 심사 과정에서 수집한 데이터의 백업 가능 환경 구성 가능 여부 검토 - 심사 수행 시점의 기술 기록의 입증 가능 환경 구성 가능 여부 검토 - 장비 생성 파일의 저장·보관 가능 환경 구성 가능 여부 검토
논리적·물리적 보안 환경 확인	- 심사 데이터 유출·위변조 방지를 위한 외부의 침입 차단 등 논리적 보안 환경 구성 가능 여부 검토 - 인증심사를 위한 독립된 공간으로 물리적 보안(시건 장치 등) 환경 구성 가능 여부 검토

심사 환경 예시

(예시 1)

- OS: Windows
- 대상 DBMS: MySQL
- DB 접속: 외부망 불가하여 신청기관의 내부 인트라넷으로 접속
- 도구: DBeaver를 통해 대상 DBMS 접근 가능
- 기술 기록: DBeaver를 통해 심사한 결과에 대한 로그나 스크린 캡처 시 파일이 저장된 시간으로 저장됨
- 논리적 보안: 심사 장비에 대하여 논리적으로 외부 접근이 불가함
- 물리적 보안: 심사 장소가 독립적이고 잠금장치가 있어 심사원 및 관계자 외 출입이 불가함

▶ 심사 도구 검토

심사 대상 데이터의 특성과 심사 항목에 적합한 도구인지 확인한다. 심사 항목을 효과적으로 측정할 수 있는 기능을 보유했는지 검토한 후, 최종 심사 도구를 선정한다.

도구 예시

- DBMS Client 프로그램: MySQL, Oracle for Client, DBeaver 등 SQL 쿼리문을 사용하여 정형 데이터를 심사할 수 있는 도구
- 데이터품질 진단 프로그램
- 파이썬 라이브러리를 활용한 스크립트: 다양한 파이썬 라이브러리 내 함수를 활용한 스크립트
- 비정형 데이터 라벨링 도구: 비정형 데이터의 원천데이터와 어노테이션 데이터를 육안으로 확인하여 검증할 수 있는 도구

▶ 심사 계획 수립

심사 대상 데이터의 특성과 목적에 따라 심사 항목, 심사 환경 및 도구, 심사 일정, 심사 방법(샘플링 여부, 자동·수동 점검 비율 등)을 구체적으로 정의한다. 이를 통해 심사가 체계적이고 일관되게 수행될 수 있도록 계획을 확정한다.

● 심사 수행

▶ 심사 환경 구성

인증심사원은 아래와 같이 심사 환경을 구성한다.

심사 도구 사용 및 심사대상 접근 가능 환경	- 심사 도구를 설치·사용할 수 있는 심사 장비(H/W 및 OS) 구성 - 심사대상에 접근 가능한 환경 구성
기술기록 수집·관리 환경	- 심사에 대한 기술기록 보관·유지·관리 가능 환경 구성 - 현장 심사 과정에서 수집한 데이터의 백업 가능 환경 구성 - 심사 수행 시점의 기술기록의 입증 가능 환경 구성 - 장비 생성 파일의 저장·보관 가능 환경 구성
논리적·물리적 보안 환경 확인	- 심사 데이터 유출·위변조 방지를 위한 외부의 침입 차단 등 논리적 보안 환경 구성 - 인증심사를 위한 독립된 공간으로 물리적 보안(시건 장치 등) 환경 구성

▶ 수립된 심사계획에 따라 심사를 수행

인증심사원은 프로파일링 등 사전 분석을 통해 심사대상 데이터의 특성을 파악하고, 데이터 명세서의 적정성(정의, 구조, 관계, 규칙 등)을 검토한 후, 수립된 심사계획에 따라 실제 심사를 수행한다.

▶ 오류 데이터 추정 및 심사 결과 분석

심사 수행 후, 심사팀 내부 회의를 통해 각 심사 항목별 오류 데이터를 추정하고, 오류 유형을 분류하며, 부적합 사항을 분류한다.

● 심사 결과 공유

심사 결과를 신청기관에 공유하여, 심사팀이 추정한 오류 데이터 목록을 제시하고, 신청기관과 함께 오류 여부를 검토하여 오류 데이터로 확정한다. 신청기관은 심사 결과를 바탕으로 데이터 명세서와 오류 데이터를 수정·보완한다.

● 회귀 심사 수행(최종 심사 수행)

신청기관이 수정·보완을 완료한 후, 인증심사원은 최종 데이터 명세서 및 수정된 데이터를 기준으로 회귀(최종) 심사를 수행한다. 이 과정에서 시정조치가 적절히 반영되었는지, 부적합 사항이 해소되었는지, 품질 수준이 인증 기준에 부합하는지 재확인한다.

● 심사결과보고서 작성

최종 심사 결과를 바탕으로 심사팀은 심사의 주요 내용을 종합 정리하여 심사결과보고서를 작성한다. 심사팀장은 보고서를 검토하여 심사 결과의 타당성, 심사 과정의 적정성, 결론 및 판정 근거의 명확성을 확인한다.

● 인증심의위원회 상정

최종 심사 결과가 인증 상정 기준을 충족하는 경우, 해당 결과는 인증심의위원회에 상정된다. 인증 등급별 상정 기준은 아래와 같다.

인증 등급	인증 상정 기준
Class A	모든 개별 심사 항목이 최소 0.95 이상이고, 심사 항목 평균 점수 0.99 이상
Class B	모든 개별 심사 항목이 최소 0.95 이상이고, 심사 항목 평균 점수 0.97 이상
Class C	모든 개별 심사 항목이 최소 0.95 이상이고, 심사 항목 평균 점수 0.95 이상

1.3 주요 심사대상 서류 및 증빙

데이터 내용 인증을 위해 제출되는 주요 심사대상 서류는 데이터의 구조와 속성을 객관적으로 증빙하기 위한 것이다. 정형 데이터와 비정형 데이터의 제출 서류는 아래와 같으며 유형별로 요구되는 서류가 다를 수 있으므로, 세부 목록은 인증기관과의 협의를 통해 확정한다.

● 정형 데이터

테이블 정의서	테이블명, 엔티티 정보 등을 정의한 문서
항목 정의서	데이터 항목 정보를 정의한 문서
코드 정의서	컬럼에 기재된 각 코드 정보를 정의한 문서
ERD(객체관계도)	각 엔티티 간의 관계도
항목에 적용된 도메인 규칙 및 업무규칙	각 항목별로의 연관성을 분석할 수 있는 문서

● 비정형 데이터

데이터 명세서	데이터 정보(확장자, 데이터 수), 데이터 구성 및 파일 포맷을 정의한 문서
메타데이터 및 어노테이션 명세서	메타데이터 및 어노테이션의 구조 및 세부 속성 정보를 정의한 문서
라벨링 가이드(작업지시서)	데이터(비정형 객체 등) 수집, 정제, 라벨링, 전처리 수행을 위한 기준, 방법 등을 정의한 문서

2 심사 기준

2.1 데이터 내용에 적용되는 품질기준

데이터 내용에 대한 DQ인증 심사 기준은 과학기술정보통신부 「데이터 품질 인증기관 지정 및 운영에 관한 지침」에서 정의한 데이터 품질기준 10가지 중, 데이터 내용에 관한 6가지 기준을 적용한다.

기준	내용
완전성	사용목적에 맞게 설계된 데이터가 필수항목을 누락 없이 포함하여 완전한지 진단하는 기준
유효성	데이터가 규정된 형식과 의미, 관계 규칙을 준수하고 논리적으로 타당한지 진단하는 기준
일관성	준수해야 하는 표준, 규칙, 기준에 따라 데이터가 일관되게 입력되어 있는지 진단하는 기준
정확성	데이터가 업무규정 또는 논리에 따라 구조적, 의미적으로 정확한지 진단하는 기준
접근성	데이터가 쉽게 접근할 수 있고 사용하기에 편리한지 진단하는 기준
유일성	데이터가 중복되지 않고 유일한지 진단하는 기준

참고	데이터 품질기준
「데이터 산업진흥 및 이용촉진에 관한 기본법」과 동법 시행령에 따라 제정된 「데이터 품질 인증기관 지정 및 운영에 관한 지침」에서는 데이터의 일정 수준 이상의 품질을 충족한 데이터를 인증하기 위한 데이터 품질기준을 아래와 같이 규정하고 있다.	
기준	내용
완전성	사용목적에 맞게 설계된 데이터가 필수항목을 누락 없이 포함하여 완전한지 진단하는 기준
유효성	데이터가 규정된 형식과 의미, 관계 규칙을 준수하고 논리적으로 타당한지 진단하는 기준
일관성	준수해야 하는 표준, 규칙, 기준에 따라 데이터가 일관되게 입력되어 있는지 진단하는 기준
정확성	데이터가 업무규정 또는 논리에 따라 구조적, 의미적으로 정확한지 진단하는 기준
보안성	데이터가 보안 정책에 따라 안전하게 보호되고, 적절히 관리되고 있는지 진단하는 기준
유용성	데이터가 사용자의 데이터 활용 목적 및 요구사항에 부합하는 정보를 제공하는지 진단하는 기준
접근성	데이터가 쉽게 접근할 수 있고 사용하기에 편리한지 진단하는 기준
적시성	데이터가 최신성을 유지하고 사용자가 원하는 시점에 적합한 데이터를 적절하게 제공할 수 있는지 진단하는 기준
다양성	데이터가 사용자의 이용 목적에 적합한 다양한 특성을 포괄하고 편향되지 않았는지 진단하는 기준
유일성	데이터가 중복되지 않고 유일한지 진단하는 기준

참고

업무 규칙, 파생 규칙, 도메인 규칙

● 업무 규칙 (Business Rule)

정의: 특정 업무나 비즈니스 프로세스에 따라 데이터를 정의하고 사용하는 데 필요한 규칙

예시

- 고객 등급: 매출액에 따라 고객 등급을 "VIP", "일반", "신규"로 구분
- 배송 상태: 주문 데이터의 "배송 상태" 값은 "배송 준비", "배송 중", "배송 완료"로 제한
- 현재 연도 = 2024, 입사 연도 = 2018 → 근속 연수 = 6

● 파생 규칙 (Derived Rule)

정의: 기존 데이터 값이나 계산된 값을 바탕으로 새로운 값을 도출하는 규칙

예시: 산술 연산이나 계산식을 기반으로 새로운 데이터 생성

- 잔액 계산: 수입 - 지출 = 잔액
(예: 수입 = 500만원, 지출 = 200만원 → 잔액 = 300만원)
- 총 매출: 단가 × 판매량
(예: 단가 = 1만원, 판매량 = 500 → 총 매출 = 500만원)
- 나이 계산: 현재 연도 - 태어난 연도 = 나이
(예: 현재 연도 = 2025년, 태어난 연도 = 2001년 → 나이 = 24세)
- 총 관객 수: 지역별 관객 수 합계
(예: 서울 관객 수 = 5,000명, 부산 관객 수 = 3,000명 → 총 관객 수 = 8,000명)

● 도메인 규칙 (Domain Rule)

정의: 특정 데이터 항목에 허용 가능한 값의 범위, 형식, 조건 등을 정의하는 규칙

예시: 데이터 값의 범위, 형식, 코드 등에 대한 제약

- 전화번호 형식: "+국가번호-지역번호-전화번호" 형식이어야 함
(예: +82-10-1234-5678)
- 날짜 형식: 날짜는 "YYYY-MM-DD" 형식이어야 함 (예: 2024-01-01)
- 성별 코드: 성별은 "M"(남성), "F"(여성)으로 제한 (예: M, F 외 다른 값은 오류)
- 우편번호 범위: 우편번호는 5자리 숫자로만 구성 (예: 12345)
- 온도 범위: 센서 데이터에서 온도 값은 -50°C에서 50°C 사이여야 함
(예: -10°C (정상), 60°C (오류))

③ 정형 데이터 심사

정형 데이터 심사는 DQ인증 품질기준을 바탕으로, ISO/IEC 25024에서 정의된 데이터 품질 측정 지표를 준용하여 총 14개 심사 항목으로 구성된다. 심사 항목은 필수 항목과 선택 항목으로 구분된다.

■ 정형 데이터 심사 항목

번호	기준	심사 항목명	설명
1	완전성	데이터 값 완전성	필수(NOT NULL)로 선언된 컬럼에 모든 데이터 값이 존재하는지를 심사하는 항목
2		데이터 레코드 완전성	레코드가 누락 없이 필요한 데이터를 모두 포함하고 있는지를 심사하는 항목
3	유효성	구문 유효성	데이터 값이 컬럼에 정해진 구문 규칙을 따르는지를 심사하는 항목
4		의미 유효성	데이터 값이 의미적으로 유효하고 설정된 기준에 부합하는지를 심사하는 항목
5		범위 유효성	데이터 값이 유효한 범위 내에 있는지를 심사하는 항목
6		관계 유효성	데이터 값이 다른 컬럼과의 관계 규칙을 준수하는지를 심사하는 항목
7		데이터 값 정밀성	데이터 값이 정밀도 요구사항을 충족하는지를 심사하는 항목
8	일관성	참조 무결 일관성	데이터 값이 테이블 간의 참조 무결성 규칙을 지키는지를 심사하는 항목
9		데이터 포맷 일관성	데이터 파일 내에서 동일 속성의 데이터 구문(형식)이 일관되게 유지되고 있는지를 심사하는 항목
10		공통 어휘 일관성	데이터 사전에 정의된 공통 용어를 사용하는지를 심사하는 항목
11	정확성	메타 데이터 정확성	메타데이터의 데이터 값이 정확하고 설정된 요구사항에 부합하는지를 심사하는 항목
12		데이터 값 정확성	컬럼 간 규칙에 따라 데이터의 값이 정확한지를 심사하는 항목
13	접근성	표준기반 데이터 접근성	데이터가 요구되는 표준이나 협약을 준수하여 데이터에 용이하게 접근할 수 있는지를 심사하는 항목
14	유일성	데이터 값 유일성	데이터의 특정 값이 중복 없이 유일한지를 심사하는 항목

필수 심사 항목과 선택 심사 항목 선정

정형 데이터 심사의 항목은 필수 항목과 선택 항목으로 구분된다.

필수 심사 항목	정형 데이터의 기본적인 품질을 평가하는 항목
선택 심사 항목	정형 데이터의 특수한 요구사항이나 활용 목적에 따라 추가적인 품질을 평가하는 항목

심사 대상 데이터에 대해 데이터 명세서(스키마, 제약조건, 규칙 등)와 프로파일링 결과를 종합 분석하여 적용할 심사 항목을 선정하고, 선정된 항목 수에 따라 구조 유형(Simple-Type, Normal-Type, Complex-Type)을 분류한다.

구분	데이터 품질기준	심사 항목
필수 심사 항목 (7개)	완전성(2개)	데이터 값 완전성, 데이터 레코드 완전성
	유효성(4개)	구문 유효성, 의미 유효성, 범위 유효성, 관계 유효성
	일관성(1개)	참조 무결 일관성
선택 심사 항목 (7개)	유효성(1개)	데이터 값 정밀성
	일관성(2개)	데이터 포맷 일관성, 공통 어휘 일관성
	정확성(2개)	메타데이터 정확성, 데이터 값 정확성
	접근성(1개)	표준기반 데이터 접근성
	유일성(1개)	데이터 값 유일성

3.1 완전성

완전성은 데이터가 명세서에서 정의된 필수 항목과 레코드에 누락 없이 포함되어 있는지를 평가하는 기준이다. 필수 값의 누락 여부(NULL 또는 공백)를 식별하고, 데이터 값과 레코드의 완전성을 진단하여 데이터의 신뢰성을 확보하는 데 중점을 둔다. 이를 통해 데이터 누락으로 인한 품질 저하를 방지할 수 있다. 정형 데이터의 심사 항목은 다음과 같다.

■ (필수) 데이터 값 완전성

필수(NOT NULL)로 선언된 컬럼에 모든 데이터 값이 존재하는지를 심사하는 항목이다. 예를 들어, 고객 테이블에서 필수 항목인 "이름"과 "연락처"가 비어 있지 않은지 확인한다.

- ▶ **적용 대상:** NULL 값(또는 공백)을 허용하지 않는 컬럼
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 'NULL'이나 공백이 포함된 데이터 값
 - 진단 데이터: 데이터 명세서에 'NOT NULL'로 정의된 컬럼의 데이터 값



심사기준을 영상으로
확인하세요!

데이터 예시

- 예시 1: 고객 데이터베이스의 "이메일" 컬럼이 필수로 설정된 경우
 오류 데이터) ["user1@example.com", null, "", "user4@example.com"]
 정상 데이터) ["user1@example.com", "user2@example.com", "user3@example.com", "user4@example.com"]
- 예시 2: 직원 정보 테이블의 "직원 번호" 컬럼이 필수로 설정된 경우
 오류 데이터) [101, null, 103, ""]
 정상 데이터) [101, 102, 103, 104]
- 예시 3: 주문 테이블의 "배송 주소" 컬럼이 필수로 설정된 경우
 오류 데이터) ["서울 강남구 1번지", "", null, "부산 해운대구 2번지"]
 정상 데이터) ["서울 강남구 1번지", "부산 해운대구 2번지", "대전 서구 1번지", "대구 중구 3번지"]
- 예시 4: 회원 정보 데이터베이스의 "생년월일" 컬럼이 필수로 설정된 경우
 오류 데이터) ["1990-01-01", null, "", "1985-05-20"]
 정상 데이터) ["1990-01-01", "2001-07-22", "2000-10-15", "1985-05-20"]
- 예시 5: 상품 재고 테이블의 "재고 수량" 컬럼이 필수로 설정된 경우
 오류 데이터) [50, null, "", 100]
 정상 데이터) [50, 30, 100, 10]

예시 1

주택 보급률 데이터

- 테이블 내 필수(NOT NULL 선언) 컬럼: 연도, 가구수, 주택합계, 단독주택, 다가구주택, 아파트, 연립주택, 다세대주택, 비거주용 주택, 주택보급률
- 데이터 내용

연도	가구수	주택합계	단독주택	다가구주택	아파트	연립주택	다세대주택	비거주용 주택	주택 보급률
	38656	45181	16663	5406	25448	1844	1226	1	116.90%
2020	38659	46459	11226	5379	26784	1844	1226		
2021	38466	47457	11303	5533	27551	1844	1226		123.37%
2022	37737	47865		5551		1844	1226	2	126.83%
2023		48355	11319	5559	28407	1844	1226		128.15%

- 진단 총 데이터 수: 45
- 오류 데이터 수: 5
- 데이터 값 완전성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 5 / 45$
 $= 0.89$

예시 2

체육시설 데이터

- 테이블 내 필수(NOT NULL 선언) 컬럼: 순번, 시설명, 주소, 구조
- 데이터 내용

순번	시설명	주소	구조	부지면적	건축면적	관리주체
1	종합사격장	청운면 청운로 168-46	클레이사격, 일반사격, 시설 부대, 숙소	130701	8526	문화체육과
2	국제양궁장	오수면 의견로 1	주 경기장, 보조 경기장, 관람시설 등		1812	문화체육과
3	서바이벌게임장	성수면 도인리 698-8번지	운영시설, 세트장	3035	128	
				7048	2157	문화체육과
5	군자정	임실읍 호국로 1632	국궁장	18591	370	문화체육과

- 진단 총 데이터 수: 20
- 오류 데이터 수: 4
- 데이터 값 완전성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 4 / 20$
 $= 0.80$

● (필수) 데이터 레코드 완전성

빈 레코드(모든 데이터의 값이 없거나 공백인 경우)가 존재하는지를 점검하는 항목으로 모든 필드의 값이 NULL이거나 공백인 빈 레코드가 존재하지 않는지를 확인한다.

▶ **적용 대상:** 전체 레코드

▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 모든 필드의 값이 NULL 또는 공백인 레코드
- 진단 데이터: 레코드 완전성이 요구되는 전체 레코드



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 제품 재고 데이터의 경우

오류 데이터) [{"product_id": null, "name": null, "quantity": null, "price": null}]

정상 데이터) [{"product_id": 1, "name": "Laptop", "quantity": 10, "price": 1000}]

예시 2: 환자 기록 데이터의 경우

오류 데이터) [{"patient_id": null, "diagnosis": null, "treatment": null}]

정상 데이터) [{"patient_id": 1, "diagnosis": "Hypertension", "treatment": "Medication"}]

예시 3: 매출 기록 데이터의 경우

오류 데이터) [{"sales_id": null, "amount": null, "date": null, "customer_id": null}]

정상 데이터) [{"sales_id": 1, "amount": 50000, "date": "2024-11-24", "customer_id": 1001}]

예시 4: 학교 출석 기록 데이터의 경우

오류 데이터) [{"record_id": null, "name": null, "student_id": null, "status": null}]

정상 데이터) [{"record_id": 1, "name": "John Doe", "student_id": 20241001, "status": "Present"}]

예시 5: 도서 대출 기록 데이터의 경우

오류 데이터) [{"loan_id": null, "book_id": null, "borrower_id": null, "loan_date": null, "return_date": null}]

정상 데이터) [{"loan_id": 1, "book_id": 30045, "borrower_id": 1023, "loan_date": "2024-10-01", "return_date": "2024-10-15"}]

예시 6: 주문 배송 데이터의 경우

오류 데이터) [{"delivery_id": null, "order_id": null, "address": null, "delivery_status": null}]

정상 데이터) [{"delivery_id": 1, "order_id": 78901, "address": "서울시 강남구", "delivery_status": "Delivered"}]

예시 1

월별 관람객 현황 데이터

● 데이터 내용

월별	어른	청소년	어린이	외국인	단체	계	개관일수	일일평균
1	990	173	401	0	99	1663	24	70
2	1054	83	538	5	288	1968	24	82
3	1511	306	472	0	107	2396	27	89
4	1888	531	753	0	185	3357	26	130
5	2385	704	951	8	275	4323	26	167
6	1965	523	1076	3	440	4007	26	155
7	1901	675	901	4	66	3547	26	137
9	1980	556	966	0	310	3812	25	153
10	2417	463	881	10	1012	4783	26	184

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 데이터 레코드 완전성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 1 / 10$
 $= 0.90$

예시 2

법안 정보데이터

● 데이터 내용

구분	건의	결산안	결의	규칙	기타
2023	2	1	1		1
2021		1	3	2	24
2020		1	2	1	27
2019	1	1	1	1	9

● 진단 총 데이터 수: 5

● 오류 데이터 수: 1

● 데이터 레코드 완전성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 1 / 5$
 $= 0.80$

3.2 유효성

유효성은 데이터 값이 사전에 정의된 포맷, 범위, 의미, 관계 규칙 등을 충족하는지를 평가하는 기준이다. 데이터가 유효성을 만족하지 못할 경우 비즈니스 프로세스에 오류를 초래할 수 있다. 유효성 평가는 데이터가 형식적, 의미적, 범위적, 논리적으로 정확하고 신뢰할 수 있는지를 진단하여 데이터 무결성과 품질을 보장한다. 정형 데이터의 심사 항목은 다음과 같다.

참고	유효성과 정확성의 차이	
	유효성	정확성
	데이터가 정의된 형식, 규칙, 또는 범위를 충족하는지를 평가	- 데이터 값이 정의된 규칙에 따라 기대하는 값과 일치하는지를 평가 - 기대하는 값이 명확한 규칙(산출식)에 적용
	- 주민등록번호 데이터에서 모든 값이 "#####-#####" 형식인지 확인. - 나이 데이터가 0~120 범위 내에 있는지 확인. - 이메일 주소 데이터가 "@", "." 등의 필수 요소를 포함한 올바른 형식을 가지는지 확인.	- 잔액 컬럼의 값이 수식(잔액 = 수입 - 지출)에 맞는지 확인 - 나이 컬럼의 값이 수식(나이 = 올해 - 태어난 해)에 맞는지 확인 - 분기 컬럼의 값이 수식(분기 = $\lceil \text{월} \div 3 \rceil$)에 맞는지 확인
	- 주민등록번호가 "12345-6789012"로 잘못 입력됨 (정해진 형식을 벗어남). - 나이 데이터가 -5 또는 200으로 입력됨 (범위를 벗어남). - 이메일이 "example_at_domain.com"으로 입력됨 (형식 오류).	- 수입: 1,200,000원 / 지출: 500,000원 / 잔액: 750,000원: 오류(잔액이 실제 계산보다 50,000원 많음) - 태어난 해: 1985년 / 올해: 2024년 / 나이: 42세: 오류(2년 많게 계산됨) - 월: 5월 → 분기: 1분기: 오류(이전 분기로 잘못 계산됨)

■ (필수) 구문 유효성

데이터 값이 컬럼에 정의된 구문 규칙을 정확히 따르고 있는지를 심사하는 항목이다. 예를 들어, 이메일 주소가 "username@example.com"로 정의 되었다면, 형식에 맞게 입력되었는지 확인한다.

▶ **적용 대상:** 구문 규칙(ex. 도메인 규칙, 데이터 구문 등)이 정의된 문자열 컬럼

▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 정의된 구문 규칙을 준수하지 않은 데이터 값
- 진단 데이터: 구문 규칙이 정의된 컬럼의 데이터 값



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 이메일 컬럼의 구문 규칙이 "abc@example.com" 형식으로 설정된 경우
오류 데이터) ["abc#example.com", "user@@domain.com", "testemail.com"]
정상 데이터) ["user1@example.com", "user2@example.com", "user3@example.com"]

예시 2: 날짜 컬럼의 구문 규칙이 "YYYY-MM-DD" 형식으로 설정된 경우
오류 데이터) ["11-25-2024", "31/12/2023", "2024.05.01", "2023/06/15", "01-01-2022"]
정상 데이터) ["2024-11-25", "2023-12-31", "2024-05-01", "2023-06-15", "2022-01-01"]

예시 3: 우편번호 컬럼의 구문 규칙이 "5자리 숫자" 형식으로 설정된 경우
오류 데이터) ["1234A", "123456", "ABCDE", "12A34", "9876B"]
정상 데이터) ["12345", "67890", "54321", "98765", "11223"]

예시 4: 전화번호 컬럼의 구문 규칙이 "(XXX) XXX-XXXX" 형식으로 설정된 경우
오류 데이터) ["123-456-7890", "9876543210", "(555)1234567", "(202 555-7890")
정상 데이터) ["(123) 456-7890", "(987) 654-3210", "(555) 123-4567", "(202) 555-7890"]

예시 5: 신용카드 번호 컬럼의 구문 규칙이 "16자리 숫자" 형식으로 설정된 경우
오류 데이터) ["1234-5678-1234-567X", "987654329876543", "1111-2222-3333-4444X"]
정상 데이터) ["1234567812345678", "9876543298765432", "1111222233334444"]

예시 1

유기 동물 현황 데이터

● 구문 규칙이 정의된 컬럼

컬럼명	구문 규칙
공고번호	한글2자리-한글2자리-숫자4자리-숫자5자리
공고기간	YYYY-MM-DD~YYYY-MM-DD
접수일시	YYYY-MM-DD
출생연도	YYYY

● 데이터 내용

공고번호	공고기간	접수일시	축종	색상	체중	출생연도
경남-거제-2024-00457	2024-10-03~2024-10-14	2024-10-03	고양이	갈색	3	2020
경남-거제-2024-00456	2024-10-03~2024-10-14	2024-10-03	개	흰색	3	1
경남-거제-2024-00455	2024-10-02~2024-10-14	2024-10-02	고양이	연갈색	0.8	2024
경남-JP-2024-00454	2024-10-02~2024-10-14	2024-13-02	고양이	연갈색	0.8	24년
경남-거제-2024-0045	2024-10-02~2024-10-14	2024-10-02	고양이	연갈색	0.8	2024

● 진단 총 데이터 수: 20

● 오류 데이터 수: 6

● 구문 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 6 / 20$$

$$= 0.70$$

예시 2

국제선 항공기 스케줄 데이터

● 구문 규칙이 정의된 컬럼

컬럼명	구문 규칙
항공사	영문 3자리
운항편명	영문 2자리 + 숫자
출발공항	영문 3자리
도착공항	영문 3자리
출발시간	hh:mm
도착시간	hh:mm
시작일자	YYYY-MM-DD
종료일자	YYYY-MM-DD
국내국제	한글 2글자

● 데이터 내용

항공사	운항 편명	출발 공항	도착 공항	출발 시간	도착 시간	운항 요일	시작일자	종료일자	국내 국제
AAL	AA9604	ICN	DFW	16:30	15:30	토	2024-08-03	0000-00-00	국제
AAR	OZ101	NRT	ICN	13:20	15:50	금	2024-05-24	2024-05-24	국제
AAR	OZ101	NRT	ICN	13:20	3:50	월수	2024-07-01	2024-10-26	가방
AAR	OZ101	NRT	ICN	13:20	15:50	월	2024-05-06	2024-05-06	해외
AAR	OZ101	NRT	ICN	13:20	15:50	월	2024-06-17	2024-06-17	여자
AAR	OZ101	NRT	ICN	13:20	15:50	월	2024.09.30	2024-09-30	여자
JEJU	OZ101	NRT	인천	13:20	15:50	화	2024-10-01	2024-10-01	국제
AAR	OZ1013	NRT	AAA	20:10	22:50	월	2024-05-06	2024-05-06	국제
AAR	OZ1013	NRT	ICN	20:10	22:50	화	2024-05-07	2024-05-07	남자
AAR	OZ102	ICN	NRT	9:00	11:20	금	2024-05-24	2024-05-24	국제

● 진단 총 데이터 수: 90

● 오류 데이터 수: 5

● 구문 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 5 / 90$$

$$= 0.94$$

■ (필수) 의미 유효성

데이터 값이 의미적으로 유효하고 설정된 기준에 부합하는지를 심사하는 항목이다.

▶ **적용 대상:** 의미적으로 유효한 값의 목록이 정의된 컬럼

▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 의미적으로 유효한 값의 목록에 존재하지 않는 데이터 값
- 진단 데이터: 의미적으로 유효한 값의 목록이 정의된 컬럼의 데이터 값

※ 의미 유효성은 해당 필드나 속성에 의미적으로 유효한 데이터가 존재하는지 확인하는 항목이지만, 다양한 전문분야(예:의료, 화학, 반도체 등)의 전문용어에 대한 의미 유효성 심사가 불가능하여 의미 유효성 측정을 위한 참조 데이터(리스트)가 존재해야 함



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: "성별" 컬럼의 유효한 값이 "M" (남성), "F" (여성)으로 정의된 경우

오류 데이터) ["X", "UNKNOWN", "Other", "NA", "U"]

정상 데이터) ["M", "F", "M", "F", "M"]

예시 2: "요일" 컬럼의 유효한 값이 "Monday", "Tuesday", "Wednesday", "Thursday"으로 정의된 경우

오류 데이터) ["Holiday", "Weekend", "Funday", "Weekday", "Offday"]

정상 데이터) ["Monday", "Tuesday", "Wednesday", "Thursday", "Monday"]

예시 3: "결제 방식" 컬럼의 유효한 값이 "Credit Card", "Cash", "Bank Transfer", "PayPal"으로 정의된 경우

오류 데이터) ["Crypto", "Cheque", "Bitcoin", "Wire Transfer", "Apple Pay"]

정상 데이터) ["Credit Card", "Cash", "Bank Transfer", "PayPal", "Credit Card"]

예시 4: "배송 상태" 컬럼의 유효한 값이 "Shipped", "Pending", "Delivered", "Cancelled"으로 정의된 경우

오류 데이터) ["In Progress", "On the Way", "Returned", "Awaiting Pickup", "On Hold"]

정상 데이터) ["Shipped", "Pending", "Delivered", "Cancelled", "Shipped"]

예시 5: "회원 등급" 컬럼의 유효한 값이 "Bronze", "Silver", "Gold", "Platinum"으로 정의된 경우

오류 데이터) ["Diamond", "VIP", "Premium", "SuperGold", "UltraPlatinum"]

정상 데이터) ["Bronze", "Silver", "Gold", "Platinum", "Gold"]

예시 1 가족상담 기관 데이터

● 의미 유효성이 요구된 컬럼

컬럼명	의미 데이터 목록
지역	서울, 부산, 대구, 인천, 광주, 대전, 울산, 세종, 경기, 강원, 충북, 충남, 전북, 전남, 경북, 경남, 제주

● 데이터 내용

순번	지역	센터명	인증년도	인증기간	전화번호
1	서울	강남구가족센터	2024년	2025-01-01 ~ 2026-12-31	02-3412-2222
2	부산	금정구가족센터	2024년	2025-01-01 ~ 2026-12-31	051-513-2131
3	LA	대구북구가족센터	2024년	2024-08-19 ~ 2026-12-31	053-327-2994
4	대전	대전광역시가족센터	2024년	2025-01-01 ~ 2026-12-31	042-932-9995
5	울산	울산남구가족센터	2024년	2024-08-19 ~ 2026-12-31	052-274-3136
6	세종	세종시가족센터	2024년	2024-08-19 ~ 2026-12-31	044-862-9336~8
7	서쪽	가평군가족센터	2024년	2025-01-01 ~ 2026-12-31	031-582-9902
8	강원	양구군가족센터	2022년	2023-01-01 ~ 2024-12-31	033-480-2445
9	남부	제천시가족센터	2024년	2025-01-01 ~ 2026-12-31	043-645-1995

● 진단 총 데이터 수: 9

● 오류 데이터 수: 3

$$\begin{aligned}
 \text{의미 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 3 / 9 \\
 &= 0.67
 \end{aligned}$$

예시 2 수목원 수목 상세 정보 데이터

● 의미 유효성이 요구된 컬럼

컬럼명	의미 데이터 목록
국명	꽃댕강나무 '프랜시스 메이슨', 땡강나무, 섬댕강나무, 미선나무, 분홍미선나무, 상아미선나무, 구상나무, 분비나무, 전나무, 아브로마 아우구스툼, 가두리아카시아, 글라우콤테라아카시아, 긴잎아카시아
과명	Caprifoliaceae, Oleaceae, Pinaceae, Malvaceae, Fabaceae, Euphorbiaceae, Orchidaceae, Acanthaceae, Myrtaceae, Aceraceae
과국명	인동과, 물푸레나무과, 소나무과, 아욱과, 콩과, 대극과, 난초과, 쥐꼬리망초과, 도금양과, 단풍나무과
속명	Abelia, Abeliophyllum, Abies, Abroma, Acacia, Acalypha, Acampe, Acanthus, Acca, Acer

● 데이터 내용

국명	과명	과국명	속명	자생재배	특산
댕강나무	Caprifoliaceae	인동과	Aebeliria	자생식물	
섬댕강나무	Caprifoliaceae	인동과	Abelia	자생식물	
미선나무	Oleaceae		Abeliophyllum	자생식물	특산식물
분홍미선나무	Oleaceae	물푸레나무과	Abeliophyllum	자생식물	
상아미선나무	Oleaceae	안과	Abeliophyllum	재배식물	
봉선화꽃	Pinaceae	소나무과	Abies	자생식물	특산식물
분비나무	Pinaceae	소나무과	Abies	자생식물	
전나무	Pinaceae	소나무과	Abieseee	자생식물	
아브로마 아우구스툼	Malvaceae	아욱과	Abroma	재배식물	

- 진단 총 데이터 수: 35
- 오류 데이터 수: 4
- 의미 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 4 / 35$$

$$= 0.89$$

■ (필수) 범위 유효성

데이터 값이 허용된 범위 내에 포함되는지를 심사하는 항목이다. 예를 들어, "나이" 컬럼의 값이 0에서 120 사이인지 확인한다.

- ▶ **적용 대상:** 유효한 범위가 정의된 컬럼으로 숫자, 날짜, 시간의 경우에만 적용
(예: 최댓값, 최솟값이 적용 가능한 수치)
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 허용 범위를 벗어난 데이터 값
 - 진단 데이터: 범위가 정의된 컬럼의 데이터 값



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 시험 성적 컬럼의 값이 0에서 100 사이로 정의된 경우
오류 데이터) [105, -10, 110, 200, 101]
정상 데이터) [95, 85, 72, 100, 60]

예시 2: 직원 연령 컬럼의 값이 18세 이상으로 정의된 경우
오류 데이터) [16, 17, 15, 14, 13]
정상 데이터) [25, 32, 40, 28, 35]

예시 3: 급여 컬럼의 값이 0 이상으로 정의된 경우
오류 데이터) [-100, -500, -200, -50, -300]
정상 데이터) [3000, 5000, 4500, 3800, 3200]

예시 4: 제품 가격 컬럼의 값이 0 이상으로 정의된 경우
오류 데이터) [-5, -10, -3, -1, -20]
정상 데이터) [15.99, 20.00, 12.49, 25.00, 9.99]

예시 5: 재고 수량 컬럼의 값이 0 이상으로 정의된 경우
오류 데이터) [-10, -5, -20, -15, -30]
정상 데이터) [50, 100, 20, 80, 40]

예시 1

연도별 해양 쓰레기 데이터

● 범위가 정의된 컬럼

컬럼명	최솟값	최댓값
연도	2008	2023

● 데이터 내용

연도	수거량(ton)
2007	25239.5
2009	59437.5
2015	69128.9
2016	70840.6
2018	95632
2019	108644.1
2022	126035.4
2024	131930.7

● 진단 총 데이터 수: 8

● 오류 데이터 수: 2

$$\begin{aligned}
 \text{범위 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 2 / 8 \\
 &= 0.75
 \end{aligned}$$

● (필수) 관계 유효성

데이터 값이 컬럼 간 또는 테이블 간의 관계 규칙을 준수하는지를 심사하는 항목이다. 예를 들어, 입학일은 졸업일보다 빠른지 확인한다.

▶ **적용 대상:** 다른 컬럼 또는 다른 테이블과 관계 규칙이 정의된 컬럼

▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 정의된 관계 규칙에 맞지 않는 데이터 값
- 진단 데이터: 다른 컬럼과의 관계 규칙이 정의된 컬럼의 데이터 값

※ 관계 규칙은 데이터 간의 연관성과 제약 조건을 정의하여, 데이터베이스에서 규칙을 구현하고 비즈니스 요구사항이 데이터 수준에서 충족되도록 보장하는 기준



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 수강생 데이터에서 규칙이 "졸업 연도는 입학 연도보다 늦어야 한다"로 정의된 경우
오류 데이터) {"졸업 연도": 2018, "입학 연도": 2020}
정상 데이터) {"졸업 연도": 2023, "입학 연도": 2019}

예시 2: 결제 테이블에서 규칙이 "결제 완료일은 결제 요청일보다 늦어야 한다"로 정의된 경우
오류 데이터) {"결제 완료일": "2024-12-05", "결제 요청일": "2024-12-10"}
정상 데이터) {"결제 완료일": "2024-12-15", "결제 요청일": "2024-12-10"}

예시 3: 배송 테이블에서 규칙이 "배송 시작일은 배송 완료일보다 빨라야 한다"로 정의된 경우
오류 데이터) {"배송 시작일": "2024-12-24", "배송 완료일": "2024-12-18"}
정상 데이터) {"배송 시작일": "2024-12-15", "배송 완료일": "2024-12-20"}

예시 4: 주문 테이블에서 규칙이 "배송 완료일은 주문 일자보다 늦어야 한다"로 정의된 경우
오류 데이터) {"배송 완료일": "2024-09-28", "주문 일자": "2024-09-29"}
정상 데이터) {"배송 완료일": "2024-10-01", "주문 일자": "2024-09-29"}

예시 5: 학생 테이블에서 규칙이 "입학일은 졸업일보다 빨라야 한다"로 정의된 경우
오류 데이터) {"입학일": "2020-09-01", "졸업일": "2019-05-10"}
정상 데이터) {"입학일": "2019-09-01", "졸업일": "2023-05-10"}

예시 1

공동체 미디어 교육 데이터

- 정의된 컬럼 간의 관계 규칙 (업무규칙)

컬럼명	컬럼 간의 관계 규칙(업무규칙)
교육종료일자	교육종료일자는 교육시작일자보다 늦어야 한다.

- 데이터 내용

센터명	강좌명	교육시작일자	교육종료일자	교육대상 구분
부산시청자미디어센터	라디오체험(웰컴투라디오)	2024-10-02	2023-10-31	일반시민
부산시청자미디어센터	스마트체험(꿈지락애니)	2024-10-02	2024-10-31	일반시민
부산시청자미디어센터	TV체험(행복뉴스)	2024-10-02	2024-09-31	일반시민
부산시청자미디어센터	크로마키체험(파랑TV)	2024-10-02	2024-10-31	유아
광주시청자미디어센터	미디어체험	2024-10-02	2024.10.02	장애인
광주시청자미디어센터	미디어체험	2024-10-04		유아

- 진단 총 데이터 수: 5
- 오류 데이터 수: 2
- 관계 유효성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 2 / 5$
 $= 0.60$

(선택) 데이터 값 정밀성

데이터 값이 명세서에 정의된 정밀도(소수점 자릿수 등)를 충족하는지를 심사하는 항목이다. 예를 들어, 금액 컬럼의 값이 소수점 두 자리까지 정확히 표시되었는지 확인한다.

- ▶ **적용 대상:** 정밀도가 요구되는 숫자 컬럼
- ▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수
 - 오류 데이터: 정의된 정밀도 기준을 충족하지 않는 데이터 값
 - 진단 데이터: 명세서에 정밀도 기준이 정의된 컬럼의 데이터 값



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 평가액(억 원) 컬럼의 정밀도가 정수로 요구된 경우

오류 데이터) [123.45, 456.78, 789.56, 12.33, 320.22]

정상 데이터) [123, 456, 789, 1, 320]

예시 2: 자산군 내 비중(퍼센트) 컬럼의 정밀도가 소수점 둘째 자리로 요구된 경우

오류 데이터) [45.678, 12.345, 99.999, 56.789, 83.421]

정상 데이터) [45.67, 12.34, 99.99, 56.78, 83.42]

예시 3: 지분율(퍼센트) 컬럼의 정밀도가 소수점 둘째 자리로 요구된 경우

오류 데이터) [20.2, 75.4, 50.5, 30.3, 67.8]

정상 데이터) [20.25, 75.40, 50.00, 30.50, 67.85]

※ 위의 예시 중 실제 데이터가 20.20이나 시스템의 특성상 자동으로 20.0으로 저장되는 경우는 오류 추정 후 정상데이터로 처리할 수 있음

예시 4: 평가액(억 원) 컬럼의 정밀도가 소수점 첫째 자리로 요구된 경우

오류 데이터) [100.56, 200.89, 45.23, 123.75, 78.95]

정상 데이터) [100.5, 200.3, 45.0, 123.7, 78.9]

예시 5: 자산군 내 비중(퍼센트) 컬럼의 정밀도가 소수점 셋째 자리로 요구된 경우

오류 데이터) [1350.1, 1125.5, 900.3, 1234.7, 1500.2]

정상 데이터) [1350.125, 1125.500, 900.354, 1234.768, 1500.211]

예시 1

국내 주식 투자 데이터

● 정밀도가 요구된 컬럼

컬럼명	정밀도
평가액(억 원)	정수
자산군 내 비중(퍼센트)	소수점 둘째 자리
지분율(퍼센트)	소수점 둘째 자리

● 데이터 내용

번호	종목명	평가액(억 원)	자산군 내 비중(퍼센트)	지분율(퍼센트)
1	삼성전자	341048	23.29	7.28
2	SK하이닉스	82235	5.62	7.9
3	LG에너지솔루션	55196	3.77	5.52
4	삼성바이오로직스	36167	2.47	6.69
5	NAVER	33861	2.31	9.31
6	현대차	30759	2.1	7.1
7	기아	28576	1.95	7.11
8	POSCO홀딩스	26894	1.84	6.37
9	삼성SDI	24678	1.69	7.6

● 진단 총 데이터 수: 27

● 오류 데이터 수: 4

$$\begin{aligned}
 \text{데이터 값 정밀성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 4 / 27 \\
 &= 0.85
 \end{aligned}$$

3.3 일관성

일관성은 데이터가 정해진 규칙과 속성을 유지하며, 데이터 간 불일치 없이 일관되게 정의되고 사용되는지를 평가하는 기준이다. 데이터 간 참조 무결성, 동일 속성의 포맷 일관성, 공통 어휘 사용 여부 등을 검토하여 데이터의 신뢰성과 정합성을 보장한다. 이를 통해 데이터 활용 과정에서의 혼란과 오류를 예방할 수 있다. 정형 데이터의 심사 항목은 다음과 같다.

■ (필수) 참조 무결 일관성

데이터 값이 테이블 간의 참조 무결성 규칙을 지키는지를 심사하는 항목이다. 예를 들어, 주문 테이블의 "고객 ID"가 고객 테이블에 실제로 존재하는 ID인지 확인한다.

- ▶ **적용 대상:** 다른 테이블의 컬럼을 참조하는 컬럼
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 참조 대상 테이블의 대상 컬럼에 존재하지 않는 데이터 값
 - 진단 데이터: 데이터 명세서에 참조 관계가 정의된 컬럼의 데이터 값



심사기준을 영상으로
확인하세요!


데이터 예시

- 예시 1: 고객 테이블의 "고객 ID"가 주문 테이블의 "고객 ID"를 참조하는 경우
 오류 데이터) 주문 테이블의 "고객 ID"가 고객 테이블의 "고객 ID" 컬럼에 존재하지
 않음
 정상 데이터) 주문 테이블 "고객 ID"가 고객 테이블의 "고객 ID" 컬럼에 존재함
- 예시 2: 수업 테이블의 "수업 ID"가 학생 테이블의 "수업 ID"를 참조하는 경우
 오류 데이터) 학생 테이블의 "수업 ID"가 수업 테이블의 "수업 ID" 컬럼에 존재하지
 않음
 정상 데이터) 학생 테이블의 "수업 ID"가 수업 테이블의 "수업 ID" 컬럼에 존재함
- 예시 3: 직원 테이블의 "직원 ID"가 회사 조직 테이블의 "직원 ID"를 참조하는 경우
 오류 데이터) 회사 조직 테이블의 "직원 ID"가 직원 테이블의 "직원 ID" 컬럼에
 존재하지 않음
 정상 데이터) 회사 조직 테이블의 "직원 ID"가 직원 테이블의 "직원 ID" 컬럼에 존재함
- 예시 4: 상품 테이블의 상품 ID가 재고 테이블의 상품 ID를 참조하는 경우
 오류 데이터) 재고 테이블의 상품 ID가 상품 테이블의 상품 ID 컬럼에 존재하지 않음
 정상 데이터) 재고 테이블의 상품 ID가 상품 테이블의 상품 ID 컬럼에 존재함

예시 1

행안부 지역별 성별 현황 데이터

● ERD



● 지역 테이블 데이터 내용

법정동코드	시도명	시군구명	읍면동명	리명
1111010100	서울특별시	종로구	청운동	청운동
1111010200	서울특별시	종로구	신교동	신교동
1111010300	서울특별시	종로구	궁정동	궁정동

● 지역별 성별 현황

법정동코드	기준연월	남자	여자	계
1111010100	2024-09-30	561	274	835
1111010200	2024-09-30	310	272	582
1111010300	2024-09-30	49	57	106
1111010100	2023-09-30	-	-	-
1111010500	2023-09-30	-	-	-
1111010300	2023-09-30	-	-	-

● 진단 총 데이터 수: 6

● 오류 데이터 수: 1

$$\begin{aligned}
 \text{참조 무결 일관성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 1 / 6 \\
 &= 0.83
 \end{aligned}$$

● (선택) 데이터 포맷 일관성

데이터 파일 내에서 여러 컬럼이 동일한 데이터 유형(날짜/전화번호/우편번호 등)을 가질 경우, 해당 컬럼들이 모두 동일한 데이터 형식(포맷)으로 표현되고 있는지를 심사하는 항목이다. 예를 들어, 여러 날짜 컬럼이 모두 'YYYY-MM-DD' 형식을 사용하는지 확인한다.

- ▶ **적용 대상:** 서로 다른 컬럼이지만 동일한 데이터 유형에 속하는 컬럼들
- ▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수
 - 오류 데이터: 같은 유형에 속한 여러 컬럼 중 형식(포맷)이 다른 데이터 값
 - 진단 데이터: 같은 유형으로 분류된 전체 컬럼들의 데이터 값



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: date_created, date_updated, event_date 컬럼 간 날짜 형식이 "YYYY-MM-DD" 으로 설정된 경우

date_created : 2024-11-01, date_updated : 2024/11/02, event_date : 2024-11-03
오류 데이터) [2024/11/02]

정상 데이터) [2024-11-01, 2024-11-03]

예시 2: user_phone, emergency_phone 컬럼 간 전화번호 형식이 "XXX-XXXX-XXXX" 으로 설정된 경우

user_phone : 010-1234-5678, emergency_phone : 01023456789
오류 데이터) [01023456789]

정상 데이터) [010-1234-5678]

예시 3: billing_zip, shipping_zip, office_zip 컬럼 간 우편번호 형식이 "XXXXX" 으로 설정된 경우

billing_zip : 12345, shipping_zip: 456-78, office_zip: 56789
오류 데이터) [456-78]

정상 데이터) [12345, 56789]

예시 4: user_email, manager_email 컬럼 간 이메일 형식이 "example@example.com" 으로 설정된 경우

user_email : user1@example.com, manager_email : manager1@com
오류 데이터) [manager1@com]

정상 데이터) [user1@example.com]

예시 1

공동체 미디어 교육 데이터

● 포맷 일관성이 정의된 컬럼

컬럼명	데이터 포맷(구문)
교육시작일자	YYYY-MM-DD
교육종료일자	
데이터기준일자	

● 데이터 내용

번호	강좌명	교육시작일자	교육종료일자	교육대상 구분	데이터 기준일자
1	라디오체험(웰컴투라디오)	2024-10-02	2024-10-31	일반시민	2024.10.01
2	더빙체험(나도 애니 주인공)	2024-10-02	2024-10-31	일반시민	2024.10.01
3	스마트체험(꿈지락애니)	2024-10-02	2024-10-31	일반시민	2024.10.01
4	TV체험(행복뉴스)	2024-10-02	2024-10-31	일반시민	2024.10.01
5	크로마키체험(파랑TV)	2024-10-02	2024-10-31	유아	2024.10.01
6	문화다양성 미디어체험	2024-10-10	2024-10-31	일반시민	2024.10.01
7	위장환경주의 수사대! (팩트체크 체험)	2024-10-05	2024-10-26	초등학생 고학년	2024.10.01
8	미디어체험	2024-10-02	2024-10-02	장애인	2024.10.02
9	미디어체험	2024-10-04	2024-10-04	유아	2024.10.02
10	미디어체험	2024-10-11	2024-10-11	유아	2024.10.02

● 진단 총 데이터 수: 30

● 오류 데이터 수: 10

$$\begin{aligned}
 \text{데이터 포맷 일관성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 10 / 30 \\
 &= 0.67
 \end{aligned}$$

■ (선택) 공통 어휘 일관성

데이터 사전에 정의된 공통 용어가 정확히 사용되고 있는지를 심사하는 항목이다. 예를 들어, "직급" 컬럼에서 "과장", "차장" 등 데이터 사전에 정의된 용어만 사용되었는지 확인한다.

- ▶ **적용 대상:** 공통 용어로 유효한 값 정의된 컬럼
- ▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수
 - 오류 데이터: 공통 용어를 사용하지 않은 데이터 값
 - 진단 데이터: 데이터 사전에 공통 용어가 정의된 컬럼의 데이터 값



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 데이터 사전에 "성별" 컬럼의 공통 어휘가 "남"과 "여"로 정의 된 경우

오류 데이터) [M, F, M, F, M]

정상 데이터) [남, 여, 남, 여, 남]

예시 2: 데이터 사전에 "제품 상태" 컬럼의 공통 어휘가 "사용 중"과 "미사용"으로 정의 된 경우

오류 데이터) [Active, Inactive, Active, Active, Inactive]

정상 데이터) [사용 중, 미사용, 사용 중, 사용 중, 미사용]

예시 3: 데이터 사전에 "지역명" 컬럼의 공통 어휘가 "서울"과 "부산"으로 정의 된 경우

오류 데이터) [SEOUL, BUSAN, SEOUL, BUSAN, SEOUL]

정상 데이터) [서울, 부산, 서울, 부산, 서울]

예시 4: 데이터 사전에 "상태" 컬럼의 공통 어휘가 "진행 중"과 "완료"로 정의 된 경우

오류 데이터) [In Progress, Completed, In Progress, In Progress, Completed]

정상 데이터) [진행 중, 완료, 진행 중, 진행 중, 완료]

예시 5: 데이터 사전에 "고객 등급" 컬럼의 공통 어휘가 "VIP"와 "일반"으로 정의 된 경우

오류 데이터) [High, Regular, High, High, Regular]

정상 데이터) [VIP, 일반, VIP, VIP, 일반]

예시 1

미술관 운영 데이터

● 공통 어휘 사전

공통 어휘	설명
공립	공공기관에서 운영하는 미술관
사립	개인, 법인, 재단에서 운영하는 미술관

● 데이터 내용

번호	구분	미술관명	연락처	등록일
1	공립	전남도립미술관	061-760-3200	2020-12-11
2	공립	함평군립미술관	061-320-2276	2011-06-17
3	공공	남도전통미술관	061-540-6293	2012-03-07
4	공립	저녁노을미술관	061-240-8067	2020-05-11
5	사립	신선미술관	061-284-7887	2014-07-22
6	개인	갯바위미술관	061-279-5763	2015-10-27
7	재단	경훈미술관	061-277-6900	2016-06-24
8	법인	유달미술관	061-279-7777	2010-09-30

● 진단 총 데이터 수: 8

● 오류 데이터 수: 4

$$\begin{aligned}
 \text{공통 어휘 일관성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 4 / 8 \\
 &= 0.50
 \end{aligned}$$

3.4 정확성

정확성은 데이터 값이 규칙, 파생 규칙, 어노테이션 규칙 등 정의된 기준에 따라 정확한지를 평가하는 기준이다. 메타데이터와 데이터 값의 정확성을 검토하여 데이터가 기대치에 부합하는지를 확인하며, 이를 통해 데이터의 오류를 조기에 식별하고 신뢰성을 유지한다. 정확성 평가는 비즈니스 의사결정의 정확성을 높이는 핵심 요소이다. 정형 데이터의 심사 항목은 다음과 같다.

■ (선택) 메타데이터 정확성

메타데이터의 값과 실제 데이터 값이 일치하며 요구사항에 부합하는지를 심사하는 항목이다. 예를 들어, 명세서에 정의된 "상품 ID"의 형식과 실제 데이터 값의 형식이 일치하는지 확인한다.

▶ **적용 대상:** 명세서에 요구사항이 정의된 메타데이터

▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 데이터 값과 일치하지 않거나 명세서에 정의된 기준에 부합하지 않는 메타데이터
- 진단 데이터: 명세서에 요구사항이 정의된 메타데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 레코드 수가 메타데이터에 "10"으로 정의되어 있는 경우
오류 데이터) 레코드 수가 100임
정상 데이터) 레코드 수가 10임

예시 2: 컬럼 종류 메타데이터에 "기준년, 기준월, 연령대"로 정의되어 있는 경우
오류 데이터) 컬럼 종류가 "기준년, 기준월, 연령대, 성별"임
정상 데이터) 컬럼 종류가 "기준년, 기준월, 연령대"임

예시 3: 데이터 설명이 "출국심사 완료된 국민(승객)을 연령대별로 분류하여 제공"으로 정의되어 있는 경우
오류 데이터) 데이터가 출국심사 완료된 국민(승객)을 직종별로 분류함
정상 데이터) 데이터가 출국심사 완료된 국민(승객)을 연령대별로 분류하여 제공함

예시 4: 메타데이터에 "연령대" 컬럼의 값이 "0세_4세, 5세_9세, 10세_14세, 15세_19세"로 정의되어 있는 경우
오류 데이터) "연령대" 컬럼의 값이 "10세_14세, 15세_19세, 30세_34세"임
정상 데이터) "연령대" 컬럼의 값이 "0세_4세, 5세_9세, 10세_14세, 15세_19세"임

예시 1 법무부 연령별 국민 출국자 데이터

● 메타데이터

데이터 설명	2022년 7월부터 전국 공항·만을 통해 출국심사 완료된 국민(승객)을 월별, 연령별로 0세부터 29세까지 분류하여 제공
레코드 수	10
컬럼 종류	기준년, 기준월, 0세_4세, 5세_9세, 10세_14세, 15세_19세, 20세_24세, 25세_29세

● 데이터 내용

기준년	기준월	0세_4세	5세_9세	10세_14세	15세_19세	20세_24세	25세_30세
2022	7	13218	28462	31942	22455	45182	57709
2022	8	12107	26530	27600	27473	58815	73406
2022	9	10894	13573	10969	9453	33007	68003
2022	10	12282	16279	13559	8241	28046	86055
2022	11	14765	21129	19875	16592	51634	121547
2022	12	26244	44190	42795	44835	107147	163479
2023	1	19974	56562	79671	88010	190029	164167
2023	2	16669	49299	69087	77124	196519	144025
2023	3	16801	25491	20884	12746	68257	152908
2023	4	20163	39925	31044	11469	57107	150948

● 진단 총 데이터 수: 3

● 오류 데이터 수: 2

※ 메타데이터 3개(데이터 설명, 레코드 수, 컬럼 종류) 중 컬럼 종류와 데이터 설명에 오류

● 메타데이터 정확성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 2 / 3
 = 0.33

■ (선택) 데이터 값 정확성

컬럼 간의 규칙에 따라 데이터 값이 정확한지를 심사하는 항목이다. 예를 들어, "수량" 컬럼과 "단가" 컬럼의 값을 곱한 결과가 "총액" 컬럼의 값과 일치하는지 확인한다.

- ▶ **적용 대상:** 데이터 값이 다른 컬럼과 산술적 관계를 갖는 컬럼
- ▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수
 - 오류 데이터: 다른 컬럼과 산술적 관계를 충족하지 못하는 데이터 값
 - 진단 데이터: 다른 컬럼과 산술적 관계가 정의된 컬럼의 데이터 값



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: '근속연수' 컬럼은 '올해년도' - '입사년도'로 정의된 경우

오류 데이터) {올해년도: 2024, 입사년도: 2020, 근속연수: 3}

정상 데이터) {올해년도: 2024, 입사년도: 2020, 근속연수: 4}

예시 2: '잔액' 컬럼은 '수입'컬럼 - '지출'로 정의된 경우

오류 데이터) {수입: 200, 지출: 150, 잔액: 300}

정상 데이터) {수입: 200, 지출: 150, 잔액: 50}

예시 3: '총 관객수' 컬럼은 '서울 관객수' 컬럼 + '부산 관객수'로 정의된 경우

오류 데이터) {서울 관객수: 5000명, 부산 관객수: 5500명, 총 관객수: 10000명}

정상 데이터) {서울 관객수: 5000명, 부산 관객수: 5500명, 총 관객수: 10500명}

예시 4: '평균 연봉' 컬럼은 '총 연봉' / '근속연수'로 정의된 경우

오류 데이터) {총 연봉: 6000만원, 근속연수: 5년, 평균 연봉: 1300만원}

정상 데이터) {총 연봉: 6000만원, 근속연수: 5년, 평균 연봉: 1200만원}

예시 5: '총 매출' 컬럼은 '온라인 매출' + '오프라인 매출'로 정의된 경우

오류 데이터) {온라인 매출: 300만원, 오프라인 매출: 500만원, 총 매출: 900만원}

정상 데이터) {온라인 매출: 300만원, 오프라인 매출: 500만원, 총 매출: 800만원}

예시 1

시립박물관 관람객 현황 데이터

- 컬럼과 컬럼 간의 정확한 값이 요구되는 업무 규칙

컬럼명	컬럼 간의 관계 규칙(업무규칙)
계	계 = 어른 + 청소년 + 어린이 + 외국인 + 단체

- 데이터 내용

월별	어른	청소년	어린이	외국인	단체	계	개관일수
1	990	173	401	0	99	1663	24
2	1054	83	538	5	288	0	24
3	1511	306	472	0	107	2396	27
4	1888	531	753	0	185	3357	26
5	2385	704	951	8	275	4323	26
6	1965	523	1076	3	440		26
7	1901	675	901	4	66	3547	26
8	2099	543	1015	0	197	0	27
9	1980	556	966	0	310	3812	25
10	2417	463	881	10	1012	4783	26
11	2219	378	767	4	1267	0	26
12	2126	422	675	0	141	3364	27

- 진단 총 데이터 수: 12
- 오류 데이터 수: 4
- 데이터 값 정확성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 4 / 12$
 $= 0.67$

3.5 접근성

접근성은 데이터가 요구되는 표준과 협약을 준수하여 사용자가 데이터를 쉽게 접근하고 활용할 수 있는지를 평가하는 기준이다. 표준화된 형식으로 저장된 데이터를 통해 데이터의 활용 가능성과 호환성을 보장하며, 데이터 교환 및 분석의 효율성을 향상시킨다. 접근성 평가는 데이터 사용자의 이해와 활용도를 높이는 데 기여한다. 정형 데이터의 심사 항목은 다음과 같다.

■ (선택) 표준기반 데이터 접근성

데이터가 요구되는 표준이나 협약을 준수하여 접근할 수 있도록 존재하는지를 심사하는 항목이다. 예를 들어, 날짜를 저장할 때, 날짜 표기 국제 표준을 준수하는지 확인한다.

- ▶ **적용 대상:** 요구되는 표준이나 협약이 정의된 컬럼
- ▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수
 - 오류 데이터: 요구되는 표준이나 협약을 준수하지 않는 데이터 값
 - 진단 데이터: 요구되는 표준이나 협약이 정의된 컬럼의 데이터 값



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 날짜가 국제 표준 ISO 8601 형식(YYYY-MM-DD)으로 정의된 경우
오류 데이터) "12/31/2024", "20241231"
정상 데이터) "2024-12-31"

예시 2: 전화번호가 국가별 국제 표준(예: +82-10-1234-5678)으로 정의된 경우
오류 데이터) "010-1234-5678", "12345678"
정상 데이터) "+82-10-1234-5678"

예시 3: 언어가 국제 표준 ISO 639-1 언어 코드(en, ko)로 정의된 경우
오류 데이터) "English", "Korean"
정상 데이터) "en", "ko"

예시 4: 국가명이 ISO 3166-1 표준 국가 코드(Alpha-2 코드)로 정의된 경우
오류 데이터) "USA", "United States"
정상 데이터) "US", "KR"

예시 5: 화폐가 ISO 4217 화폐 코드(KRW, USD, EUR)로 정의된 경우
오류 데이터) "\$", "US Dollars", "₩", "Korean Won"
정상 데이터) "USD", "KRW"

예시 1

국제선 항공기 스케줄 데이터

- 표준, 협약 또는 규정이 정의된 컬럼

컬럼명	컬럼 간의 관계 규칙(업무규칙)
출발공항	IATA의 공항 코드(국토교통부_세계공항코드) 사용 - NRT(나리타 국제공항), NAA(나라브리 공항), ICN(인천국제공항), NAY(베이징 난위안 공항), DFW(델러스/포트워스 국제공항) 등
도착공항	

- 데이터 내용

항공사	운항편명	출발공항	도착공항	출발시간	도착시간	운항요일	국내_국제
AAL	AA9604	ICN	DFW	16:30	15:30	토	국제
AAR	OZ101	NRT	ICN	13:20	15:50	금	국제
AAR	OZ101	NRT	ICN	13:20	15:50	월수금	국제
AAR	OZ101	BBB	AAA	13:20	15:50	월	국제
AAR	OZ101	NRT	ICN	13:20	15:50	월	국제
AAR	OZ101	NRT	ICN	13:20	15:50	월	국제
AAR	OZ101	NRT	ICN	13:20	15:50	화	국제
AAR	OZ1013	NRT	ICN	20:10	22:50	월	국제
AAR	OZ1013	NRT	ICN	20:10	22:50	화	국제

- 진단 총 데이터 수: 18
- 오류 데이터 수: 2
- 표준기반 데이터 접근성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 2 / 18$
 $= 0.89$

3.6 유일성

유일성은 특정 데이터 값이 중복 없이 고유하게 존재하는지를 평가하는 기준이다. 중복이 허용되지 않는 컬럼에서 데이터 값이 정확히 한 번만 나타나는지를 검토하여 데이터베이스의 무결성과 정확성을 유지한다. 유일성 평가는 데이터 중복으로 인한 문제를 방지하고, 데이터 품질과 신뢰성을 확보한다. 정형 데이터의 심사 항목은 다음과 같다.

■ (선택) 데이터 값 유일성

특정 컬럼의 데이터 값이 중복되지 않고, 고유한지를 심사하는 항목이다. 예를 들어, 고객 테이블의 "회원 ID"가 중복 없이 고유한지 확인한다.

- ▶ **적용 대상:** 중복이 허용되지 않는 컬럼
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 중복 값이 존재하는 데이터 값
 - 진단 데이터: 중복이 허용되지 않는 컬럼의 데이터 값



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 고객 테이블의 고유 컬럼 "고객 ID"의 경우

오류 데이터) ["C12345", "C12345", "C67890", "C67890"]

정상 데이터) ["C12345", "C67890", "C11223", "C44556"]

예시 2: 주문 테이블의 고유 컬럼 "주문 번호"의 경우

오류 데이터) ["ORD123", "ORD123", "ORD456", "ORD456"]

정상 데이터) ["ORD123", "ORD456", "ORD789", "ORD1011"]

예시 3: 사용자 테이블의 고유 컬럼 "주민등록번호"의 경우

오류 데이터) ["990101-1234567", "990101-1234567", "880505-7654321", "880505-7654321"]

정상 데이터) ["990101-1234567", "880505-7654321", "900909-2345678", "950505-8765432"]

예시 4: 고유 컬럼 "상품 코드"의 경우

오류 데이터) ["P1001", "P1001", "P1002", "P1002"]

정상 데이터) ["P1001", "P1002", "P1003", "P1004"]

예시 5: 고유 컬럼 "회원 번호"의 경우

오류 데이터) ["M0001", "M0001", "M0002", "M0002"]

정상 데이터) ["M0001", "M0002", "M0003", "M0004"]

예시 1

산업직업분류 연계 데이터

- 중복이 허용되지 않는 컬럼: 신분류코드, 신분류항목명
- 데이터 내용

분류차수	분류종류	신분류코드	신분류항목명
7	JOB	11104	지방정부 고위 공무원
7	JOB	11105	공공 기관 임원
7	JOB	11106	정당 및 특수 단체 임원
7	JOB	11201	기업 대표이사
7	JOB	11104	기업 고위 임원
7	JOB	12110	정부행정 관리자
7	JOB	11104	총무 및 인사 관리자
7	JOB	6139	기타 사육 관련 종사원
7	JOB	6201	조림·산림경영인 및 벌목원

- 진단 총 데이터 수: 18
- 오류 데이터 수: 2
- 데이터 값 유일성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 2 / 18$
 $= 0.89$

4

비정형 데이터 심사

비정형 데이터 심사는 DQ인증의 품질기준에 따라 ISO/IEC 5259-2, TTAK.KO-10.1344-Part2, NIA 학습용 데이터 품질 관리 가이드의 데이터 품질 측정 지표를 준용하여 아래의 24개 심사 항목으로 구성한다.

■ 비정형 데이터 심사 항목

번호	데이터 품질기준	심사 항목명	설명
1	완전성	데이터 파일 완전성	데이터 명세서에 기술된 파일 수와 실제 제공된 파일 수가 일치하는지 심사하는 항목
2		레코드 완전성	전체 데이터 레코드(논리적으로 연결된 하나의 단위로, 객체, 메타데이터, 어노테이션 등이 통합된 최소 단위) 중 필수 항목 데이터가 누락되지 않았는지 심사하는 항목
3		메타데이터 값 완전성	메타데이터 내 필수 항목의 값이 누락되지 않았는지를 심사하는 항목
4		어노테이션 완전성	학습용 데이터의 객체 데이터마다 대응되는 어노테이션(라벨 또는 참조 데이터)이 존재하는지를 심사하는 항목
5		특징 완전성	학습용 데이터에서 모델 학습에 필요한 주요 특징(feature) 데이터가 누락되지 않았는지를 심사하는 항목
6	유효성	데이터 구조 구문 유효성	메타데이터와 어노테이션의 구조가 사전에 정의된 스키마 규칙에 부합하는지를 심사하는 항목
7		데이터 포맷 유효성	데이터 파일이 명세서에 정의된 파일 포맷 및 코덱 형식을 충족하는지를 심사하는 항목
8		객체 유효성	비정형 객체 파일(텍스트, 이미지, 동영상, 오디오 등)이 손상이 없고, 활용 가능한 상태인지를 심사하는 항목
9		관계 유효성	레코드를 구성하는 객체 데이터, 메타데이터, 어노테이션 간의 데이터 값이 정의된 관계 규칙(ID, 경로, 시간 정렬, 논리적 관계 등)에 부합하는지를 심사하는 항목
10		데이터 값 정밀성	데이터 값이 명세서에 정의된 정밀도 기준(단위, 자릿수)을 충족하는지 심사하는 항목
11		데이터 속성 유효성	객체 데이터의 내부 속성(해상도, 채널수, 프레임률, 인코딩, 텍스트 길이, 오디오·영상 길이 등)이 명세서 기준에 적합한지를 심사하는 항목
12		범위 유효성	메타데이터 및 어노테이션 데이터 내의 속성 값이 명세서에서 정의한 허용 범위(값, 길이, 시간, 좌표 등)에 포함되는지를 심사하는 항목
13		시간 유효성	데이터 생성 또는 수집 시간이 명세서에 정의된 기준 시간을 만족하는지를 심사하는 항목
14		어노테이션 유효성	어노테이션이 명세서에 정의된 기준(형식, 구조, 인코딩, 시간 정렬, 내용 건전성 등)을 만족하는지를 심사하는 항목

번호	데이터 품질기준	심사 항목명	설명
15	일관성	공동 어휘 일관성	객체 데이터 파일명, 메타데이터, 어노테이션이 공통 어휘 사전에 정의된 용어를 사용하는지를 심사하는 항목
16		데이터 포맷 일관성	비정형 객체와 메타데이터, 어노테이션 데이터가 동일한 도메인의 데이터 포맷을 유지하는지를 심사하는 항목
17	정확성	구문 정확성	비정형 객체에 대한 메타데이터와 어노테이션 내 데이터의 구문이 명세서에 정의된 구문에 적합한지를 심사하는 항목
18		메타데이터 정확성	메타데이터 값이 실제 객체의 속성과 정확히 일치하는지를 심사하는 항목
19		어노테이션 정확성	객체데이터의 어노테이션이 의미적·사실적으로 정확한지를 심사하는 항목
20		주제 정확성	비정형 객체가 정의된 주제·도메인과 일치하는지를 심사하는 항목
21	접근성	데이터 포맷 접근성	비정형 객체 데이터가 일반적인 데이터 포맷(예: jpg, png, bmp 등)으로 제공되는지를 심사하는 항목
22		표준기반 데이터 접근성	데이터가 요구되는 표준이나 협약을 준수하여, 사용자가 용이하게 접근하고 활용할 수 있도록 제공되어 있는지를 심사하는 항목
23	유일성	객체 유일성	객체 데이터가 중복 없이 유일한지를 심사하는 항목
24		레코드 유일성	데이터 레코드가 중복 없이 유일한지 심사하는 항목

필수 심사 항목과 선택 심사 항목 선정

비정형 데이터 심사의 항목은 필수 항목과 선택 항목으로 구분한다.

필수 심사 항목	비정형 데이터의 기본적인 품질을 평가하는 항목
선택 심사 항목	비정형 데이터의 특수한 요구사항이나 활용 목적에 따라 추가적인 품질을 평가하는 항목

심사 대상 데이터에 대해 데이터 명세서와 프로파일링 결과를 바탕으로 적용할 심사 항목을 선정하고, 선정된 항목 수에 따라 구조 유형(Simple-Type, Normal-Type, Complex-Type)을 분류한다.

구분	데이터 품질기준	심사 항목
필수 심사 항목 (9개)	완전성(3개)	데이터 파일 완전성, 레코드 완전성, 메타데이터 값 완전성
	유효성(3개)	데이터 구조 구문 유효성, 데이터 포맷 유효성, 객체 유효성
	정확성(2개)	구문 정확성, 메타데이터 정확성
	유일성(1개)	객체 유일성
선택 심사 항목 (15개)	완전성(2개)	어노테이션 완전성, 특징 완전성
	유효성(6개)	관계 유효성, 데이터 값 정밀성, 데이터 속성 유효성, 범위 유효성, 시간 유효성, 어노테이션 유효성
	일관성(2개)	공동 어휘 일관성, 데이터 포맷 일관성
	정확성(2개)	어노테이션 정확성, 주제 정확성
	접근성(2개)	데이터 포맷 접근성, 표준기반 데이터 접근성
	유일성(1개)	레코드 유일성

4.1 완전성

완전성은 명세서에서 정의된 필수항목이나 레코드의 데이터가 누락되지 않았는지 진단하는 기준으로 비정형 데이터에 대해 다음과 같은 심사 항목으로 평가한다.

■ (필수) 데이터 파일 완전성

데이터 명세서에 기술된 파일 수와 실제 제공된 파일 수가 일치하는지 심사하는 항목이다. 예를 들어, 명세서에 메타데이터 파일 수와 어노테이션 파일 수, 객체 데이터 파일 수가 실제 파일 수와 동일한지 확인한다.

- ▶ **적용 대상:** 비정형 객체 데이터 레코드
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 명시된 데이터에서 부족한 데이터 수
 - 진단 데이터: 데이터 명세서에 정의된 데이터



심사기준을 영상으로
확인하세요

데이터 예시

- 예시 1: 이미지 데이터 셋의 명세서에 정의된 이미지 파일 수가 100개인 경우
 오류 데이터) 실제 이미지 파일 수: 90개, 누락된 파일 수 : 10개
 정상 데이터) 실제 이미지 파일 수: 100개
- 예시 2: 텍스트 데이터 셋의 명세서에 정의된 데이터 레코드 수가 200개인 경우
 오류 데이터) 실제 데이터 레코드 수: 195개, 누락된 파일 수 : 5개
 정상 데이터) 실제 데이터 레코드 수: 200개
- 예시 3: 센서 로그 데이터의 명세서에 정의된 레코드 수가 1,000개인 경우
 오류 데이터) 실제 레코드 수: 950개, 누락된 파일 수 : 50개
 정상 데이터) 실제 레코드 수: 1,000개
- 예시 4: 동영상 데이터셋의 명세서에 정의된 파일 수가 80개인 경우
 오류 데이터) 실제 파일 수: 70개, 누락된 파일 수 : 10개
 정상 데이터) 실제 파일 수: 80개
- 예시 5: PDF 문서 데이터셋의 명세서에 정의된 문서 수가 300개인 경우
 오류 데이터) 실제 문서 수: 290개, 누락된 파일 수 : 10개
 정상 데이터) 실제 문서 수: 300개

이미지 예시 1


하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

- 명시된 데이터 수 확인 : 200 개

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	200개 (이미지 객체 200장, json 파일 200개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일 고유키, 파일명, 이미지 순번, 이미지 높이, 이미지 너비, 파일크기, 기상정보, 촬영구역, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 인스턴스, 지역코드, 라벨링 Object 개수			메타데이터 파일 형식	json
어노테이션	라벨링구분(Polygon), 라벨좌표, 대분류(산업구분), 중분류(축사 유형), 소분류(축사 종류)			어노테이션 파일 형식	

● 이미지 객체 파일(Tiff) 수 확인 : 200 개



● 메타데이터 및 어노테이션 파일(json) 수 확인 : 200 개

이름	항목유형	크기
L01_41463_150_20230915_N07_02653.json	JSON 파일	1KB
L01_41463_150_20230915_N07_02667.json	JSON 파일	1KB
L01_41220_130_20231022_N13_01427.json	JSON 파일	1KB
L01_41220_130_20231022_N13_01511.json	JSON 파일	2KB
L01_41220_130_20231022_N13_01551.json	JSON 파일	3KB
L01_41220_130_20231022_N13_01589.json	JSON 파일	1KB

● 진단 총 데이터 수: 200

● 오류 데이터 수: 명시된 데이터 수 - 실제 확인된 데이터 수 = 200 - 200 = 0

$$\begin{aligned}
 \text{데이터 파일 완전성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 0 / 200 \\
 &= 1.00
 \end{aligned}$$

비디오 예시 1

안전 관리 및 보안 시스템용 영상 데이터

● 데이터 명세서

- 명시된 데이터 수 확인 : 200 개

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	200개 (비디오 객체 200장, json 파일 200개)				
객체 데이터 유형	비디오	객체 데이터 형식	MP4	객체 데이터 해상도	1280 × 720 이상
메타데이터	파일명, 이미지 너비, 이미지 높이, 프레임 수, 데이터 전송 속도, 비트 수, CCTV 설치 구간, 촬영 일자, 야간 촬영 여부			메타데이터 파일 형식	json
어노테이션	이벤트 구분, 발생 시점 프레임, 지속 시간, 설명, 비식별화 여부			어노테이션 파일 형식	

● 비디오 객체 파일(MP4) 수 확인 : 192 개



● 메타데이터 및 어노테이션 파일(json) 수 확인 : 192 개

이름	유형	크기
A_0101_001.json	JSON 원본 파일	1KB
A_0101_002.json	JSON 원본 파일	1KB
A_0101_003.json	JSON 원본 파일	1KB
A_0101_004.json	JSON 원본 파일	1KB
A_0102_001.json	JSON 원본 파일	1KB
A_0102_002.json	JSON 원본 파일	1KB
A_0201_001.json	JSON 원본 파일	1KB
A_0201_002.json	JSON 원본 파일	1KB
A_0201_004.json	JSON 원본 파일	1KB

● 진단 총 데이터 수: 200

● 오류 데이터 수: 명시된 데이터 수 - 실제 확인된 데이터 수 = 200 - 192 = 8

$$\begin{aligned}
 \text{데이터 파일 완전성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 8 / 200 \\
 &= 0.96
 \end{aligned}$$

● (필수) 레코드 완전성

전체 데이터 레코드(논리적으로 연결된 하나의 단위로, 객체, 메타데이터, 어노테이션 등이 통합된 최소 단위) 중 필수 항목 데이터가 누락되지 않았는지 심사하는 항목이다. 예를 들어, 학습용 식물 정보 데이터에서 식물 이미지는 존재하는데, 필수 항목인 식물의 이름이 누락된 데이터를 오류 레코드로 분류하고, 정상 레코드의 비율을 측정한다.

- ▶ **적용 대상:** 비정형 객체 데이터 레코드
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 필수 항목이 누락된 레코드
 - 진단 데이터: 필수 항목이 존재하는 전체 레코드



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 이미지 파일명이 필수 값인 경우

오류 데이터) [null, "missing_file_name"]

정상 데이터) ["image1.jpg", "image2.png"]

예시 2: 동영상 데이터셋에서 프레임 속성이 필수 값인 경우

오류 데이터) [null, "undefined_frame_rate"]

정상 데이터) ["30fps", "60fps"]

예시 3: 오디오 데이터셋에서 샘플 속성이 필수 값인 경우

오류 데이터) [null, "undefined_sample_rate"]

정상 데이터) ["44.1kHz", "48kHz"]

예시 4: 텍스트 데이터셋에서 "ID" 필드가 필수 값인 경우

오류 데이터) [null, "missing_ID"]

정상 데이터) ["ID001", "ID002"]

예시 5: 위치 데이터셋에서 필수 값인 "경도" 필드가 요구되는 경우

오류 데이터) [null, "undefined_longitude"]

정상 데이터) ["37.7749", "122.4194"]

이미지 예시 1

하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일 고유키, 파일명, 이미지 순번, 이미지 높이, 이미지 너비, 파일크기, 기상정보, 촬영구역, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 인스턴스, 지역코드, 라벨링 Object 개수				메타데이터 파일 형식 json
어노테이션	라벨링구분(Polygon), 라벨좌표, 대분류(산업구분), 중분류(축사 유형), 소분류(축사 종류)				어노테이션 파일 형식

● 필수 속성

메타데이터	어노테이션
파일크기, 기상정보, 촬영구역	라벨링구분, 라벨좌표

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	메타데이터	<pre>{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" }, </pre>
	어노테이션	<pre>"ANNOTATIONS": [{ "DRAWING": "polygon", "SEGMENTATION": [0,512,0,512], "CATEGORY_1": "농업계", "CATEGORY_2": "과수원", "CATEGORY_3": "해당없음" }]</pre>

● 전체 레코드 확인

번호	객체	메타데이터			어노테이션		확인 결과
		FILE_SIZE	WEATHER	LOCATION	DRAWING	CATEGORY	
1	L01_41220_130_20230831_N11_01340.tif	791338	맑음	한강	pol	○	정상
2	L01_41220_130_20230831_N11_00702.tif						오류
3	L01_41220_130_20230831_N11_00744.tif	791400	흐림	낙동강	pol	○	정상
4	L01_41220_130_20230831_N11_01117.tif	806762	맑음	한강	pol	○	정상
5	L01_41220_130_20230831_N11_01253.tif	685945	맑음			○	오류
6	L01_41220_130_20230831_N11_01284.tif	556578	흐림	섬진강	pol	○	정상
7	L01_41220_130_20230831_N11_01288.tif	754138	흐림	한강	pol	○	정상
8	L01_41220_130_20230831_N11_01296.tif	956128	흐림	낙동강	pol	○	정상
9	L01_41220_130_20230831_N11_00084.tif	598746	맑음	한강	pol	○	정상
10	L01_41220_130_20230831_N11_01457.tif	618951	흐림	한강	pol	○	정상

● 진단 총 레코드 수: 10

● 오류 레코드 수: 2

● 레코드 완전성 = $1 - \text{오류 레코드 수} / \text{진단 총 레코드 수}$
 $= 1 - 2 / 10$
 $= 0.80$

● (필수) 메타데이터 값 완전성

비정형 객체의 메타데이터에서 필수 항목의 값이 누락되지 않았는지를 심사하는 항목이다. 예를 들어, 이미지 메타데이터에서 필수 항목인 파일명과 생성일이 누락이 없는지를 확인하여 필수 항목의 값이 누락되지 않은 비율을 심사한다.

▶ **적용 대상:** 메타데이터

▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 필수 항목인 메타데이터의 값이 누락된 메타데이터
- 진단 데이터: 명세서에 필수 항목으로 정의된 메타데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 이미지 메타데이터에서 필수 항목인 해상도(resolution) 값이 요구되는 경우

오류 데이터) [null, "undefined_resolution"]

정상 데이터) ["1920x1080", "3840x2160"]

예시 2: 오디오 파일 메타데이터에서 필수 값인 샘플링 레이트가 요구되는 경우

오류 데이터) [null, "undefined_sample_rate"]

정상 데이터) ["44.1kHz", "48kHz"]

예시 3: 동영상 데이터 메타데이터에서 프레임 속성값이 요구되는 경우

오류 데이터) [null, "undefined_frame_rate"]

정상 데이터) ["30fps", "60fps"]

예시 4: 텍스트 파일 메타데이터에서 필수 값인 파일 인코딩 값이 요구되는 경우

오류 데이터) [null, "undefined_encoding"]

정상 데이터) ["UTF-8", "ASCII"]

예시 5: 위치 데이터 메타데이터에서 필수 항목인 위도와 경도 값이 요구되는 경우

오류 데이터) [null, "undefined_coordinates"]

정상 데이터) ["37.7749, -122.4194", "40.7128, -74.0060"]

이미지 예시 1

산업 로봇-작업자 상호작용 환경 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	PNG	객체 데이터 해상도	1080 × 1920 이상
메타데이터	이미지 정보, 파일 이름, 깊이 파일 이름, 높이, 너비, 깊이 높이, 깊이 너비, 이미지ID, 카메라 정보, 환경, 작업 단계, 조도, 각도조건			메타데이터 파일 형식	json
어노테이션	영역, 이미지ID, 바운딩 박스, 카테고리ID, 지칭 문자, 토큰, 슈퍼 클래스, 용도, 무게			어노테이션 파일 형식	

● 메타데이터 필수 항목 정의

키	설명	필수 여부
FILE_NAME	파일명	Y
WORKING_STAGE	작업단계	Y
ANGLE_TYPE	각도조건	Y

● 데이터 세부 내용

파일명	구분	내용
4859_000001.json	메타데이터	<pre>{ "IMAGES": { "FILE_NAME": "4859_000001.png", "DEPTH_FILE_NAME": "4859_000001.npy", "HEIGHT": 1080, "WIDTH": 1920, "DEPTH_HEIGHT": 1024, "DEPTH_WIDTH": 1024, "ID": 1000162000001, "CAMERA_INFO": { "DEPTH_SCALE": 10, "CAMERA_TYPE": "azure_kinect" }, "ENVIRONMENT": "factory_r_01", "WORKING_STAGE": "ready", "LUMINOUS_INTENSITY": 1880, "ANGLE_TYPE": "각도조건1" } }</pre>

● 오류 데이터 예시

파일명	구분	내용
4859_000007.json	메타데이터	<pre>{ "IMAGES": { "FILE_NAME": "4859_000007.png", "DEPTH_FILE_NAME": "4859_000007.npy", "HEIGHT": 1080, "WIDTH": 1920, "DEPTH_HEIGHT": 1024, "DEPTH_WIDTH": 1024, "ID": 1000162000001, "CAMERA_INFO": { "DEPTH_SCALE": 10, "CAMERA_TYPE": "azure_kinect" }, }, "ENVIRONMENT": "factory_r_01", "WORKING_STAGE": "ready", "LUMINOUS_INTENSITY": 1880, "ANGLE_TYPE": "" } }</pre>

● 전체 데이터 확인

번호	파일명	필수 항목 값 존재 여부			확인 결과
		FILE_NAME	WORKING_STAGE	ANGLE_TYPE	
1	3848_000007.json	존재	존재	존재	정상
2	4848_000008.json	존재	존재	존재	정상
3	3848_000009.json	존재	존재	존재	정상
4	4859_000001.json	존재	존재	존재	정상
5	4859_000002.json	존재	존재	존재	정상
6	4859_000003.json	존재	존재	존재	정상
7	4859_000004.json	존재	존재	존재	정상
8	4859_000005.json	존재	존재	존재	정상
9	4859_000006.json	존재	존재	존재	정상
10	4859_000007.json	존재	존재	누락	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 메타데이터 값 완전성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 1 / 10$
 $= 0.90$

이미지 예시 2

하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일 고유키, 파일명, 이미지 순번, 이미지 높이, 이미지 너비, 파일크기, 기상정보, 촬영구역, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 인스턴스, 지역코드, 라벨링 Object 개수			메타데이터 파일 형식	json
어노테이션	라벨링구분(Polygon), 라벨좌표, 대분류(산업구분), 중분류(축사 유형), 소분류(축사 종류)			어노테이션 파일 형식	

● 메타데이터 필수 항목 정의

키	설명	필수 여부
ID	파일 고유키	Y
FILE_NAME	파일명	Y
SEQUENCE	이미지 순번	Y
HEIGHT	이미지 높이	Y
WIDTH	이미지 너비	Y

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	메타데이터	<pre>{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" } }</pre>

● 오류 데이터 예시

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	메타데이터	<pre>{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "", "WIDTH": "", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" }, }</pre>

● 전체 데이터 확인

번호	객체 데이터	파일명	확인 결과
1	L01_11680_65_20231025_N03_00002.tif	L01_11680_65_20231025_N03_00002.json	정상
2	L01_41220_130_20230831_N11_00661.tif	L01_41220_130_20230831_N11_00661.json	정상
3	L01_41220_130_20230831_N11_00702.tif	L01_41220_130_20230831_N11_00702.json	정상
4	L01_41220_130_20230831_N11_00744.tif	L01_41220_130_20230831_N11_00744.json	정상
5	L01_41220_130_20230831_N11_01117.tif	L01_41220_130_20230831_N11_01117.json	정상
6	L01_41220_130_20230831_N11_01253.tif	L01_41220_130_20230831_N11_01253.json	정상
7	L01_41220_130_20230831_N11_01284.tif	L01_41220_130_20230831_N11_01284.json	정상
8	L01_41220_130_20230831_N11_01288.tif	L01_41220_130_20230831_N11_01288.json	정상
9	L01_41220_130_20230831_N11_01296.tif	L01_41220_130_20230831_N11_01296.json	정상
10	L01_41220_130_20230831_N11_01340.tif	L01_41220_130_20230831_N11_01340.json	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 메타데이터 값 완전성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 1 / 10$$

$$= 0.90$$

■ (선택) 어노테이션 완전성

바운딩박스 크기, 정해진 카테고리 또는 라벨링 기준 등이 누락없이 존재하는지를 심사하는 항목이다. 예를 들어, 이미지 데이터의 모든 객체에 라벨이 부여되었는지를 확인한다.

- ▶ **적용 대상:** 학습용 데이터로 비정형 객체에 대해 필수인 어노테이션 속성
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 어노테이션이 누락된 비정형 객체 데이터
 - 진단 데이터: 어노테이션이 요구되는 비정형 객체 데이터



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 이미지 데이터에서 객체의 바운딩박스 좌표 값이 요구되는 경우
오류 데이터) [null, "undefined_coordinates"]
정상 데이터) ["x1:10, y1:20, x2:50, y2:60"]

예시 2: 음성 데이터에서 텍스트 스크립트 라벨이 요구되는 경우
오류 데이터) [null, "missing_script"]
정상 데이터) ["안녕하세요", "Hello"]

예시 3: 동영상 데이터에서 모든 프레임에 객체 라벨링이 요구되는 경우
오류 데이터) [null, "undefined_label"]
정상 데이터) ["cat", "car"]

예시 4: 자연어 처리 데이터에서 텍스트의 감정 분석 결과 라벨이 요구되는 경우
오류 데이터) [null, "missing_sentiment"]
정상 데이터) ["positive", "neutral", "negative"]

예시 5: 오디오 데이터에서 특정 구간의 라벨이 요구되는 경우
오류 데이터) [null, "missing_label"]
정상 데이터) ["음성", "배경 소음"]

이미지 예시 1

하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일 고유키, 파일명, 이미지 순번, 이미지 높이, 이미지 너비, 파일크기, 기상정보, 촬영구역, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 인스턴스, 지역코드, 라벨링 Object 개수			메타데이터 파일 형식	json
어노테이션	라벨링구분(Polygon), 세그멘테이션좌표, 대분류(산업구분), 중분류(축사 유형), 소분류(축사 종류)			어노테이션 파일 형식	

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01296.json	어노테이션	<pre> "ANNOTATIONS": [{ "DRAWING": "polygon", "SEGMENTATION": [0, 0, 0, 512, 512, 512, 512, 0, 175, 0], "CATEGORY_1": "농업계", "CATEGORY_2": "과수원", "CATEGORY_3": "해당없음" }] </pre>

● 오류 데이터 예시

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	어노테이션	<pre> "ANNOTATIONS": [{ "DRAWING": "polygon", "SEGMENTATION": [0, 0, 0, 512, 512, 512, 512, 0, 175, 0], "CATEGORY_1": "농업계", "CATEGORY_2": "과수원", "CATEGORY_3": "해당없음" }] </pre>

● 전체 데이터 확인

번호	객체 데이터	파일명	확인 결과
1	L01_11680_65_20231025_N03_000002.tif	L01_11680_65_20231025_N03_000002.json	정상
2	L01_41220_130_20230831_N11_00661.tif	L01_41220_130_20230831_N11_00661.json	정상

번호	객체 데이터	파일명	확인 결과
3	L01_41220_130_20230831_N11_00702.tif	L01_41220_130_20230831_N11_00702.json	정상
4	L01_41220_130_20230831_N11_00744.tif	L01_41220_130_20230831_N11_00744.json	정상
5	L01_41220_130_20230831_N11_01117.tif	L01_41220_130_20230831_N11_01117.json	정상
6	L01_41220_130_20230831_N11_01253.tif	L01_41220_130_20230831_N11_01253.json	정상
7	L01_41220_130_20230831_N11_01284.tif	L01_41220_130_20230831_N11_01284.json	정상
8	L01_41220_130_20230831_N11_01288.tif	L01_41220_130_20230831_N11_01288.json	정상
9	L01_41220_130_20230831_N11_01296.tif	L01_41220_130_20230831_N11_01296.jpg	정상
10	L01_41220_130_20230831_N11_01340.tif	L01_41220_130_20230831_N11_01340.json	오류 ※ 대분류, 중분류, 소분류 누락

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 어노테이션 완전성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 1 / 10$
 $= 0.90$

● (선택) 특징 완전성

학습용 데이터에서 모델 학습에 필요한 주요 특징(feature) 데이터가 누락되지 않았는지를 심사하는 항목이다. 예를 들어, 머신러닝 학습 데이터에서 각 학습을 위해 중요한 객체와 객체의 메타데이터 또는 어노테이션 속성값(크기, 색상 등)이 모두 채워져 있는지를 확인한다.

- ▶ **적용 대상:** 요구되는 특징이 있는 데이터 셋
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 모델학습에 필요한 주요 특징이 누락된 데이터 값
 - 진단 데이터: 모델학습에 필요한 주요 특징으로 정의된 데이터 값



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 이미지 데이터에서 색상 특징 값이 요구되는 경우

오류 데이터) [null, "histogram_value_missing"]

정상 데이터) ["histogram_value_1", "histogram_value_2"]

예시 2: 텍스트 데이터에서 감정 점수 값이 요구되는 경우

오류 데이터) [null, "score_missing"]

정상 데이터) ["0.8", "-0.5"]

예시 3: 동영상 데이터에서 움직임 특징 값이 요구되는 경우

오류 데이터) [null, "motion_vector_missing"]

정상 데이터) ["vector_1", "vector_2"]

예시 4: 오디오 데이터에서 음조 특징 값이 요구되는 경우

오류 데이터) [null, "pitch_missing"]

정상 데이터) ["pitch_value_1", "pitch_value_2"]

예시 5: 자연어 처리 데이터에서 텍스트 길이 값이 요구되는 경우

오류 데이터) [null, "length_missing"]

정상 데이터) ["100", "150"]

비디오 예시 1

행동 인식 기반 로봇 자율작동 데이터

● 데이터 구조

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (비디오 객체 10장, json 파일 10개)				
객체 데이터 유형	비디오	객체 데이터 형식	MP4	객체 데이터 해상도	1296 × 2304 이상
메타데이터	파일명, 파일 포맷, 파일 크기, 영상 해상도, 서비스 환경, 프레임 속도, 총 프레임 수, 카메라 설치 높이, 카메라 설치 각도, 상호작용 유형			메타데이터 파일 형식	json
어노테이션	사용자 수, 연령대, 행동 구간 식별 정보(세그멘테이션)			어노테이션 파일 형식	

● 모델 학습에 필요한 주요 특징

객체 데이터	비디오 객체
메타데이터	서비스 환경
어노테이션	연령대, 행동 구간 식별 정보

● 데이터 세부 내용

파일명	구분	내용
01_1141039.json	메타데이터	<pre>{ "META_DATA": { "FILE_NAME": "01_1141039.mp4", "FORMAT": "mp4", "SIZE": 29740039, "WIDTH_HEIGHT": [2304, 1296], "ENVIRONMENT": "복지시설", "FRAME_RATE": 15, "TOTAL_FRAMES": 1424, "CAMERA_HEIGHT": 200, "CAMERA_ANGLE": 30 } }</pre>
	어노테이션	<pre>"ANNOTATIONS": { "SPACE_CONTEXT": "복지관에서 10월 14일 점심에 촬영된 동영상이다. 촬영 카메라는 입구 근처 측면에 설치되어있고, 장소를 이용하기 위한 좌석이 있다.", "USER_NUM": 1, "TARGET_OBJECTS": [{ "OBJECT_ID": 0, "AGE": "노년", "GENDER": "2", }], }</pre>

파일명	구분	내용
		<pre> "SEGMENTATION": [{ "SEGMENT_ID": 0, "ACTION_TYPE": "사용", "START_FRAME": 2, "END_FRAME": 1223, "DURATION": 1222 }, { "SEGMENT_ID": 1, "ACTION_TYPE": "종료", "START_FRAME": 1223, "END_FRAME": 1421, "DURATION": 199 }] </pre>

● 전체 레코드 확인

번호	객체	메타데이터	어노테이션		확인 결과
		ENVIRONMENT	AGE	SEGMENTATION	
1	01_1141030.mp4	복지시설	노년	○	정상
2	01_1141031.mp4	복지시설	청중장년	○	정상
3	01_1141032.mp4		노년	○	오류
4	01_1141033.mp4	복지시설	청중장년	○	정상
5	01_1141034.mp4	복지시설	노년		오류
6	01_1141035.mp4	복지시설	유소년	○	정상
7	01_1141036.mp4	복지시설	노년	○	정상
8	01_1141037.mp4	복지시설		○	오류
9	01_1141038.mp4	복지시설	노년	○	정상
10	01_1141039.mp4	복지시설	노년	○	정상

● 진단 총 데이터 수: 40

● 오류 데이터 수: 3

● 특징 완전성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
= 1 - 3 / 40
= 0.93

이미지 예시 1

하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일 고유키, 파일명, 이미지 순번, 이미지 높이, 이미지 너비, 파일크기, 기상정보, 촬영구역, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 인스턴스, 지역코드, 라벨링 Object 개수			메타데이터 파일 형식	json
어노테이션	라벨링구분(Polygon), 라벨좌표, 대분류(산업구분), 중분류(축사 유형), 소분류(축사 종류)			어노테이션 파일 형식	

● 모델학습에 필요한 주요 특징

객체 데이터	이미지 객체
메타데이터	기상정보, 촬영구역
어노테이션	라벨링 구분, 카테고리

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	메타데이터	<pre>{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" }, </pre>
	어노테이션	<pre>"ANNOTATIONS": [{ "DRAWING": "polygon", </pre>

파일명	구분	내용
		"SEGMENTATION": [0,512,0,512], "CATEGORY_1": "농업계", "CATEGORY_2": "과수원", "CATEGORY_3": "해당없음"
		}
		]

● 전체 레코드 확인

번호	객체	메타데이터		어노테이션		확인 결과
		WEATHER	LOCATION	DRAWING	CATEGORY	
1	L01_41220_130_20230831_N11_01340.tif	맑음	한강	pol	○	정상
2	L01_41220_130_20230831_N11_00702.tif	흐림	한강	pol	○	정상
3	L01_41220_130_20230831_N11_00744.tif		낙동강	pol	○	오류
4	L01_41220_130_20230831_N11_01117.tif	맑음	한강	pol	○	정상
5	L01_41220_130_20230831_N11_01253.tif	맑음		pol		오류
6	L01_41220_130_20230831_N11_01284.tif	흐림	섬진강	pol	○	정상
7	L01_41220_130_20230831_N11_01288.tif		한강	pol	○	오류
8	L01_41220_130_20230831_N11_01296.tif	흐림	낙동강		○	오류
9	L01_41220_130_20230831_N11_00084.tif	맑음	한강	pol	○	정상
10	L01_41220_130_20230831_N11_01457.tif	흐림	한강	pol	○	정상

- 진단 총 데이터 수: 40
- 오류 데이터 수: 5
- 특징 완전성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
= 1 - 5 / 40
= 0.88

4.2 유효성

유효성은 날짜, 범위, 포맷, 논리 관계 또는 정해진 기준에 데이터 내용이 충족하는지 진단하는 기준으로 비정형 데이터에 대해 다음과 같은 심사 항목으로 평가한다.

■ (필수) 데이터 구조 구문 유효성

메타데이터와 어노테이션의 구조가 사전에 정의된 스키마 규칙에 부합하는지를 심사하는 항목이다. 예를 들어, XML이나 JSON의 구조가 명세서에 정의된 형식에 맞는지를 확인한다.

- ▶ **적용 대상:** 메타데이터 또는 어노테이션 데이터
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 정의된 구조에 적합하지 않은 데이터 값
 - 진단 데이터: 메타데이터와 어노테이션의 구조가 정의된 데이터 값



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 명세서에 JSON 포맷의 구조가 정의된 경우

오류 데이터) 종괄호가 누락되거나 키(Key) 값이 명세서와 일치하지 않음
정상 데이터) 모든 종괄호와 키(key) 값이 명세서에 정의된 포맷과 일치함

예시 2: 명세서에 XML 포맷의 태그가 정의된 경우

오류 데이터) 태그가 중첩되거나 종료되지 않음
정상 데이터) 모든 태그가 올바르게 중첩되고 종료됨

예시 3: 명세서에 CSV 포맷의 컬럼 개수가 5개로 정의된 경우

오류 데이터) 컬럼 개수가 명세서와 다름 (예: 4개 컬럼, name, age, city, email)
정상 데이터) 컬럼 개수가 명세서와 동일함 (예: 5개 컬럼, name, age, city, country, email)

예시 4: 명세서에 CSV 포맷의 구분자가 정의된 경우

오류 데이터) 구분자가 명세서와 다르게 사용됨 (예: 쉼표 대신 세미콜론 ;)
정상 데이터) 데이터 명세서에 정의된 구분자(예: 쉼표 ,)를 정확히 사용함

예시 5: 명세서에 JSON 포맷의 계층 구조가 정의된 경우

오류 데이터) 계층 구조가 어긋나거나 속성 순서가 변경됨
(예: { "name": "John", "user": { "age": 30 } })
정상 데이터) 계층 구조와 속성 순서가 명세서에 정의된 대로 정확히 따름
(예: { "user": { "name": "John", "age": 30 } })

이미지 예시 1

고해상도 도로노면 이미지 데이터

● 데이터 기준

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (jpg파일10개, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg	객체 데이터 해상도	512 × 512 이상
메타데이터	원시데이터 정보, 승인년도, 저작권, 도로 종류, 촬영 방법, 원천데이터 정보, 이미지 번호, 이미지 폭, 이미지 높이, 원천데이터 파일명			파일 형식	json
어노테이션	원천데이터별 라벨링정보, 어노테이션 식별자, 다중 객체 라벨 시 사용되는 변수, 이미지 번호, 라벨 유형, 세그멘테이션 정보, 바운딩박스 정보, 바운딩박스 전체면적				

● 정의된 데이터 구조

No	속성명
1	info
1-1	Acknowledge
1-2	Copyright
1-3	Middle_ID
1-4	Shooting_ID
2	images
2-1	id
2-2	width
2-3	height
2-4	file_name
3	annotations
3-1	id
3-2	iscrowd
3-3	image_id
3-4	category_id
3-5	segmentation
3-6	bbox
3-7	area

● 메타데이터 및 어노테이션 구조

파일명	구분	내용
H_A_V_04_0815090338212.json	메타데이터 파일	<pre>{ "info": { "Acknowledge": "2023", "Copyright": "에이치씨아이플러스컨소시엄", "Middle_ID": "A", "Shooting_ID": "V" }, "images": { "id": "H_A_V_04_0815090338212", "width": 2048, "height": 2048, "file_name": "H_A_V_04_0815090338212.jpg" } }</pre>
	어노테이션 파일	<pre>"annotations": [{ "id": 1, "iscrowd": 0, "image_id": 1, "category_id": 15, "segmentation": [74.18, 2048.0, 77.31, 1963.79, 75.17, 1895.71, 78.33, 2048.0], "bbox": [0.0, 0.0, 82.13, 2048.0], "area": 168202.24 }]</pre>

● 구문 구조 오류 예시

파일명	구분	내용
H_C_V_06_0901083953261.json	메타데이터 파일	<pre>{ "info": { "Copyright": "에이치씨아이플러스컨소시엄", "Middle_ID": "C", "Acknowledge": "2023", "Shooting_ID": "V" }, "images": { "id": "H_C_V_06_0901083952961", "width": 2048, "height": 2048, </pre>

파일명	구분	내용
		"file_name": "H_C_V_06_0901083952961.jpg" }
	어노테이션 파일	"annotations": [{ "id": 1, "iscrowd": 0, "image_id": 01, "category_id": 3, "area": 103805.7426, "bbox": [40.7, 0.0, 102.42, 1013.53] }]

● 데이터 구문 구조 확인 결과

번호	객체 데이터	구문 구조 확인 대상 파일	확인 결과
1	H_A_V_04_0815090338212.jpg	H_A_V_04_0815090338212.json	정상
2	H_C_F_05_0815090620898.jpg	H_C_F_05_0815090620898.json	정상
3	H_C_F_05_0815091300806.jpg	H_C_F_05_0815091300806.json	정상
4	H_C_F_05_0815092312304.jpg	H_C_F_05_0815092312304.json	정상
5	H_C_V_04_0801093327839.jpg	H_C_V_04_0801093327839.json	정상
6	H_C_V_04_0801094107823.jpg	H_C_V_04_0801094107823.json	정상
7	H_C_V_04_0801094511915.jpg	H_C_V_04_0801094511915.json	정상
8	H_C_V_06_0901083715828.jpg	H_C_V_06_0901083715828.json	정상
9	H_C_V_06_0901083952961.jpg	H_C_V_06_0901083952961.json	정상
10	H_C_V_06_0901083953261.jpg	H_C_V_06_0901083953261.json	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 데이터 구조 구문 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 1 / 10
 = 0.9

■ (필수) 데이터 포맷 유효성

비정형 객체 데이터가 명세서에 정의된 파일 포맷 및 코덱 형식을 따르는지를 심사하는 항목이다. 비정형 객체 데이터는 동일한 파일 포맷이라도 내부 코덱에 따라 호환성이 달라지므로, 명세서에서 허용한 포맷과 코덱 형식까지 확인한다. 예를 들어, 명세서 내 파일 포맷과 코덱이 MP4, H.264로 정의된 경우 객체 데이터의 파일 포맷뿐만 아니라 코덱까지 확인하여야 한다.

▶ **적용 대상:** 파일 포맷이 정의된 비정형 객체 데이터

▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 정의된 파일 포맷을 따르지 않는 비정형 객체 데이터
- 진단 데이터: 파일 포맷이나 코덱 형식 정의된 비정형 객체 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 명세서에 이미지 파일의 포맷이 JPG으로 정의된 경우

오류 데이터) [image1.png, photo.png]

정상 데이터) [image1.jpg, photo.jpg]

예시 2: 명세서에 오디오 파일의 포맷이 WAV으로 정의된 경우

오류 데이터) [audio1.mp3, track.mp3]

정상 데이터) [audio1.wav, track.wav]

예시 3: 명세서에 텍스트 파일의 포맷이 UTF-8으로 정의된 경우

오류 데이터) 인코딩: ASCII

정상 데이터) 인코딩: UTF-8

예시 4: 명세서에 동영상 파일의 포맷이 MP4 형식으로 정의된 경우

오류 데이터) [video1.mkv, movie.mkv]

정상 데이터) [video1.mp4, movie.mp4]

예시 5: 명세서에 로그 데이터의 파일의 포맷이 JSON으로 정의된 경우

오류 데이터) [log.txt]

정상 데이터) [log.json]

이미지 예시 1

고해상도 도로노면 이미지 데이터

● 데이터 요약

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (jpg파일 10개, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg	객체 데이터 해상도	512 × 512 이상
메타데이터	원시데이터 정보, 승인년도, 저작권, 도로 종류, 촬영 방법, 원천데이터 정보, 이미지 번호, 이미지 폭, 이미지 높이, 원천데이터 파일명			파일 형식	json
어노테이션	원천데이터별 라벨링정보, 어노테이션 식별자, 다중 객체 라벨 시 사용되는 변수, 이미지 번호, 라벨 유형, 세그멘테이션 정보, 바운딩박스 정보, 바운딩박스 전체면적				

● 객체 데이터 파일 포맷 확인

이름	날짜	유형	크기	태그
H_A_V_04_0815090338212.jpg	2024-02-01 오전 10:45	JPG 파일	1,615KB	
H_C_F_05_0815090620898.jpg	2024-02-01 오전 10:45	JPG 파일	741KB	
H_C_F_05_0815091300806.jpg	2024-02-01 오전 10:45	JPG 파일	907KB	
H_C_F_05_0815092312304.jpg	2024-02-01 오전 10:45	JPG 파일	641KB	
H_C_V_04_0801093327839.jpg	2024-02-01 오전 10:45	JPG 파일	1,430KB	
H_C_V_04_0801094107823.jpg	2024-02-01 오전 10:45	JPG 파일	1,538KB	
H_C_V_04_0801094511915.jpg	2024-02-01 오전 10:45	JPG 파일	1,436KB	
H_C_V_06_0901083715828.jpg	2024-02-01 오전 10:45	JPG 파일	370KB	
H_C_V_06_0901083952961.jpg	2024-02-01 오전 10:45	JPG 파일	750KB	
H_C_V_06_0901083953261.jpg	2024-02-01 오전 10:45	JPG 파일	750KB	

〈정의된 데이터 파일 포맷인지 확인〉

- 진단 총 데이터 수: 10
- 오류 데이터 수: 0
- 데이터 포맷 유효성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 0 / 10$
 $= 1.00$

■ (필수) 객체 유효성

비정형 객체 파일이 손상이 없고, 활용 가능한 상태인지를 심사하는 항목이다. 예를 들어, 객체 파일(텍스트, 이미지, 오디오, 비디오 등)이 손상 없이 열리고, 지정된 포맷·인코딩·코덱이 정상인지 여부를 확인하거나 객체의 내용에 혐오나 차별 등 유해 요소를 포함하지 않는지를 심사한다.

▶ 데이터 유형별 실제 활용이 어려운 예

데이터 유형	속성 예시
공통	파일이 정상적으로 동작하지 않는 경우
이미지	이미지 해상도가 낮아 객체를 식별하기 어려운 경우
동영상	영상 해상도가 낮아 객체를 식별하기 어려운 경우
오디오	요구사항에 없는 노이즈 발생 또는 사운드 데이터가 누락되어 내용 확인이 어려운 경우
텍스트	텍스트가 깨져서 내용 확인이 어려운 경우

▶ 적용 대상: 비정형 객체 데이터

▶ 정량화 수식: $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$

- 오류 데이터: 실제 활용할 수 없는 비정형 객체 데이터
- 진단 데이터: 객체 유효성이 적용되는 비정형 객체 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 이미지 파일이 정상적으로 열리지 않는 경우

오류 데이터) 이미지 파일이 깨져서 열리지 않음

정상 데이터) 이미지 파일이 정상적으로 열리며 객체 식별이 가능함

예시 2: 오디오 파일이 정상적으로 재생되지 않는 경우

오류 데이터) 오디오 파일이 재생되지 않음

정상 데이터) 오디오 파일이 요구된 형식으로 재생되며 노이즈 없이 깨끗하게 들림

예시 3: 동영상 파일이 정상적으로 재생되지 않는 경우

오류 데이터) 동영상 파일이 손상되어 일부 프레임이 누락됨

정상 데이터) 동영상 파일이 손상 없이 모든 프레임이 재생 가능함

예시 4: 동영상 파일이 동영상 코덱 문제로 인해 재생되지 않는 경우

오류 데이터) 동영상 파일이 코덱 문제로 인해 재생되지 않음

정상 데이터) 동영상 파일이 요구된 코덱으로 저장되어 문제없이 재생 가능함

예시 5: 텍스트 파일이 정상적으로 표시되지 않는 경우

오류 데이터) 텍스트 파일이 인코딩 문제로 인해 내용이 깨져서 읽을 수 없음

정상 데이터) 텍스트 파일이 올바르게 인코딩되어 모든 내용이 정상적으로 표시됨


이미지 예시 1

고해상도 도로노면 이미지 데이터


● 데이터 요약

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (jpg파일 10개, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg	객체 데이터 해상도	512 × 512 이상
메타데이터	원시데이터 정보, 승인년도, 저작권, 도로 종류, 촬영 방법, 원천데이터 정보, 이미지 번호, 이미지 폭, 이미지 높이, 원천데이터 파일명			파일 형식	json
어노테이션	원천데이터별 라벨링정보, 어노테이션 식별자, 다중 객체 라벨 시 사용되는 변수, 이미지 번호, 라벨 유형, 세그멘테이션 정보, 바운딩박스 정보, 바운딩박스 전체면적				

● 오류 데이터 예시



〈파일이 정상적으로 동작하지 않는 경우〉



〈이미지가 깨진 경우〉

● 객체 유효성 확인 결과

번호	파일명	확인 결과
1	H_A_V_04_0815090338212.jpg	정상
2	H_C_F_05_0815090620898.jpg	정상
3	H_C_F_05_0815091300806.jpg	정상
4	H_C_F_05_0815092312304.jpg	정상
5	H_C_V_04_0801093327839.jpg	정상
6	H_C_V_04_0801094107823.jpg	오류
7	H_C_V_04_0801094511915.jpg	정상
8	H_C_V_06_0901083715828.jpg	정상
9	H_C_V_04_0801094107824.jpg	정상
10	H_C_V_06_0901083953261.jpg	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

● 객체 유효성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 2 / 10$
 $= 0.80$

오디오 예시 1

감정이 태깅된 자유대화 (청소년)

데이터 구조	오디오 객체, 오디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (wav파일 10개, json 파일 10개)				
객체 데이터 유형	오디오	객체 데이터 형식	wav	재생 길이	3s 이상
메타데이터	파일 정보, 파일명, 파일 길이, 발화 시작점, 발화 끝점, 발화 길이, 원천데이터 정보, 주파수, 비트 수, 인코딩방식, 채널 수			파일 형식	json
어노테이션	소음 정보, 실내/실외 환경 종류, 녹음 장소, SNR, 실내/실외 환경 종류, 녹음 장소, SNR, 참여자 정보, 발화자 고유 번호, 청소년 구분, 연령, 성별, 거주지, 직업, 목상태, 마스크 착용 유/무, 녹음 장치, 참여자 정보, 발화자 고유 번호, 청소년 구분, 연령, 성별, 거주지, 직업, 목상태, 마스크 착용 유/무, 녹음 장치, 대화정보, 대화 도메인, 대화 토픽, 대화 토픽, 대화내용, 대화 순서 번호, 발화자 구분, 감정 유형, 감정 상태, 감정 정도, 감정 대상, 감정 유형, 감정 상태, 감정 정도, 감정 대상, Text 전사내용, 대화 시작시간, 대화 끝 시간				

● 오류 데이터 예시

1_A651G1A1_A644G1A1_T2_1D09T0360C000310_047154.wav ×
파일을 재생할 수 없습니다. 파일 형식이 지원되지 않거나, 파일 확장명이 올바르지 않거나, 파일이 손상되었을 수 있습니다.

0xC00D36C4

피드백 보내기

〈파일을 열었을 때 정상적으로 파일이 동작하지 않는 경우〉

● 객체 유효성 확인 결과

번호	파일명	확인 결과
1	1_A627G2A1_A629G2A1_T2_1D09T0384C000358_047277.wav	정상
2	1_A633G2A1_A632G2A1_T2_1D02T0058C000219_047180.wav	정상
3	1_A635G1A1_A634G1A1_T2_1D09T0393C000742_047104.wav	정상
4	1_A639G1A1_A640G1A1_T2_1D09T0386C000477_047315.wav	정상
5	1_A640G1A1_A639G1A1_T2_1D09T0379C000468_047145.wav	정상
6	1_A640G1A1_A639G1A1_T2_1D10T0429C000446_047116.wav	정상
7	1_A642G1A1_A643G1A1_T2_1D10T0420C000310_047910.wav	정상
8	1_A644G1A1_A651G1A1_T2_1D03T0097C000065_048026.wav	정상
9	1_A651G1A1_A644G1A1_T2_1D04T0151C000360_047128.wav	정상
10	1_A651G1A1_A644G1A1_T2_1D09T0360C000310_047154.wav	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 객체 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 1 / 10$$

$$= 0.90$$

비디오 예시 1

한국 씨름 동작 데이터

● 데이터 요약

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	2개 (mp4 파일 2개, json 파일 2개)				
객체 데이터 유형	비디오	객체 데이터 형식	mp4	재생 길이	1m 이상
메타데이터	데이터셋 정보, 데이터셋 명칭, 데이터셋 버전, 데이터셋 생성년도, 카테고리 정보, 카테고리 아이디, 카테고리 대분류, 기술명, 비디오 정보, 비디오 아이디, 비디오 파일명, 카메라 번호, 비디오 확장자, 비디오 가로길이, 비디오 세로길이, 비디오 종횡비, 원본영상 FPS, 추출영상 FPS, 비디오 길이, 비디오 카테고리, 비디오 촬영날짜			파일 형식	json
어노테이션	비디오 구간, 어노테이션 정보, 비디오 구간, 어노테이션 아이디, 비디오 구간 시작점, 비디오 구간 끝점, 비디오 구간, 분류 아이디, 비디오 구간 분류, 공격 선수 아이디, 공격 선수 설명, 승자 선수 아이디, 승자 선수 설명, 비디오 세부, 구간 리스트, 비디오 세부, 구간 시작점, 비디오 세부, 구간 끝점, 비디오 세부, 구간 분류				

● 오류 데이터 예시



〈파일이 정상적으로 동작하지 않는 경우〉



〈영상이 해상도가 낮아 객체 식별이 어려운 경우〉

● 객체 유효성 확인 결과

번호	파일명	확인 결과
1	씨름영상1.mp4	오류
2	씨름영상2.mp4	오류

● 진단 총 데이터 수: 2

● 오류 데이터 수: 2

● 객체 유효성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 2 / 2$
 $= 0.00$


텍스트 예시 1

초거대 AI 헬스케어 질의응답 데이터

● 데이터 요약

데이터 구조	텍스트 객체, 텍스트 객체별 메타데이터와 어노테이션으로 구성된 json 파일			
데이터 수량	2개 (json파일 2개, json 파일 2개)			
객체 데이터 유형	텍스트	객체 데이터 형식	json	
메타데이터	파일명			
어노테이션	질환 분류, 참여자 성별, 참여자 나이, 참여자 직업, 과거병력유무, 현 거주지, 한글 질환명, 영어 질환명, 질문 의도, 질문 문장, 엔티티 id, 엔티티 텍스트, 엔티티 값, 엔티티 텍스트 시작 위치, 질문 문장 어절 수, 진료과, 본론, 결론, 답변 문장 어절 수			파일 형식 json

● 오류 데이터 예시



〈텍스트가 깨져서 내용 확인이 어려운 경우〉

● 객체 유효성 확인 결과

번호	파일명	확인 결과
1	HC-Q-1160428.json	오류
2	HC-A-03614230.json	정상

● 진단 총 데이터 수: 2

● 오류 데이터 수: 1

$$\begin{aligned}
 \text{객체 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 1 / 2 \\
 &= 0.50
 \end{aligned}$$

■ (선택) 관계 유효성

레코드를 구성하는 객체데이터, 메타데이터, 어노테이션 간의 데이터 값이 정의된 관계 규칙에 부합하는지를 심사하는 항목이다. 예를 들어, 레코드 내 구성요소 간의 참조 규칙(ID·경로·시간 정렬 등)이 일관되게 유지되는지를 확인하거나, 멀티모달 데이터의 경우, 시간적·공간적 정렬성과 의미적 대응 관계를 함께 확인한다.

- ▶ **적용 대상:** 속성 간 규칙이 정의된 메타데이터와 어노테이션
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 정의된 속성 간 관계 규칙을 따르지 않는 데이터
 - 진단 데이터: 데이터 속성 간 관계 규칙이 정의된 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 메타데이터에 정의된 파일 크기가 2MB인 경우

오류 데이터) 실제 파일 크기: 3MB

정상 데이터) 실제 파일 크기: 2MB

예시 2: 메타데이터에 정의된 어노테이션 라벨이 “cat”인 경우

오류 데이터) 어노테이션 라벨이 “dog”로 라벨링됨

정상 데이터) 어노테이션 라벨이 “cat”로 라벨링됨

예시 3: 메타데이터에 정의된 프레임 수가 300인 경우

오류 데이터) 실제 동영상 데이터 프레임 수: 280프레임

정상 데이터) 실제 동영상 데이터 프레임 수: 300프레임

예시 4: 오디오 파일의 길이(duration)가 180초인 경우

오류 데이터) 메타데이터에 오디오 파일의 길이가 185초로 정의됨

정상 데이터) 메타데이터에 오디오 파일의 길이가 180초로 정의됨

예시 5: 텍스트 파일의 단어 개수가 150개인 경우

오류 데이터) 메타데이터에 텍스트 파일의 단어 개수가 160개로 정의됨

정상 데이터) 메타데이터에 텍스트 파일의 단어 개수가 150개로 정의됨

이미지 예시 1

아동 복부 X선 합성 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	PNG	객체 데이터 해상도	512 × 512 이상
메타데이터	객체 파일명, 파일 포맷, 이미지 생성 일자, 파일크기, 이미지 가로 길이, 이미지 세로 길이			메타데이터 파일 형식	json
어노테이션	세그멘테이션(좌표값, 라벨링 타입), 캡션, 환자 정보 (나이, 진단 구분, 접수 일자)			어노테이션 파일 형식	

● 속성 간 관계 규칙

대상	속성명		속성 설명	관계 규칙
json 파일	메타데이터	IMAGEDATE	이미지 생성 일자	REGISTRATIONDATE <= IMAGEDATE
	어노테이션	REGISTRATIONDATE	접수 일자	

● 데이터 세부 내용

파일명	구분	내용
31_al0009.json	메타데이터	<pre>{ "META": { "FILENAME": "31_al0009.png", "FORMAT": "png", "IMAGEDATE": "2024-11-21", "IMAGESIZE": "329.02 KB", "IMAGEWIDTH": 512, "IMAGEHEIGHT": 512 } }</pre>
	어노테이션	<pre>"ANNOTATIONS": [{ "PATIENT": { "AGE": null, "DIAGNOSIS": 3, "REGISTRATIONDATE": "2024-11-19" }, "SHAPES": [{ "CLASS": 3, "POINTS": [[291, 122], [286, 122], [277, 126], [273, 130]] }] }]</pre>

파일명	구분	내용
		<pre>], "SHAPE_TYPE": "POLYGON" }], "CAPTION": "This abdominal X-ray image shows the presence of air-fluid level in the abdominal cavity." }]</pre>

● 오류 데이터 예시

파일명	구분	내용
31_al0046.json	메타데이터	<pre>{ "META": { "FILENAME": "31_al0046.png", "FORMAT": "png", "IMAGEDATE": "2024-11-22", "IMAGESIZE": "317.83 KB", "IMAGEWIDTH": 512, "IMAGEHEIGHT": 512 } }</pre>
	어노테이션	<pre>"ANNOTATIONS": [{ "PATIENT": { "AGE": null, "DIAGNOSIS": 3, "REGISTRATIONDATE": "2024-11-29" }, "SHAPES": [{ "CLASS": 3, "POINTS": [[189, 227], [172, 253], [160, 267], [140, 252]], "SHAPE_TYPE": "POLYGON" }], "CAPTION": "This abdominal X-ray image shows the presence of air-fluid level." }]</pre>

● 전체 데이터 확인

번호	file_name	IMAGEDATE	REGISTRATIONDATE	확인 결과
1	31_al0009.json	2024-11-21	2024-11-19	정상
2	31_al00012.json	2024-11-11	2024-11-19	오류
3	31_al0033.json	2024-11-27	2024-11-26	정상
4	31_al0042.json	2024-11-03	2024-11-03	정상
5	31_al0046.json	2024-11-22	2024-11-29	오류
6	31_al0056.json	2024-11-11	2024-11-10	정상
7	31_al0066.json	2024-11-24	2024-11-23	정상
8	31_al0068.json	2024-11-05	2024-11-05	정상
9	31_al0072.json	2024-11-18	2024-11-17	정상
10	31_al0099.json	2024-11-04	2024-11-03	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

● 관계 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 2 / 10
 = 0.80

파일명	구분	내용
		"HEIGHT": 1080, "CAPTION": "9월 맑은 날씨의 낮 바다에 어선 한 척이 지나가는 중이다.", "CLASS": "0", "BBOX": [80, 739, 99, 22], "AREA": 2178 }]
● 관계 유효성 오류 예시		
파일명	구분	내용
B1_1001013.json	메타데이터	{ "META": { "FILENAME": "B1_1001013.jpg", "DATE": "2024-09-29", "TIME": 1, "LOCATION": 2, "SPOT": 13, "SENSOR": 0, "WEATHER": [27.7, 182, 2.6, 0, 1008.7, 1009.6, 60], } }
	어노테이션	"ANNOTATIONS": [{ "FILENAME": "B1_1001009.jpg", "WIDTH": 1920, "HEIGHT": 1080, "CAPTION": "9월 맑은 날씨의 밤 바다에 어선 한 척이 지나가는 중이다.", "CLASS": "0", "BBOX": [83, 729, 90, 20], "AREA": 2178 }]

● 전체 데이터 확인

번호	파일명	메타데이터와 어노테이션의 파일명 일치 여부	확인 결과
1	B1_1001009.json	일치	정상
2	B1_1001010.json	불일치	오류
3	B1_1001011.json	일치	정상
4	B1_1001012.json	일치	정상
5	B1_1001013.json	불일치	오류
6	B1_1001014.json	일치	정상
7	B1_1001015.json	일치	정상
8	B1_1001016.json	일치	정상
9	B1_1001017.json	일치	정상
10	B1_1001018.json	일치	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

● 관계 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 2 / 10
 = 0.80

이미지 예시 3

하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일명, 이미지 높이, 이미지 너비, 파일 사이즈, 기상 정보, 촬영장소, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 지역코드			메타데이터 파일 형식	json
어노테이션	어노테이션 객체 수, 어노테이션 유형(폴리곤), 어노테이션 라벨(산업 구분, 축사 유형, 축사 종류)			어노테이션 파일 형식	

● 속성 간 관계 규칙

대상	속성명		속성 설명	관계 규칙
json 파일	IMAGES	FLG_DE	촬영일시	FLG_DE ≤ CRT_DE
		CRT_DE	수정일시	

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	메타데이터	<pre>{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "CRT_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" } }</pre>

● 관계 유효성 오류 예시

파일명	구분	내용
L01_41220_130_20230831_N11_00661.json	메타데이터	<pre>{ "IMAGES": { "ID": "306845", "FILE_NAME": "L01_41220_130_20230831_N11_00661.tif", "SEQUENCE": "00661", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9406697", "NOR_LATITUDE": "36.6441", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "CRT_DE": "202208301031", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "B011", "CTPRVN_NM": "41220", "LABELCOUNT": "1" } }</pre>

● 전체 데이터 확인

번호	file_name	FLG_DE	CRT_DE	확인 결과
1	L01_11680_65_20231025_N03_00002.json	202308311045	202308311045	정상
2	L01_41220_130_20230831_N11_00661.json	202308311045	202208301031	오류
3	L01_41220_130_20230831_N11_00702.json	202308311045	202308311045	정상
4	L01_41220_130_20230831_N11_00744.json	202308311045	202308311045	정상
5	L01_41220_130_20230831_N11_01117.json	202308311045	202308311045	정상
6	L01_41220_130_20230831_N11_01253.json	202308311045	202308311045	정상
7	L01_41220_130_20230831_N11_01284.json	202308311045	202308311045	정상
8	L01_41220_130_20230831_N11_01288.json	202308311045	202308311045	정상
9	L01_41220_130_20230831_N11_01296.json	202308311045	202308311045	정상
10	L01_41220_130_20230831_N11_01340.json	202308311045	202308311045	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

$$\begin{aligned}
 \text{관계 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 1 / 10 \\
 &= 0.90
 \end{aligned}$$

생성형 예시 1

도로 주행 행동 데이터

● 데이터 구조

데이터 구조	운전자 운전행동 비디오 객체, 주행 환경정보 비디오 객체, 센서 객체, 운전행동 이미지 객체, 객체별 메타데이터와 어노테이션으로 구성된 json 파일		
데이터 수량	10개 (비디오 객체 각 10개, 센서 객체 10개, 이미지 객체 10개, json 파일 10개)		
객체 데이터 유형	비디오 / 센서 / 이미지	객체 데이터 형식	mp4 / json / jpg
메타데이터	파일명, 촬영일, 촬영일시, 날씨 정보, 실도로/테스트도로 구분, 영상 데이터 길이	메타데이터 파일 형식	json
어노테이션	라벨링(영상 데이터 쌍에 포함된 운전 행동, 운전 환경, 운전 행동에 따른 차량의 주요 변화 기록한 텍스트)	어노테이션 파일 형식	

● 관계 유효성이 요구되는 객체 및 속성

대상	속성명		속성 설명	관계 규칙
CAN 데이터 (센서)	sys_time	year	촬영일	모든 객체 및 json 파일에 촬영일 동일 (year.month.day)
		month		
		day		
비디오 객체	촬영 날짜			
이미지 객체	촬영 날짜			
메타데이터	dataset[].date			

● 운전자 운전행동 비디오 객체 확인 : 2024/10/24



● 주행 환경정보 비디오 객체 확인 : 2024/10/24



● 운전자 운전행동 이미지 객체 확인 : 2024/10/24



● CAN 데이터(센서) 확인 : year/month/day = 24/10/24

파일명	구분	내용
A1_ARA_R_37889_CAN.json	CAN 데이터	<pre>{ "frames": [{ "sys_time": { "day": 24, "hour": 3, "minute": 20, "month": 10, "second": 17, "year": 24 } }] }</pre>

● 메타데이터 확인 : 2024.10.24

파일명	구분	내용
A1_ARA_R_37889.json	메타데이터	<pre>{ "dataset": { "title": "A1_ARA_R_37889.json", "date": "2024.10.24", "time": "D", "weather": "Sunny", "scenario": "Real", "length": "00:01:59" }, }</pre>

● 관계 유효성 오류 예시

- 객체(CAN 데이터, 비디오 데이터, 이미지 데이터)와 메타데이터 중 하나라도 촬영일이 일치하지 않아 관계 규칙이 위반된 경우

● 전체 데이터 확인

메타데이터 파일명	메타데이터	운전자 운전행동 비디오	주행 환경정보 비디오	운전자 운전행동 이미지	CAN 데이터	확인 결과
A1_ARA_R_37880.json	2024.10.26	2024/10/26	2024/10/26	2024/10/26	24.10.26	정상
A1_ARA_R_37881.json	2024.10.22	2024/10/20	2024/10/21	2024/10/20	24.10.22	오류
A1_ARA_R_37882.json	2024.10.23	2024/10/23	2024/10/23	2024/10/23	24.10.23	정상
A1_ARA_R_37883.json	2024.10.24	2024/10/24	2024/10/24	2024/10/24	24.10.24	정상
A1_ARA_R_37884.json	2024.10.24	2024/10/24	2024/10/24	2024/10/24	24.10.23	오류
A1_ARA_R_37885.json	2024.10.23	2024/10/23	2024/10/23	2024/10/23	24.10.23	정상
A1_ARA_R_37886.json	2024.10.24	2024/10/24	2024/10/24	2024/10/24	24.10.24	정상
A1_ARA_R_37887.json	2024.10.30	2024/10/30	2024/10/30	2024/10/30	24.10.30	정상
A1_ARA_R_37888.json	2024.10.27	2024/10/27	2024/10/27	2024/10/27	24.10.27	정상
A1_ARA_R_37889.json	2024.10.24	2024/10/24	2024/10/24	2024/10/24	24.10.24	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

- 관계 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
- $$= 1 - 2 / 10$$
- $$= 0.80$$

■ (선택) 데이터 값 정밀성

데이터 값이 명세서에 정의된 정밀도 기준(단위, 자릿수)을 충족하는지 심사하는 항목이다. 예를 들어, 금액 데이터가 소수점 두 자리까지만 표현되었는지를 확인한다.

- ▶ **적용 대상:** 정밀도 기준이 정의된 숫자 데이터
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 정의된 정밀도를 충족하지 못한 데이터 값
 - 진단 데이터: 정밀도가 정의된 데이터 값



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 명세서에 센서 데이터 값이 소수점 셋째 자리까지 요구되는 경우
오류 데이터) 23.45, 45.67
정상 데이터) 23.456, 45.678

예시 2: 명세서에 환율 데이터 값이 소수점 다섯째 자리까지 요구되는 경우
오류 데이터) 1.234, 0.98
정상 데이터) 1.23456, 0.98765

예시 3: 명세서에 거리 데이터 값이 소수점 둘째 자리까지 요구되는 경우
오류 데이터) 123km, 456km
정상 데이터) 123.45km, 456.78km

예시 4: 명세서에 GPS 데이터 값이 소수점 여섯째 자리까지 요구되는 경우
오류 데이터) 37.7749, 122.4194
정상 데이터) 37.774929, 122.419415

예시 5: 명세서에 시간 데이터 값이 밀리초 단위까지 요구되는 경우
오류 데이터) 12:34:56, 01:23:45
정상 데이터) 12:34:56.789, 01:23:45.123

이미지 예시 1

작업 환경 로봇조작 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	PNG	객체 데이터 해상도	640 × 480 이상
메타데이터	원천데이터, 환경, 그리퍼 종류, 작업 종류, 물체 종류, 작업 배경 종류, 이미지 해상도, 촬영 시각			메타데이터 파일 형식	json
어노테이션	각도 데이터, 힘/토크 데이터, 이미지캡션(한국어 설명문)			어노테이션 파일 형식	

● 정밀도가 요구되는 속성

대상	속성명		요구되는 정밀도
json 파일	어노테이션	JOINT_ANGLE	소수점 열다섯 자리까지 표기

● 데이터 세부 내용

파일명	구분	내용
L01_R-K16_r8_1001.json	어노테이션	<pre> { "JOINT_ANGLE": { "JOINT1_ANGLE": 3.085711002349853, "JOINT2_ANGLE": -1.664229532281393, "JOINT3_ANGLE": 1.7270053068744105 }, "FORCE_TORQUE": { "FORCE_DATA_X": 4.696085232188633, "FORCE_DATA_Y": 6.018582042584109, "FORCE_DATA_Z": 12.353520972703096, "TORQUE_DATA_X": 0.217484916218092, "TORQUE_DATA_Y": 0.6419783344215543, "TORQUE_DATA_Z": -0.2682366327565251 }, "DESCRIPTION": { "KOR_DESCRIPTION": "실제 환경의 참치 캔이 있는 노란색 부엌에서 로봇 팔이 음료수 옆에 있는 고등어 통조림 캔을 잡고 끝기 위해 이동하고 있다." } } </pre>

● 데이터 정밀성 오류 예시

파일명	구분	내용
L01_R-K16_r8_1005.json	어노테이션	<pre> { "JOINT_ANGLE": { "JOINT1_ANGLE": 3.085749853, "JOINT2_ANGLE": -1.664393, "JOINT3_ANGLE": 1.7270005 }, "FORCE_TORQUE": { "FORCE_DATA_X": 4.696085232188633, "FORCE_DATA_Y": 6.018582042584109, "FORCE_DATA_Z": 12.353520972703096, "TORQUE_DATA_X": 0.217484916218092, "TORQUE_DATA_Y": 0.6419783344215543, "TORQUE_DATA_Z": -0.2682366327565251 }, "DESCRIPTION": { "KOR_DESCRIPTION": "실제 환경의 참치 캔이 있는 파란색 부엌에서 로봇 팔이 물통 옆에 있는 고기 캔을 잡고 끌기 위해 이동하고 있다." } }</pre>

● 데이터 정밀성 확인 결과

번호	파일명	소수점 열다섯 자리 여부 (O / X)			확인 결과
		JOINT1_ANGLE	JOINT2_ANGLE	JOINT3_ANGLE	
1	L01_R-K16_r8_1001.json	○	○	○	정상
2	L01_R-K16_r8_1002.json	X	X	X	오류
3	L01_R-K16_r8_1003.json	○	○	○	정상
4	L01_R-K16_r8_1004.json	○	○	○	정상
5	L01_R-K16_r8_1005.json	X	X	X	오류
6	L01_R-K16_r8_1006.json	○	○	○	정상
7	L01_R-K16_r8_1007.json	○	○	○	정상
8	L01_R-K16_r8_1008.json	○	X	○	오류
9	L01_R-K16_r8_1009.json	○	○	○	정상
10	L01_R-K16_r8_1010.json	○	○	○	정상

● 진단 총 데이터 수: 30

● 오류 데이터 수: 7

● 데이터 값 정밀성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 7 / 30
 = 0.77

이미지 예시 2

하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일명, 이미지 높이, 이미지 너비, 파일 사이즈, 기상 정보, 촬영장소, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 지역코드			메타데이터 파일 형식	json
어노테이션	어노테이션 객체 수, 어노테이션 유형(폴리곤), 어노테이션 라벨(산업 구분, 축사 유형, 축사 종류)			어노테이션 파일 형식	

● 정밀도가 요구되는 속성

대상	속성명		요구되는 정밀도
json 파일	IMAGES	EST_LONGITUDE	소수점 일곱 자리까지 표기
		NOR_LATITUDE	소수점 일곱 자리까지 표기

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	메타데이터	<pre> { "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" } } </pre>

● 데이터 정밀성 오류 예시

파일명	구분	내용
L01_41220_130_20230831_N11_00661.json	메타데이터	<pre>{ "IMAGES": { "ID": "306845", "FILE_NAME": "L01_41220_130_20230831_N11_00661.tif", "SEQUENCE": "00661", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9406697", "NOR_LATITUDE": "36.6441", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "B011", "CTPRVN_NM": "41220", "LABELCOUNT": "1" } }</pre>

● 데이터 정밀성 확인 결과

번호	file_name	EST_LONGITUDE	NOR_LATITUDE	확인 결과
1	L01_11680_65_20231025_N03_00002.json	128.2640412	37.3616691	정상
2	L01_41220_130_20230831_N11_00661.json	126.9406697	36.6441	오류
3	L01_41220_130_20230831_N11_00702.json	126.9407112	36.6442245	정상
4	L01_41220_130_20230831_N11_00744.json	126.9407685	36.6442245	정상
5	L01_41220_130_20230831_N11_01117.json	126.9411775	36.6444168	정상
6	L01_41220_130_20230831_N11_01253.json	126.9413357	36.6440397	정상
7	L01_41220_130_20230831_N11_01284.json	126.9413585	36.6444412	정상
8	L01_41220_130_20230831_N11_01288.json	126.9413513	36.6443587	정상
9	L01_41220_130_20230831_N11_01296.json	126.9413557	36.6440016	정상
10	L01_41220_130_20230831_N11_01340.json	126.9413958	36.6439261	정상

● 진단 총 데이터 수: 20

● 오류 데이터 수: 1

● 데이터 값 정밀성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 1 / 20
 = 0.95

■ (선택) 데이터 속성 유효성

객체 데이터의 내부 속성(해상도, 채널수, 프레임률, 인코딩, 텍스트 길이, 오디오·영상 길이 등)이 명세서 기준에 적합한지를 심사하는 항목이다. 예를 들어, 해상도, 채널수, 프레임률, 인코딩, 텍스트 길이, 오디오·영상 길이 등이 요구사항을 충족하는지 확인한다.

▶ 비정형 객체 데이터 유형별 데이터 속성 예시

데이터 유형	속성 예시
이미지	밝기, 해상도, 컬러심도, 픽셀당 비트수 등
동영상	해상도, 컬러심도, 프레임레이트, 영상길이 등
오디오	주파수, 재생시간, 평균 데시벨 등
텍스트	어절수, 어휘 개수, 문장 길이, 토큰 수 등

▶ 적용 대상: 비정형 객체의 속성에 대한 기준이 정의된 데이터

▶ 정량화 수식: 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 정의된 기준에 충족되지 않는 비정형 객체 데이터
- 진단 데이터: 속성에 대한 기준이 정의된 비정형 객체 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 이미지 파일의 명세서에 정의된 해상도가 1920×1080인 경우

오류 데이터) 1280×720, 1024×768

정상 데이터) 1920×1080, 2560×1440, 3840×2160

예시 2: 동영상 파일의 프레임 속도가 명세서 기준인 30fps인 경우

오류 데이터) 15fps, 24fps

정상 데이터) 30fps, 48fps, 60fps

예시 3: 오디오 파일의 샘플링 속성이 명세서에서 요구한 44.1kHz인 경우

오류 데이터) 16kHz, 22kHz

정상 데이터) 44.1kHz, 48kHz, 96kHz

예시 4: 동영상 파일의 재생 시간이 명세서에서 요구된 최소 60초인 경우

오류 데이터) 30초, 45초

정상 데이터) 60초, 75초, 90초

예시 5: 텍스트 데이터의 어절 수가 명세서 기준인 100개인 경우

오류 데이터) 50개, 80개

정상 데이터) 100개, 110개, 120개

이미지 예시 1

고해상도 도로노면 이미지 데이터

● 데이터 요약

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (jpg객체 10개, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg	객체 데이터 해상도	2048 × 2048 이상
메타데이터	원시데이터 정보, 승인년도, 저작권, 도로 종류, 촬영 방법, 원천데이터 정보, 이미지 번호, 이미지 폭, 이미지 높이, 원천데이터 파일명			파일 형식	json
어노테이션	원천데이터별 라벨링정보, 어노테이션 식별자, 다중 객체 라벨 시 사용되는 변수, 이미지 번호, 라벨 유형, 세그멘테이션 정보, 바운딩박스 정보, 바운딩박스 전체면적				

● 데이터 속성 기준

대상	속성명	속성 기준
jpg 객체	해상도	2048 × 2048 이상
	픽셀당 비트수	20 이상

● 데이터 속성 확인

이름	날짜	유형	크기	해그	비트 수준	사진 크기
H_A_V_04_0815090338212.jpg	2024-02-01 오전 10:45	JPG 파일	1,615KB		24	2048 × 2048
H_C_F_05_0815090620898.jpg	2024-10-31 오전 11:28	JPG 파일	409KB		24	1620 × 1730
H_C_F_05_0815091300806.jpg	2024-02-01 오전 10:45	JPG 파일	907KB		24	2048 × 2048
H_C_F_05_0815092312304.jpg	2024-02-01 오전 10:45	JPG 파일	641KB		24	2048 × 2048
H_C_V_04_0801093327839.jpg	2024-02-01 오전 10:45	JPG 파일	1,430KB		8	2048 × 2048
H_C_V_04_0801094107823.jpg	2024-02-01 오전 10:45	JPG 파일	1,338KB		8	2048 × 2048
H_C_V_04_0801094511915.jpg	2024-02-01 오전 10:45	JPG 파일	1,456KB		8	2048 × 2048
H_C_V_06_0901083715828.jpg	2024-02-01 오전 10:45	JPG 파일	370KB		24	2048 × 2048
H_C_V_06_0901083952961.jpg	2024-02-01 오전 10:45	JPG 파일	750KB		24	2048 × 2048
H_C_V_06_0901083953261.jpg	2024-02-01 오전 10:45	JPG 파일	750KB		24	2048 × 2048

● 데이터 속성 유효성 확인 결과

번호	객체	해상도	비트 크기	확인 결과
1	H_A_V_04_0815090338212.jpg	2048 × 2048	24	정상
2	H_C_F_05_0815090620898.jpg	1620 × 1730	24	오류
3	H_C_F_05_0815091300806.jpg	2048 × 2048	24	정상
4	H_C_F_05_0815092312304.jpg	2048 × 2048	24	정상
5	H_C_V_04_0801093327839.jpg	2048 × 2048	8	오류
6	H_C_V_04_0801094107823.jpg	2048 × 2048	8	오류
7	H_C_V_04_0801094511915.jpg	2048 × 2048	8	오류
8	H_C_V_06_0901083715828.jpg	2048 × 2048	24	정상
9	H_C_V_06_0901083952961.jpg	2048 × 2048	24	정상
10	H_C_V_06_0901083953261.jpg	2048 × 2048	24	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 4

$$\begin{aligned}
 \text{데이터 속성 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 4 / 10 \\
 &= 0.60
 \end{aligned}$$

오디오 예시 1

감정이 태깅된 자유대화 (청소년)

● 데이터 요약

데이터 구조	오디오 객체, 오디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (wav객체 10개, json 파일 10개)				
객체 데이터 유형	오디오	객체 데이터 형식	wav	재생 길이	10min 이상
메타데이터	파일 정보, 파일명, 파일 길이, 발화 시작점, 발화 끝점, 발화 길이, 원천데이터 정보, 주파수, 비트수, 인코딩방식, 채널수			파일 형식	json
어노테이션	소음 정보, 실내/실외 환경 종류, 녹음 장소, SNR, 실내/실외 환경 종류, 녹음 장소, SNR, 참여자 정보, 발화자 고유 번호, 청소년 구분, 연령, 성별, 거주지, 직업, 목상태, 마스크 착용 유/무, 녹음 장치, 참여자 정보, 발화자 고유 번호, 청소년 구분, 연령, 성별, 거주지, 직업, 목상태, 마스크 착용 유/무, 녹음 장치, 대화정보, 대화 도메인, 대화 토픽, 대화 토픽, 대화내용, 대화 순서 번호, 발화자 구분, 감정 유형, 감정 상태, 감정 정도, 감정 대상, 감정 유형, 감정 상태, 감정 정도, 감정 대상, Text 전사내용, 대화 시작시간, 대화 끝 시간				

● 데이터 속성 기준

대상	속성명	속성 기준
wav 객체	재생 길이	10분 이상
	비트 전송률	512kbps 이상

● 데이터 속성 확인

이름	길이	비트 전송률
1_A627G2A1_A629G2A1_T2_1D09T0384C000358_047277.wav	00:15:03	512kbps
1_A633G2A1_A632G2A1_T2_1D02T0058C000219_047180.wav	00:11:09	512kbps
1_A635G1A1_A634G1A1_T2_1D09T0393C000742_047104.wav	00:22:29	512kbps
1_A639G1A1_A640G1A1_T2_1D09T0386C000477_047315.wav	00:16:12	512kbps
1_A640G1A1_A639G1A1_T2_1D09T0379C000468_047145.wav	00:18:03	512kbps
1_A640G1A1_A639G1A1_T2_1D10T0429C000446_047116.wav	00:17:55	512kbps
1_A642G1A1_A643G1A1_T2_1D10T0420C000310_047910.wav	00:20:16	512kbps
1_A644G1A1_A651G1A1_T2_1D03T0097C000065_048026.wav	00:03:12	512kbps
1_A651G1A1_A644G1A1_T2_1D04T0151C000360_047128.wav	00:20:32	512kbps
1_A651G1A1_A644G1A1_T2_1D09T0360C000310_047154.wav	00:01:03	512kbps

● 데이터 유효성 확인 결과

번호	객체	길이	비트 전송률	확인 결과
1	1_A627G2A1_A629G2A1_T2_1D09T0384C000358_047277.wav	15min	512	정상
2	1_A633G2A1_A632G2A1_T2_1D02T0058C000219_047180.wav	11min	24	정상
3	1_A635G1A1_A634G1A1_T2_1D09T0393C000742_047104.wav	22min	24	정상
4	1_A639G1A1_A640G1A1_T2_1D09T0386C000477_047315.wav	16min	24	정상
5	1_A640G1A1_A639G1A1_T2_1D09T0379C000468_047145.wav	18min	24	정상
6	1_A640G1A1_A639G1A1_T2_1D10T0429C000446_047116.wav	17min	24	정상
7	1_A642G1A1_A643G1A1_T2_1D10T0420C000310_047910.wav	20min	24	정상
8	1_A644G1A1_A651G1A1_T2_1D03T0097C000065_048026.wav	3min	24	오류
9	1_A651G1A1_A644G1A1_T2_1D04T0151C000360_047128.wav	20min	24	정상
10	1_A651G1A1_A644G1A1_T2_1D09T0360C000310_047154.wav	1min	24	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

● 데이터 속성 유효성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 2 / 10$
 $= 0.80$

비디오 예시 1

한국 씨름 동작 데이터

● 데이터 요약

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	2개 (mp4 객체 2개, json 파일 2개)				
객체 데이터 유형	비디오	객체 데이터 형식	MP4	재생 길이	1min 이상
메타데이터	비디오 구간, 어노테이션 정보, 비디오 구간, 어노테이션 아이디, 비디오 구간 시작점, 비디오 구간 끝점, 비디오 구간, 분류 아이디, 비디오 구간 분류, 비디오 세부, 구간 리스트, 비디오 세부, 구간 시작점, 비디오 세부, 구간 끝점, 비디오 세부, 구간 분류			파일 형식	json
어노테이션	비디오 구간, 어노테이션 정보, 비디오 구간, 어노테이션 아이디, 비디오 구간 시작점, 비디오 구간 끝점, 비디오 구간, 분류 아이디, 비디오 구간 분류, 공격 선수 아이디, 공격 선수 설명, 승자 선수 아이디, 승자 선수 설명, 비디오 세부, 구간 리스트, 비디오 세부, 구간 시작점, 비디오 세부, 구간 끝점, 비디오 세부, 구간 분류				

● 데이터 속성 기준

대상	속성명	속성 기준
mp4 객체	재생 길이	1분 이상
	프레임 속도	20프레임 이상

● 데이터 속성 확인

이름	길이	프레임 속도
150101_15설특집활성전국여자장사씨름대회_통합_16강.mp4	00:05:10	29.00 프레임/초
150101_2015 제6회 국민생활체육회장배 산청 전국장사 씨름대회_단체전준결승.mp4	00:00:03	23.99 프레임/초

● 데이터 속성 유효성 확인 결과

번호	객체	재생 길이	프레임 속도	확인 결과
1	150101_전국장사_씨름대회_통합_16강.mp4	5min	29	정상
2	150101_전국장사_씨름대회_단체전준결승.mp4	3s	23.99	오류

● 진단 총 데이터 수: 2

● 오류 데이터 수: 1

$$\begin{aligned}
 \text{데이터 속성 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 1 / 2 \\
 &= 0.50
 \end{aligned}$$

텍스트 예시 1

문서 OCR 데이터

● 데이터 요약

데이터 구조	텍스트 객체, 텍스트 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	2개 (docx 객체 2개, json 파일 2개)				
객체 데이터 유형	텍스트	객체 데이터 형식	docx	페이지 수	5 이상
메타데이터	데이터셋 정보, 데이터셋 명칭, 데이터셋 버전, 데이터셋 생성년도, 카테고리 정보, 카테고리 아이디, 카테고리 대분류, 페이지 수, 단어 수, 문자 수, 줄 수, 단락 수			파일 형식	json
어노테이션	어노테이션 정보, 어노테이션 아이디, 분야 분류				

● 데이터 속성 기준

대상	속성명	속성 기준
docx 객체	단어 수	300 이상
	페이지 수	5 이상

● 데이터 속성 확인

이름	단어 수	페이지
file_1.docx	701	21
file_2.docx	229	6

● 데이터 속성 유효성 확인 결과

번호	객체	단어 수	페이지 수	확인 결과
1	file_1.docx	701	21	정상
2	file_2.docx	229	6	오류

● 진단 총 데이터 수: 2

● 오류 데이터 수: 1

$$\begin{aligned}
 \text{데이터 속성 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 1 / 2 \\
 &= 0.50
 \end{aligned}$$

● (선택) 범위 유효성

메타데이터 및 어노테이션 데이터 내의 속성 값이 명세서에서 정의한 허용 범위에 포함되는지 심사하는 항목이다. 예를 들어, 나이 데이터가 0~120 사이인지 검증한다.

- ▶ **적용 대상:** 값의 범위가 정의된 메타데이터와 어노테이션
- ▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수
 - 오류 데이터: 값이 정의된 범위 안에 포함되지 않은 데이터
 - 진단 데이터: 값 범위가 정의된 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 바운딩 박스의 좌표 값이 이미지 크기 1920×1080 범위 내에 있어야 하는 경우

오류 데이터) [x: 1950, y: 1100]

정상 데이터) [x: 1920, y: 1080]

예시 2: 오디오 파일의 샘플 레이트가 44.1kHz 이상이어야 하는 경우

오류 데이터) [22kHz]

정상 데이터) [44.1kHz]

예시 3: 동영상 내 객체의 시간 범위가 전체 동영상 길이 60초 내에 설정되어야 하는 경우

오류 데이터) [start_time: 65초, end_time: 70초]

정상 데이터) [start_time: 10초, end_time: 50초]

예시 4: 오디오 데이터의 평균 데시벨이 -10dB ~ 10dB 범위 내에 있어야 하는 경우

오류 데이터) [-20dB]

정상 데이터) [9dB]

예시 5: GPS 데이터에서 경도 값이 -180° ~ 180° 범위 내에 있어야 하는 경우

오류 데이터) [200°]

정상 데이터) [170°]

이미지 예시 1

대기오염 영향요인 공간 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	JPG	객체 데이터 해상도	512 × 512 이상
메타데이터	이미지 고유 식별자, 이미지 높이, 이미지 너비, 해상도, 촬영 시각, 데이터 제공 기관, 사업/총괄 기관명			메타데이터 파일 형식	json
어노테이션	바운딩박스(굴뚝탐지), 이미지 파일명, 파일 크기, 객체 모양 정보(X좌표, Y좌표, 너비, 높이)			어노테이션 파일 형식	

● 속성값 요구 범위

대상	속성명		요구 범위
json 파일	어노테이션	REGIONS[].X, REGIONS[].Y	512×512 범위 내

● 데이터 세부 내용

파일명	구분	내용
K201337_8. json	어노테이션	<pre>{ "K201337_8": { "FILENAME": "K201337_8.jpg", "SIZE": 70172, "REGIONS": [{ "SHAPE_ATTRIBUTES": { "NAME": "rect", "X": 336, "Y": 280, "WIDTH": 45, "HEIGHT": 100 }, "REGION_ATTRIBUTES": { "CHI_ID": "1" } }], } }</pre>

● 범위 유효성 오류 예시

파일명	구분	내용
K201337_4.json	어노테이션	<pre>{ "K201337_4": { "FILENAME": "K201337_4.jpg", "SIZE": 70174, "REGIONS": [{ "SHAPE_ATTRIBUTES": { "NAME": "rect", "X": 516, "Y": 280, "WIDTH": 50, "HEIGHT": 100 }, "REGION_ATTRIBUTES": { "CHI_ID": "2" } }] }, }</pre>

● 범위 유효성 확인 결과

번호	파일명	X 값	Y 값	확인 결과
1	K201337_1.json	352	210	정상
2	K201337_2.json	423	122	정상
3	K201337_3.json	233	132	정상
4	K201337_4.json	516	280	오류
5	K201337_5.json	233	120	정상
6	K201337_6.json	243	321	정상
7	K201337_7.json	260	210	정상
8	K201337_8.json	336	280	정상
9	K201337_9.json	624	323	오류
10	K201337_10.json	240	270	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

$$\begin{aligned}
 \text{범위 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 2 / 10 \\
 &= 0.80
 \end{aligned}$$

이미지 예시 2

고해상도 도로노면 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (jpg 객체 10개, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg	객체 데이터 해상도	2000 × 2000 이상
메타데이터	원시데이터 정보, 승인년도, 저작권, 도로 종류, 촬영 방법, 원천데이터 정보, 이미지 번호, 이미지 폭, 이미지 높이, 원천데이터 파일명			파일 형식	json
어노테이션	원천데이터별 라벨링정보, 어노테이션 식별자, 다중 객체 라벨 시 사용되는 변수, 이미지 번호, 라벨 유형, 세그멘테이션 정보, 바운딩박스 정보, 바운딩박스 전체면적				

● 속성값 요구 범위

대상	속성명		요구 범위
json 파일	annotations	area	2,000 < area < 3,000,000

● 데이터 세부 내용

파일명	구분	내용
H_A_V_04_0815090338212.json	어노테이션	<pre> "annotations": [{ "id": 1, "iscrowd": 0, "image_id": 1, "category_id": 15, "segmentation": [74.18, 2048.0, 1963.79, 1, 1790.6, 0.0, 2048.0], "bbox": [0.0, 0.0, 82.13, 2048.0], "area": 168202.24 }] </pre>

● 범위 유효성 오류 예시

파일명	구분	내용
H_C_V_06_0901083952961.json	어노테이션	<pre> "annotations": [{ "id": 1, "iscrowd": 0, "image_id": 1, "category_id": 3, "bbox": [40.7, 0.0, 102.42, 1013.53], "area": 1371.886500000002 }] </pre>

● 범위 유효성 확인 결과

번호	파일명	area 값	확인 결과
1	H_A_V_04_0815090338212.json	168202.24	정상
2	H_C_F_05_0815090620898.json	6762.9276000000002	정상
3	H_C_F_05_0815091300806.json	88741.728500000008	정상
4	H_C_F_05_0815092312304.json	14473.6400000000016	정상
5	H_C_V_04_0801093327839.json	112163.213799999994	정상
6	H_C_V_04_0801094107823.json	2330828.80000000003	정상
7	H_C_V_04_0801094511915.json	257519.591999999998	정상
8	H_C_V_06_0901083715828.json	353978.48699999998	정상
9	H_C_V_06_0901083952961.json	1371.886500000002	오류
10	H_C_V_06_0901083953261.json	98741.72500100008	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

$$\begin{aligned}
 \text{범위 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 1 / 10 \\
 &= 0.90
 \end{aligned}$$

생성형 예시 1

국내 문화 영상 이해 데이터

● 데이터 구조

데이터 구조	비디오 객체, 이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, 비디오 객체 10개, json 파일 10개)				
객체 데이터 유형	비디오 / 이미지	객체 데이터 형식	MP4 / PNG	객체 데이터 해상도	1280 × 720 이상
메타데이터	이미지 번호, 이미지 픽셀 크기, 이미지 픽셀 밀도, 이미지 심도, 이미지 분류, 영상 번호, 영상 내 프레임 타임 코드, 영상 초당 프레임 송출, 영상 분류			메타데이터 파일 형식	json
어노테이션	캡셔닝 데이터(이미지 영문 설명, 국문 설명, 국문 캡션 어절 수 총합, 영문 캡션 어절 수 총합)			어노테이션 파일 형식	

※ 비디오는 원천 데이터 참고 영상임. 이미지만 학습 데이터로 사용.

● 속성값 요구 범위

대상	속성명		요구 범위
어노테이션	context	total_words_ko (국문 캡션 어절 수 총합)	15 < total_words_ko < 999
		total_words_en (영문 캡션 어절 수 총합)	15 < total_words_en < 999

● 데이터 세부 내용

파일명	구분	내용
K_tt_0046.png	객체 데이터	
K_tt_0046.json	어노테이션	<pre> "context": { "caption_ko_1": "옛날 디자인의 자동차 한 대와 요즘 디자인의 자동차 한 대가 있습니다.", "caption_ko_2": "검은 자동차의 바퀴에는 스포크가 많이 보이고, 차체 앞면의 라이트는 따로따로 달려 있습니다.", "caption_ko_3": "붉은 빛의 자동차는 라이트가 두 개씩 붙어 있고, 와이퍼가 눈에 띄지 않습니다." } </pre>

파일명	구분	내용
		"caption_en_1": "Its vibrant red color captivates attention while zooming forward on a blurred background giving the impression of rapid movement.", "caption_en_2": "The upper section displays the design of an older model car.", "caption_en_3": "It has a rectangular body with round headlights on each side of the front grille.", "total_words_ko": 34, "total_words_en": 43 }

● 범위 유효성 오류 예시

파일명	구분	내용
K_tt_0042.json	어노테이션	"context": { "caption_ko_1": "빨간 자동차가 빠르게 움직입니다.", "caption_ko_2": "오래된 자동차가 보입니다.", "caption_ko_3": "라이트가 둥글습니다.", "caption_en_1": "A red car moves fast.", "caption_en_2": "An old car is shown.", "caption_en_3": "It has round lights.", "total_words_ko": 9, "total_words_en": 14 }

● 전체 데이터 확인

번호	파일명	total_words_ko	total_words_en	확인 결과
1	K_tt_0041.json	866	43	정상
2	K_tt_0042.json	9	14	오류
3	K_tt_0043.json	56	67	정상
4	K_tt_0044.json	24	22	정상
5	K_tt_0045.json	67	76	정상
6	K_tt_0046.json	34	43	정상
7	K_tt_0047.json	77	65	정상
8	K_tt_0048.json	882	914	정상
9	K_tt_0049.json	991	1012	오류
10	K_tt_0050.json	43	47	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

● 범위 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 2 / 10$$

$$= 0.80$$

생성형 예시 2

교육용 멀티미디어 데이터

● 데이터 구조

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (비디오 객체 10장, json 파일 10개)				
객체 데이터 유형	비디오	객체 데이터 형식	mp4	객체 데이터 해상도	1500 × 900 이상
메타데이터	동영상 파일 이름, 동영상 길이 정보, 해상도, 초당 프레임 정보, 발화자 수, 강의 환경 정보, 학교급 정보, 교과 과목 정보, 강의 주제, 핵심 키워드			메타데이터 파일 형식	json
어노테이션	동영상 스크립트, 캡션, 발화가 시작하는 시작 시간, 발화가 끝나는 종료 시간			어노테이션 파일 형식	

● 속성값 요구 범위

대상	속성명	요구 범위
메타데이터	video_length	3분 <= video_length

● 데이터 세부 내용

파일명	구분	내용
kp00_141.json	메타데이터	<pre>{ "video": { "file_name": "kp00_141.mp4", "video_length": "00:03:25", "resolution": "1500x900", "framerate": 20, "speaker_num": 1, "location_info": "ppt", "school_level": "초등", "domain": "국어", "topic": "주요 내용을 확인하고 자신의 생각 말하기", "keywords": ["주요 내용 파악", "글쓴이 생각"] }, }</pre>

● 범위 유효성 오류 예시

파일명	구분	내용
kp00_149.json	메타데이터	<pre>{ "video": { "file_name": "kp00_149.mp4", "video_length": "00:02:25", "resolution": "1500x900", "framerate": 20, "speaker_num": 1, }, }</pre>

파일명	구분	내용
		<pre> "location_info": "ppt", "school_level": "초등", "domain": "국어", "topic": "주요 내용을 확인하고 자신의 생각 말하기", "keywords": ["주요 내용 파악", "글쓴이 생각",] </pre>

● 전체 데이터 확인

번호	파일명	video_length	확인 결과
1	kp00_141.json	00:03:25	정상
2	kp00_142.json	00:01:25	오류
3	kp00_143.json	00:03:25	정상
4	kp00_144.json	00:04:27	정상
5	kp00_145.json	00:03:48	정상
6	kp00_146.json	00:03:05	정상
7	kp00_147.json	00:03:45	정상
8	kp00_148.json	00:04:28	정상
9	kp00_149.json	00:02:25	오류
10	kp00_150.json	00:06:25	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

● 범위 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 2 / 10
 = 0.80

■ (선택) 시간 유효성

데이터 생성 또는 수집 시간이 명세서에 정의된 기준 시간을 만족하는지를 심사하는 항목이다. 예를 들어, 객체 데이터가 명세서에 정의된 기간 내에 수집되었는지를 심사한다.

▶ **적용 대상:** 수집/생성 시간이 정의된 비정형 객체 데이터

▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$

- 오류 데이터: 명세서에 정의된 기준 시간 범위를 벗어난 객체 데이터
- 진단 데이터: 수집/생성 시간이 명세서에 정의된 객체 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 데이터가 2023년 이후에 생성되어야 하는 경우

오류 데이터) 데이터가 2023년 이후에 생성되었어야 하나, 2022년에 생성됨
정상 데이터) 데이터가 2023년 이후에 생성되어 명세서 기준을 충족함

예시 2: 센서 데이터가 실시간으로 수집되어야 하는 경우

오류 데이터) 센서 데이터가 실시간으로 수집되어야 하지만, 1시간 전에 수집된 데이터가 포함됨
정상 데이터) 센서 데이터가 실시간으로 수집되어 명세서 기준을 충족함

예시 3: 동영상 데이터가 2024년 1분기 내에 수집되어야 하는 경우

오류 데이터) 동영상 수집 시간이 2024년 1분기로 제한되어 있는데, 2023년 12월로 기록됨
정상 데이터) 동영상 데이터가 2024년 1분기 내에 수집되어 명세서 기준을 충족함

예시 4: 동영상 데이터의 수집 시간이 명세서에서 정의한 주간(9:00~18:00) 시간대에 포함
되어야 하는 경우

오류 데이터) 동영상 데이터의 수집 시간이 야간(22:00)에 수집됨
정상 데이터) 동영상 데이터의 수집 시간이 명세서에서 정의한 주간(9:00~18:00) 시간대에 포함됨

예시 5: 센서 로그 데이터가 매 분 단위로 기록되어야 하는 경우

오류 데이터) 센서 로그 데이터가 매 분 단위로 기록되어야 하나, 10분 단위로 수집됨
정상 데이터) 센서 로그 데이터가 매 분 단위로 기록되어 명세서 기준에 맞음

이미지 예시 1

고해상도 도로노면 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (jpg 객체 10개, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg	객체 데이터 해상도	2000 × 2000 이상
메타데이터	원시데이터 정보, 승인년도, 저작권, 도로 종류, 촬영 방법, 원천데이터 정보, 이미지 번호, 이미지 폭, 이미지 높이, 원천데이터 파일명			파일 형식	json
어노테이션	원천데이터별 라벨링정보, 어노테이션 식별자, 다중 객체 라벨 시 사용되는 변수, 이미지 번호, 라벨 유형, 세그멘테이션 정보, 바운딩박스 정보, 바운딩박스 전체면적				

● 비정형 객체 데이터 기준 시간

대상	생성 시간
jpg 객체	2024년 10월 20일 이후

● 데이터 생성 시간 확인

이름	만든 날짜	유형	크기	태그
H_A_V_04_0815090338212.jpg	2024-10-17 오전 10:42	JPG 파일	1,615KB	
H_C_F_05_0815090620898.jpg	2024-10-31 오전 11:23	JPG 파일	741KB	
H_C_F_05_0815091300806.jpg	2024-10-31 오전 11:23	JPG 파일	907KB	
H_C_F_05_0815092312304.jpg	2024-10-31 오전 11:23	JPG 파일	641KB	
H_C_V_04_0801093327839.jpg	2024-10-31 오전 11:23	JPG 파일	1,430KB	
H_C_V_04_0801094107823.jpg	2024-10-31 오전 11:23	JPG 파일	1,538KB	
H_C_V_04_0801094511915.jpg	2024-10-31 오전 11:23	JPG 파일	1,436KB	
H_C_V_06_0901083715828.jpg	2024-10-31 오전 11:24	JPG 파일	370KB	
H_C_V_06_0901083952961.jpg	2024-10-17 오전 10:42	JPG 파일	750KB	
H_C_V_06_0901083953261.jpg	2024-10-31 오전 11:24	JPG 파일	750KB	

● 시간 유효성 확인 결과

번호	객체	만든 날짜	확인 결과
1	H_A_V_04_0815090338212.jpg	2024년 10월 17일	오류
2	H_C_F_05_0815090620898.jpg	2024년 10월 31일	정상
3	H_C_F_05_0815091300806.jpg	2024년 10월 31일	정상
4	H_C_F_05_0815092312304.jpg	2024년 10월 31일	정상
5	H_C_V_04_0801093327839.jpg	2024년 10월 31일	정상
6	H_C_V_04_0801094107823.jpg	2024년 10월 31일	정상
7	H_C_V_04_0801094511915.jpg	2024년 10월 31일	정상
8	H_C_V_06_0901083715828.jpg	2024년 10월 31일	정상
9	H_C_V_06_0901083952961.jpg	2024년 10월 17일	오류
10	H_C_V_06_0901083953261.jpg	2024년 10월 31일	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

● 시간 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 2 / 10$$

$$= 0.80$$

오디오 예시 1

통화 내용 요약 데이터

● 데이터 구조

데이터 구조	오디오 객체, 오디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (m4a 객체 10개, json 파일 10개)				
객체 데이터 유형	오디오	객체 데이터 형식	m4a	재생 길이	5 s 이상
메타데이터	파일 정보, 파일명, 통화 길이, 원천데이터 정보, 녹음 날짜			파일 형식	json
어노테이션	소음 정보, 실내/실외 환경 종류, Text 전사내용, 대화 시작시간, 대화 끝 시간				

● 비정형 객체 데이터 기준 시간

대상	녹음 시간
m4a 객체	2024년 4월 01일 이후

● 데이터 생성 시간 확인

이름	미디어 작성 날짜	길이
통화 녹음 240320_101054.m4a	2024-03-20 오전 10:11	00:01:00
통화 녹음 240322_175919.m4a	2024-03-22 오후 5:59	00:00:07
통화 녹음 240327_182414.m4a	2024-03-27 오후 6:24	00:00:37
통화 녹음 240402_064715.m4a	2024-04-02 오전 6:47	00:00:15
통화 녹음 240428_111030.m4a	2024-04-28 오전 11:10	00:00:24
통화 녹음 240502_090337.m4a	2024-05-02 오전 9:04	00:00:27
통화 녹음 240502_153638.m4a	2024-05-02 오후 3:36	00:00:07
통화 녹음 240504_202928.m4a	2024-05-04 오후 8:30	00:00:53
통화 녹음 241026_134918.m4a	2024-10-26 오후 1:49	00:00:40
통화 녹음 241026_150253.m4a	2024-10-26 오후 3:03	00:01:01

● 시간 유효성 확인 결과

번호	객체	만든 날짜	확인 결과
1	통화 녹음 240320_101054.m4a	2024년 03월 20일	오류
2	통화 녹음 240322_175919.m4a	2024년 03월 22일	오류
3	통화 녹음 240327_182414.m4a	2024년 03월 27일	오류
4	통화 녹음 240402_064715.m4a	2024년 04월 02일	정상
5	통화 녹음 240428_111030.m4a	2024년 04월 28일	정상
6	통화 녹음 240502_090337.m4a	2024년 05월 02일	정상
7	통화 녹음 240502_153638.m4a	2024년 05월 02일	정상
8	통화 녹음 240504_202928.m4a	2024년 05월 04일	정상
9	통화 녹음 241026_134918.m4a	2024년 10월 26일	정상
10	통화 녹음 241026_150253.m4a	2024년 10월 26일	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 3

$$\begin{aligned}
 \text{시간 유효성} &= 1 - \text{객체 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 3 / 10 \\
 &= 0.70
 \end{aligned}$$

텍스트 예시 1

초거대 AI 헬스케어 질의응답 데이터

● 데이터 구조

데이터 구조	텍스트 객체, 텍스트 객체별 메타데이터와 어노테이션으로 구성된 json 파일		
데이터 수량	2개 (json 객체 2개, json 파일 2개)		
객체 데이터 유형	텍스트	객체 데이터 형식	json
메타데이터	파일명, 생성 시간,	파일 형식	json
어노테이션	질환 분류, 참여자 성별, 참여자 나이, 참여자 직업, 과거병력유무, 현 거주지, 한글 질환명, 영어 질환명, 질문 의도, 질문 문장, 엔티티 id, 엔티티 텍스트, 엔티티 값, 엔티티 텍스트 시작 위치, 질문 문장 어절 수, 진료과, 본론, 결론, 답변 문장 어절 수		

● 비정형 객체 데이터 기준 시간

대상	생성 시간	수정 시간
json 객체	2024년 10월 24일 이후	2024년 04월 01일 이전

● 데이터 생성 시간 확인

이름	만든 날짜	수정한 날짜	유형	크기
HC-A-03614230.json	2024-11-01 오후 4:38	2024-03-26 오전 11:15	JSON 파일	2KB
HC-Q-1160428.json	2024-11-01 오후 4:38	2024-11-21 오후 7:41	JSON 파일	1KB

● 시간 유효성 확인 결과

번호	객체	생성 시간	수정 시간	확인 결과
1	HC-A-03614230.json	2024년 11월 01일	2024년 03월 26일	정상
2	HC-Q-1160428.json	2024년 11월 01일	2024년 11월 21일	오류

● 진단 총 데이터 수: 2

● 오류 데이터 수: 1

$$\begin{aligned}
 \text{시간 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 1 / 2 \\
 &= 0.50
 \end{aligned}$$

● (선택) 어노테이션 유효성

어노테이션이 명세서에 정의된 기준(형식, 구조, 인코딩, 시간 정렬, 내용 건전성 등)을 만족하는지를 심사하는 항목이다. 예를 들어, 라벨링된 객체의 위치 정보가 이미지 사이즈 안에 존재하는 좌표인지 확인하고 어노테이션 파일이 지정된 형식과 구조를 따르는지, 객체데이터와 시간·프레임 단위로 정렬되어 있는지 또는 어노테이션 내용에 혐오·비하·욕설·차별 등 유해 표현이 포함되지 않았는지 확인한다.

▶ **적용 대상:** 데이터 명세서에 유효성 기준이 정의된 어노테이션

▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$

- 오류 데이터: 어노테이션 값이 기준(예: 바운딩박스 크기, 정해진 카테고리 또는 라벨링 기준 등)을 만족하지 않는 어노테이션 데이터
- 진단 데이터: 기준이 정의된 어노테이션 데이터



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 바운딩박스 크기가 객체 전체를 정확히 포함해야 하는 경우

오류 데이터) 바운딩박스 크기가 객체보다 지나치게 작아 객체 일부가 잘림

정상 데이터) 바운딩박스 크기가 객체 전체를 정확히 포함하여 명세서 기준을 충족함

예시 2: 어노테이션 라벨이 명세서에 정의된 카테고리("Cat", "Dog") 내에서 지정되어야 하는 경우

오류 데이터) 라벨링 기준에서 정의된 카테고리("Cat", "Dog")에 포함되지 않는 값 ("Animal")으로 라벨링됨

정상 데이터) 어노테이션 라벨이 명세서에 정의된 카테고리("Cat", "Dog") 내에서 지정됨

예시 3: 동영상 데이터에서 프레임 내 객체의 바운딩박스 위치가 화면 경계 내에 있어야 하는 경우

오류 데이터) 프레임 내 객체의 바운딩박스 위치가 화면 경계를 벗어남

정상 데이터) 프레임 내 객체의 바운딩박스 위치가 화면 경계 내에 정확히 설정됨

예시 4: 바운딩박스 크기가 명세서에서 요구한 최소 크기(예: 20×20 픽셀)를 충족해야 하는 경우

오류 데이터) 바운딩박스 크기가 명세서에서 요구한 최소 크기(예: 20×20 픽셀)보다 작음

정상 데이터) 바운딩박스 크기가 명세서에서 요구한 최소 크기(예: 20×20 픽셀)를 충족함

예시 5: 어노테이션 데이터의 좌표 값이 명세서에 정의된 양수 범위 내에 저장되어야 하는 경우

오류 데이터) 어노테이션 데이터의 좌표 값이 음수로 저장됨

정상 데이터) 어노테이션 데이터의 좌표 값이 명세서에 정의된 양수 범위 내에 저장됨

이미지 예시 1

하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일명, 이미지 높이, 이미지 너비, 파일 사이즈, 기상 정보, 촬영장소, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 지역코드			메타데이터 파일 형식	json
어노테이션	어노테이션 객체 수, 어노테이션 유형(폴리곤), 어노테이션 라벨(산업 구분, 축사 유형, 축사 종류)			어노테이션 파일 형식	

● 속성값 기준

대상	속성명		기준
json 파일	ANNOTATIONS	DRAWING	polygon
		SEGMENTATION	각 점의 좌표가 0 이상 512 이하
		CATEGORY_2	과수원, 비닐하우스, 축사

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	어노테이션	<pre> "ANNOTATIONS": [{ "DRAWING": "polygon", "SEGMENTATION": [0, 0, 0, 512, 512, 512, 512, 0, 175, 0], "CATEGORY_1": "농업계", "CATEGORY_2": "과수원", "CATEGORY_3": "해당없음" }] </pre>

● 오류 데이터 예시

파일명	구분	내용
L01_11680_65_20231025_N03_00002.json	어노테이션	<pre> "ANNOTATIONS": [{ "DRAWING": "bbox", "SEGMENTATION": [0, 0, 0, 512, 512, 512, 512, 0, 175, 0], "CATEGORY_1": "농업계", "CATEGORY_2": "비닐하우스", "CATEGORY_3": "해당없음" }] </pre>
L01_41220_	어노테이션	<pre> "ANNOTATIONS": [{ </pre>

파일명	구분	내용
130_20230831_N11_00661.json		<pre> "DRAWING": "polygon", "SEGMENTATION": [0, 0, -1, 512, 512, 512, 0, 175, 0], "CATEGORY_1": "농업계", "CATEGORY_2": "축사", "CATEGORY_3": "해당없음" </pre>
L01_41220_130_20230831_N11_01296.json	어노테이션	<pre> "ANNOTATIONS": [{ "DRAWING": "polygon", "SEGMENTATION": [0, 0, 0, 512, 512, 512, 0, 175, 0], "CATEGORY_1": "농업계", "CATEGORY_2": "동물원", "CATEGORY_3": "해당없음" }] </pre>

● 전체 데이터 확인

번호	file_name	DRAWING	SEGMENTATION	CATEGORY_2	확인 결과
1	L01_11680_65_20231025_N03_00002.json	bbox	0, 0, 0, 512, 512, 512, 512, 0, 175, 0	비닐하우스	오류
2	L01_41220_130_20230831_N11_00661.json	polygon	0, 0, -1, 512, 512, 512, 512, 0, 175, 0	축사	오류
3	L01_41220_130_20230831_N11_00702.json	polygon	0, 0, 0, 512, 512, 512, 512, 0, 175, 0	과수원	정상
4	L01_41220_130_20230831_N11_00744.json	polygon	0, 0, 0, 512, 512, 512, 512, 0, 175, 0	비닐하우스	정상
5	L01_41220_130_20230831_N11_01117.json	polygon	0, 0, 0, 512, 512, 512, 512, 0, 175, 0	축사	정상
6	L01_41220_130_20230831_N11_01253.json	polygon	0, 0, 0, 512, 512, 512, 512, 0, 175, 0	축사	정상
7	L01_41220_130_20230831_N11_01284.json	polygon	0, 0, 0, 512, 512, 512, 512, 0, 175, 0	비닐하우스	정상
8	L01_41220_130_20230831_N11_01288.json	polygon	0, 0, 0, 512, 512, 512, 512, 0, 175, 0	과수원	정상
9	L01_41220_130_20230831_N11_01296.json	polygon	0, 0, 0, 512, 512, 512, 512, 0, 175, 0	동물원	오류
10	L01_41220_130_20230831_N11_01340.json	polygon	0, 0, 0, 512, 512, 512, 512, 0, 175, 0	과수원	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 3

$$\begin{aligned}
 \text{어노테이션 유효성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 3 / 10 \\
 &= 0.70
 \end{aligned}$$

비디오 예시 1

특이 도로 환경 주행 데이터

● 데이터 구조

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (동영상 객체 10개, json 파일 10개)				
객체 데이터 유형	비디오	객체 데이터 형식	mp4	객체 데이터 해상도	512 × 512 이상
메타데이터	비디오ID, 촬영일시, 촬영장비, 촬영방식, 파일형식, 사진크기, 비트, ISO, 카메라 번호, 비디오 길이			메타데이터 파일 형식	json
어노테이션	비디오 구간 어노테이션 아이디, 비디오 구간 시작점, 비디오 구간 끝점, 비디오 구간 분류 아이디, 비디오 구간 분류, 장소유형 클래스, 정척객체 클래스, 라벨 타입			어노테이션 파일 형식	

● 속성값 기준

대상	속성명	기준
json 파일	class	흙/진흙, 자갈, 잔디, 시멘트
	장소 유형	산악, 농경, 해안, 복합
	label_type	segmentation, bounding box

● 데이터 세부 내용

파일명	구분	내용
4_1_1_0904 1703_00000 0007.mp4	객체 데이터	
4_1_1_0904 1703_00000 0007.mp4.json	어노테이션	<pre>"annotations": [{ "장소유형": "산악", "class": "흙/진흙", "label_type": "segmentation" }]</pre>

● 오류 데이터 예시

파일명	구분	내용
4_1_1_0904 1703_00000 00011.json	어노테이션	<pre>"annotations": [{ "장소유형": "잔디", "class": "시멘트", "label_type": "segmentation", }]</pre>

● 전체 데이터 확인

번호	객체	장소 유형	확인 결과
1	4_1_1_09041703_0000000000.mp4	해안	정상
2	4_1_1_09041703_0000000003.mp4	해안	정상
3	4_1_1_09041703_0000000004.mp4	해안	정상
4	4_1_1_09041703_0000000005.mp4	해안	정상
5	4_1_1_09041703_0000000006.mp4	해안	정상
6	4_1_1_09041703_0000000007.mp4	산악	정상
7	4_1_1_09041703_0000000008.mp4	산악	정상
8	4_1_1_09041703_0000000009.mp4	해안	정상
9	4_1_1_09041703_0000000010.mp4	농경	정상
10	4_1_1_09041703_0000000011.mp4	잔디	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 어노테이션 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 1 / 10
 = 0.90

생성형 예시 1

시각 정보 질의응답 데이터

● 데이터 구조

데이터 구조	이미지 객체, 텍스트 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, 텍스트 파일 10개, json 파일 10개)				
객체 데이터 유형	이미지 / 텍스트	객체 데이터 형식	png / json	객체 데이터 해상도	1200 × 240이상
메타데이터	이미지 이름, 이미지 ID, 발행년도, 분야, 저작권 여부, 수집기관, 발행처, 시각 요소 유형, 시각 요소 설명문, 핵심 내용			메타데이터 파일 형식	json
어노테이션	참조 텍스트, 질의응답 정보(질의응답 ID, 질문 내용, 질문 유형, 답변 내용, 답변 유형)			어노테이션 파일 형식	

● 유효성 기준

대상	속성명		기준
어노테이션	source_data_info	reference_text	reference_text별로 qa_data에 3개 이상 질의응답 쌍을 포함
		qa_data	

● 데이터 세부 내용

파일명	구분	내용
qa2500_798.json	어노테이션	<pre> "source_data_info": [{ "tab_id": "2500_789", "reference_text": "1) □ 교류대상지역 : 동아시아, 북미 및 일부 유럽 지역 중심\no 주요 교류 지역은 동아시아권이 가장 많았으며, 북미와 서유럽 국가들과의 교류가 그 뒤를 이음\no 공공과 민간 모두 교류 상위 지역이 유사하게 나타나 국내의 문화교류활동이 특정 권역에 집중되어 있음을 보여줌", "qa_data": [{ "qa_id": "0016", "question": "공공기관이 가장 많이 교류하는 지역은 어디인가요?", "q_type": "추론형-논리추론", "answer": "동아시아 지역과 가장 많은 교류를 합니다.", "qa_subject": "문화교류" }, { "qa_id": "0017", "question": "민간 기관의 교류 대상 지역에는 어떤 곳이 있나요?", "q_type": "일반형-장소", "answer": "동아시아, 북미, 유럽 지역이 포함됩니다.", "qa_subject": "문화교류" }, { "qa_id": "0018", "question": "민간 기관에서 교류 비율이 더 높은 지역은 어디인가요?", "q_type": "추론형-논리추론", "answer": "동아시아 지역의 교류 비율이 더 높습니다.", "qa_subject": "문화교류" }] }], </pre>

● 오류 데이터

파일명	구분	내용
qa2500_791.json	어노테이션	<pre> "source_data_info": [{ "tab_id": "2500_789", "reference_text": "□ 동아시아 문화도시 협력 강화\n○ 동아시아 문화도시 간 공동 사무국 설치 추진('19년~)\n~ 3개국 문화 관련 기관 내 실무급 사무국 설치, 공동 상징물 제작, 자료 아카이브 구축 등 협력 기반 강화\n○ 문화도시로 선정된 국내 주요 도시 지원 확대\n~ 당해 연도 약 ○억원 → 3년간 약 ○○억원 규모로 단계적 확대 추진\n○ 해외 문화도시와의 교류 및 협력 사업 병행 추진" "qa_data": [{ "qa_id": "0789", "question": "2016년 기준 국내 동아시아 문화도시는 어디인가요?", "q_type": "일반형-장소", "answer": "2016년 국내 문화도시는 A도시입니다.", "a_type": "문자형", "qa_subject": "문화교류" }, { "qa_id": "0790", "question": "2015년에 해외 동아시아 문화도시로 선정된 곳은 어디입니까?", "q_type": "일반형-장소", "answer": "해외 문화도시로 선정된 곳은 B도시입니다.", "a_type": "문자형", "qa_subject": "문화교류" }] </pre>

● 전체 데이터 확인

번호	객체	질의응답 개수	확인 결과
1	qa2500_791.json	2개	오류
2	qa2500_792.json	3개	정상
3	qa2500_793.json	2개	오류
4	qa2500_794.json	12개	정상
5	qa2500_795.json	5개	정상
6	qa2500_796.json	4개	정상
7	qa2500_797.json	3개	정상
8	qa2500_798.json	7개	정상
9	qa2500_799.json	6개	정상
10	qa2500_800.json	1개	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 3

● 어노테이션 유효성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 3 / 10$$

$$= 0.70$$

4.3 일관성

일관성은 데이터가 지켜야 할 속성이 일관되게 정의되고, 사용되는지 진단하는 기준으로 비정형 데이터에 대해 다음과 같은 심사 항목으로 평가한다.

● (선택) 공통 어휘 일관성

객체 데이터 파일명, 메타데이터, 어노테이션 값이 공통 어휘 사전에 정의된 용어를 사용하는지를 심사하는 항목이다. 예를 들어, 공통 어휘 사전에 성별을 “남자”, “여자”로 정의했다면, 성별의 속성값에 정의된 용어만 사용하는지 확인한다.

▶ **적용 대상:** 공통 어휘 사전에 값이 정의된 속성

▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$

- 오류 데이터: 공통 어휘 사전 내 용어를 사용하지 않은 데이터
- 진단 데이터: 공통 어휘 사전에 값이 정의된 데이터



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 공통 어휘 사전에 성별이 "남"과 "여"로 정의된 경우
오류 데이터) "Male"과 "Female"이 입력됨
정상 데이터) "남"과 "여"로 사용됨

예시 2: 공통 어휘 사전에 지역명이 "서울", "부산"으로 정의된 경우
오류 데이터) "SEOUL", "BUSAN"이 사용됨
정상 데이터) "서울", "부산"으로 입력됨

예시 3: 공통 어휘 사전에 제품 상태가 "사용 중", "미사용"으로 정의된 경우
오류 데이터) "Active", "Inactive"로 입력됨
정상 데이터) "사용 중", "미사용"으로 입력됨

예시 4: 공통 어휘 사전에 언어가 "한국어", "영어"로 정의된 경우
오류 데이터) "KR", "EN"으로 입력됨
정상 데이터) "한국어", "영어"로 입력됨

예시 5: 공통 어휘 사전에 결제 상태가 "완료", "대기"로 정의된 경우
오류 데이터) "Complete", "Pending"으로 입력됨
정상 데이터) "완료", "대기"로 사용됨

비디오 예시 1

주행 위험 시나리오 시뮬레이션 데이터

● 데이터 구조

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (비디오 객체 10장, json 파일 10개)				
객체 데이터 유형	비디오	객체 데이터 형식	MP4	객체 데이터 해상도	512 × 512 이상
메타데이터	위험 상황 유형, 실주행 데이터, 센서 데이터, 시뮬레이션 데이터			메타데이터 파일 형식	json
어노테이션	시나리오 번호, 주행도로, 주행시간, 날씨, 주행상황텍스트			어노테이션 파일 형식	

● 데이터 사전

대상	속성명	공통 어휘
json 파일	주행도로	도심도로, 고속도로
	주행시간	낮, 밤
	날씨	맑은날씨, 흐린날씨

● 데이터 세부 내용

파일명	구분	내용
K_AI_4013_11.json	어노테이션	<pre>{ "시나리오 번호": "K_AI_4013_11", "주행도로": "도심도로", "주행시간": "낮", "날씨": "맑은날씨", "주행상황텍스트": " Ego 차량이 1차로에서 직진 주행하고 있다. 전방에 좌회전용 포켓 차로에 세단이 정차 중이며 좌회전을 하기 위한 차량이 직진 차로까지 침범하여 대기 중이다. Ego 차량이 대기 중인 차들로 인해 직진 주행을 하지 못하고 정차한다. Ego 차량이 전방 동일 차로의 세단 출발 후 우측 차로로 차로 변경하여 좌회전 대기 차량을 회피하여 주행한다." }</pre>

● 오류 데이터 예시

파일명	구분	내용
K_AI_4013_16.json	어노테이션	<pre>{ "시나리오 번호": "K_AI_4013_16", "주행도로": "외곽도로", "주행시간": "새벽", "날씨": "맑은날씨", "주행상황텍스트": " 신호 3지 교차로의 비신호 부도로에서 Ego 차량이 주행 중이다. 주도로의 2차로로 SUV가 직진 주행 중이다. 주도로의 1차로에서 SUV가 주행 중이다. 주도로의 2차로에서 SUV가 주행 중이다. 주도로의 1차로에서 경차가 주행 중이다. 전방 주도로의 차량들이 직진 주행하고 있어 Ego 차량이 정차한다. 주도로의 1차로에서 세단 및 트럭이 주행 중이다. 주도로의 1차로에서 세단이 주행 중이다. 주도로의 2차로에서 세단이 주행 중이다. 주도로의 1차로에서 세단이 주행 Ego 차량이 우회전하여 주도로로 진입한다." }</pre>

● 전체 데이터 확인

번호	파일명	주행도로	주행시간	날씨	오류 여부 확인
1	K_AI_4013_11.json	도심도로	낮	맑은날씨	정상
2	K_AI_4013_12.json	도심도로	밤	흐린날씨	정상
3	K_AI_4013_13.json	고속도로	밤	흐린날씨	정상
4	K_AI_4013_14.json	도심도로	낮	맑은날씨	정상
5	K_AI_4013_15.json	고속도로	낮	맑은날씨	정상
6	K_AI_4013_16.json	외곽도로	새벽	맑은날씨	오류
7	K_AI_4013_17.json	고속도로	밤	맑은날씨	정상
8	K_AI_4013_18.json	고속도로	밤	흐린날씨	정상
9	K_AI_4013_19.json	도심도로	낮	맑은날씨	정상
10	K_AI_4013_20.json	외곽도로	밤	흐린날씨	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

● 공통 어휘 일관성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 2 / 10
 = 0.80

이미지 예시 1

하천 유입 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일 고유키, 파일명, 이미지 순번, 이미지 높이, 이미지 너비, 파일크기, 기상정보, 촬영구역, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 인스턴스, 지역코드, 라벨링 Object 개수			메타데이터 파일 형식	json
어노테이션	라벨링구분(Polygon), 라벨좌표, 대분류(산업구분), 중분류(축사 유형), 소분류(축사 종류)			어노테이션 파일 형식	

● 데이터 사전

대상	속성명	공통 어휘
json 파일	기상정보	맑음, 구름많음, 흐림

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	메타데이터	<pre>{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" } },</pre>

● 오류 데이터 예시

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	메타데이터	<pre>{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "화창", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" },}</pre>

● 전체 데이터 확인

번호	file_name	LOCATION	오류 여부 확인
1	L01_11680_65_20231025_N03_00002.json	맑음	정상
2	L01_41220_130_20230831_N11_00661.json	맑음	정상
3	L01_41220_130_20230831_N11_00702.json	구름많음	정상
4	L01_41220_130_20230831_N11_00744.json	맑음	정상
5	L01_41220_130_20230831_N11_01117.json	구름많음	정상
6	L01_41220_130_20230831_N11_01253.json	맑음	정상
7	L01_41220_130_20230831_N11_01284.json	흐림	정상
8	L01_41220_130_20230831_N11_01288.json	맑음	정상
9	L01_41220_130_20230831_N11_01296.json	흐림	정상
10	L01_41220_130_20230831_N11_01340.json	화창	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 공통 어휘 일관성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

= 1 - 1 / 10

= 0.90

■ (선택) 데이터 포맷 일관성

비정형 객체와 메타데이터, 어노테이션 데이터가 동일한 유형의 데이터일 경우, 동일한 데이터 포맷을 유지하는지를 심사하는 항목이다. 예를 들어, 동일한 유형의 데이터가 같은 파일 포맷 또는 형식인지를 확인한다.

- ▶ **적용 대상:** 동일한 속성을 갖는 데이터
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 동일한 속성 간 데이터 포맷이 일치하지 않는 데이터
 - 진단 데이터: 동일한 속성을 갖는 데이터



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 모든 날짜 데이터가 "YYYY-MM-DD" 형식으로 동일하게 저장되어야 하는 경우
 오류 데이터) [2024-11-01, 2024-11-02, 2024-11-03, 04/11/2024, 2024-11-05]
 정상 데이터) [2024-11-01, 2024-11-02, 2024-11-03, 2024-11-04, 2024-11-05]

예시 2: 모든 전화번호 데이터가 "010-1234-5678" 형식으로 동일하게 저장되어야 하는 경우
 오류 데이터) [010-1234-5678, 010-2345-6789, 01034567890, 010-4567-8901]
 정상 데이터) [010-1234-5678, 010-2345-6789, 010-3456-7890, 010-4567-8901]

예시 3: 모든 우편번호 데이터가 숫자 5자리로 동일하게 저장되어야 하는 경우
 오류 데이터) [12345, 23456, 34567, 456-78, 56789]
 정상 데이터) [12345, 23456, 34567, 45678, 56789]

예시 4: 모든 통화 금액 데이터가 "\$123.45" 형식으로 동일하게 저장되어야 하는 경우
 오류 데이터) [\$123.45, \$145.45, \$123.99, \$300.45, 523.45 USD]
 정상 데이터) [\$123.45, \$145.45, \$123.99, \$300.45, \$523.45]

예시 5: 모든 이메일 주소 데이터가 "name@example.com" 형식으로 동일하게 저장되어야 하는 경우
 오류 데이터) [user1@example.com, user2@example.com, user3@com, user4@example.com]
 정상 데이터) [user1@example.com, user2@example.com, user3@example.com]

이미지 예시 1

스마트농업기반 식품소재 농장 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	JPG	객체 데이터 해상도	512 × 512 이상
메타데이터	작물명, 작물 상태, 촬영 시간 정보, 촬영 각도, 촬영자 코드, 재배시나리오, 파일명, 이미지 높이, 이미지 폭			메타데이터 파일 형식	json
어노테이션	바운딩박스(이미지), 라벨링 ID, 분류, 환경 데이터(획득 시간, 온도, 습도, CO2, 조도), 생장 데이터(획득 시간, 경장, 경직경, 엽폭, 엽수)			어노테이션 파일 형식	

● 데이터 포맷

대상	속성명	포맷
json 파일	ENVIRONMENT[].ENV_DATE	YYYY-MM-DD HH:MM:SS
	GROWTH[].GROW_DATE	

● 데이터 세부 내용

파일명	구분	내용
LB01_5_S2_1330.json	어노테이션	<pre>{ "ENVIRONMENT": { "TEMP": "33.02", "HUMIDITY": "64.95", "CO2": "535", "LUX": "2516", "ENV_DATE": "2024-07-12 11:25:00", "NUTRIENT_TEMPERATURENUMBER": "33.9" }, "GROWTH": { "GROW_DATE": "2024-07-12 11:26:16", "STALK_DIAMETER": "0.124", "LEAF_WIDTH": "0.292", "FRUIT_QUANTITY": "0", "LEAF_NUMBER": "2" } }</pre>

● 오류 데이터 예시

파일명	구분	내용
LB01_5_S2_1338.json	어노테이션	<pre>{ "ENVIRONMENT": { "TEMP": "33.83", "HUMIDITY": "63.89", "CO2": "408", "LUX": "3102", "ENV_DATE": "2024-07-12 11:20:00", "NUTRIENT_TEMPERATURENUMBER": "30.6" }, "GROWTH": { "GROW_DATE": "20240712111806", "STALK_DIAMETER": "0.415", "LEAF_WIDTH": "2.434", "FRUIT_QUANTITY": "0", "LEAF_NUMBER": "5" } }</pre>

● 전체 데이터 확인

번호	file_name	ENVIRONMENT[]. ENV_DATE	GROWTH[]. GROW_DATE	오류 여부 확인
1	LB01_5_S2_1330.json	2024-07-12 11:25:00	2024-07-12 11:26:16	정상
2	LB01_5_S2_1331.json	2024-07-12 11:23:12	2024-07-12 11:24:03	정상
3	LB01_5_S2_1332.json	2024-07-12 11:32:23	2024-07-12 11:33:40	정상
4	LB01_5_S2_1333.json	2024-07-12 11:27:12	2024-07-12 11:28:05	정상
5	LB01_5_S2_1334.json	2024-07-12 11:28:02	2024-07-12 11:29:17	정상
6	LB01_5_S2_1335.json	2024-07-12 11:34:00	2024-07-12 11:34:52	정상
7	LB01_5_S2_1336.json	2024-07-12 11:22:14	2024-07-12 11:22:57	정상
8	LB01_5_S2_1337.json	2024-07-12 11:21:10	2024-07-12 11:22:30	정상
9	LB01_5_S2_1338.json	2024-07-12 11:20:00	20240712111806	오류
10	LB01_5_S2_1339.json	2024-07-12 11:20:00	2024-07-12 11:22:15	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

$$\begin{aligned}
 \text{데이터 포맷 일관성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 1 / 10 \\
 &= 0.90
 \end{aligned}$$

이미지 예시 2

고해상도 도로노면 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일 고유키, 파일명, 이미지 순번, 이미지 높이, 이미지 너비, 파일크기, 기상정보, 촬영구역, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 인스턴스, 지역코드, 라벨링 Object 개수			메타데이터 파일 형식	json
어노테이션	라벨링구분(Polygon), 라벨좌표, 대분류(산업구분), 중분류(축사 유형), 소분류(축사 종류)			어노테이션 파일 형식	

● 데이터 포맷

속성명		포맷
영문	한글	
FLG_DE	촬영일시	YYYYMMDDHHMM

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01340.json	메타데이터	<pre>{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" } },</pre>

● 오류 데이터 예시

파일명	구분	내용
L01_41220_130_20230831_N11_01296.jpg	메타데이터	<pre>{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "241101", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220", "LABELCOUNT": "1" } },</pre>

● 전체 데이터 확인

번호	file_name	FLG_DE	오류 여부 확인
1	L01_11680_65_20231025_N03_00002.json	202305160910	정상
2	L01_41220_130_20230831_N11_00661.json	202308311045	정상
3	L01_41220_130_20230831_N11_00702.json	202309010312	정상
4	L01_41220_130_20230831_N11_00744.json	202401230515	정상
5	L01_41220_130_20230831_N11_01117.json	202402140618	정상
6	L01_41220_130_20230831_N11_01253.json	202306190426	정상
7	L01_41220_130_20230831_N11_01284.json	202408061212	정상
8	L01_41220_130_20230831_N11_01288.json	202305270148	정상
9	L01_41220_130_20230831_N11_01296.json	241101	오류
10	L01_41220_130_20230831_N11_01340.json	202308311045	정상

● 진단 총 아이템 수: 10

● 오류 아이템 수: 1

● 데이터 포맷 일관성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 1 / 10
 = 0.90

4.4 정확성

정확성은 업무규칙, 파생 규칙, 어노테이션 규칙 등에 따라 값이 정확한지 진단하는 기준으로 비정형 데이터에 대해 다음과 같은 심사 항목으로 평가한다.

■ (필수) 구문 정확성

비정형 객체의 메타데이터와 어노테이션 값이 명세서에 정의된 구문 규칙을 따르는지를 심사하는 항목이다. 예를 들어, 날짜 형식이 "YYYY-MM-DD"인지 확인한다.

- ▶ **적용 대상:** 구문 규칙이 정의된 데이터 속성
- ▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수
 - 오류 데이터: 정의된 구문 규칙을 준수하지 않는 데이터
 - 진단 데이터: 구문 규칙이 정의된 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 어노테이션에서 사원번호 형식이 숫자 4자리로 정의된 경우

오류 데이터 ["1234", "5281", "4568", "K222"]

정상 데이터 ["1234", "5281", "4568", "2222"]

예시 2: 메타데이터에서 날짜 형식이 "YYYY-MM-DD"로 정의된 경우

오류 데이터 [2024-11-01, 2024-11-02, 2024-11-03, 04/11/2024, 2024-11-05]

정상 데이터 [2024-11-01, 2024-11-02, 2024-11-03, 2024-11-04, 2024-11-05]

예시 3: 전화번호 형식이 "010-1234-5678"로 정의된 경우

오류 데이터 [010-1234-5678, 010-2345-6789, 01034567890, 010-4567-8901]

정상 데이터 [010-1234-5678, 010-2345-6789, 010-3456-7890, 010-4567-8901]

예시 4: 메타데이터에서 좌표 형식이 "[latitude, longitude]"로 정의된 경우

오류 데이터 [37.7749, -122.4194], [48.8566, 2.3522], [35.6895:139.6917]

정상 데이터 [37.7749, -122.4194], [48.8566, 2.3522], [35.6895, 139.6917]

예시 5: 시간 데이터 형식이 "HH:MM:SS"로 정의된 경우

오류 데이터 ["12:12:50", "13:20:50", "175000"]

정상 데이터 ["12:12:50", "13:20:50", "17:50:00"]

이미지 예시 1

야생동물 활동 이미지 데이터

데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg, tif	객체 데이터 해상도	512 × 512 이상
메타데이터	이미지파일명, 이미지 높이, 이미지 너비, 파일 사이즈, 기상 정보, 촬영날짜시간, 촬영 장비명, 촬영위치, 해상도 등			메타데이터 파일 형식	json
어노테이션	어노테이션 객체 수, 어노테이션 라벨(동물명, 야행성 여부, 유해야생동물여부, 동물 모양, 동물 크기, 동물 분류)			어노테이션 파일 형식	

구문 규칙이 있는 속성

구분	속성명	설명	구문 규칙
1	images[].date_created	촬영날짜(년, 월)시간	YYYY.MM.DD hh:mm:ss

오류 예시

- 2024-10-31 10:33:04, 2024/10/31 10:33:04, 2024-Oct-31 10:33:04

데이터 세부 내용

파일명	구분	내용
A01_F03_C074_C_200114_3001_20S_000001.061.jpg	객체 데이터	
A01_F03_C074_C_200114_3001_20S_000001.061.json	메타데이터	<pre>"images":[{"id":300,"width":1920,"height":1080,"file_name":"A01_F03_C074_C_200114_3001_20S_000009.141.jpg","date_created":"2020.01.14 19:07:16", "day":"night", "photographer":"C074", "device":"sensor camera", "location":"울산양떼목장", "GPS":"35.569,129.398", "aspect_ratio":"16:9", "resolution":"1920 x 1080", "weather":"rain", "time":"000009.141"}],</pre>

● 전체 데이터 확인

구분	file_name	date_created	확인 결과
1	A01_F03_C074_C_200114_3001_20S_000001.061.json	2020.01.14 19:06:03	정상
2	A01_F03_C074_C_200114_3001_20S_000001.941.json	2020.01.14 19:06:03	정상
3	A01_F03_C074_C_200114_3001_20S_000002.139.json	2020.01.14 19:06:38	정상
4	A01_F03_C074_C_200114_3001_20S_000002.204.json	2020.01.14 19:06:38	정상
5	A01_F03_C074_C_200114_3001_20S_000006.538.json	2020.01.14 19:06:38	정상
6	A01_F03_C074_C_200114_3001_20S_000009.141.json	2020.01.14 19:07:16	정상
7	A01_F03_C074_C_200114_3001_20S_000014.639.json	2020.01.14 19:09:12	정상
8	A01_F03_C074_C_200114_3002_20S_000013.639.json	2020.01.14 19:09:12	오류
9	A01_F03_C074_C_200114_3002_20S_000018.642.json	2020.01.14 19:10:00	정상
10	A01_F03_C074_C_200114_3002_20S_000019.181.json	2020.01.14 19:10:00	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 구문 정확성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 1 / 10
 = 0.90

■ (필수) 메타데이터 정확성

메타데이터 값이 실제 객체의 속성과 정확히 일치하는지를 심사하는 항목이다. 예를 들어, 파일 크기가 실제 파일 크기와 일치하는지를 확인한다.(예: 파일명, 해상도, 확장자 등)

▶ **적용 대상:** 데이터 값이 존재하는 메타데이터 속성

▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 메타데이터 값이 정확하지 않은 비정형 객체 데이터
- 진단 데이터: 메타데이터 정확성이 요구되는 비정형 객체 데이터



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 이미지 파일의 실제 해상도가 1920*1080인 경우

오류 데이터) 메타데이터에 해상도가 1280*720으로 저장됨

정상 데이터) 메타데이터에 해상도가 1920*1080으로 저장됨

예시 2: 동영상 파일의 실제 길이가 180초인 경우

오류 데이터) 메타데이터에 기록된 길이가 200초로 저장됨

정상 데이터) 메타데이터에 기록된 길이가 180초로 저장됨

예시 3: 메타데이터에 저장된 단어 수가 100인 경우

오류 데이터) 실제 텍스트 파일의 단어 수: 80

정상 데이터) 실제 텍스트 파일의 단어 수: 100

예시 4: 메타데이터에 저장된 샘플링 레이트가 44.1kHz인 경우

오류 데이터) 실제 샘플링 레이트 값: 22kHz

정상 데이터) 실제 샘플링 레이트 값: 44.1kHz

예시 5: 파일 이름 메타데이터가 실제 파일 이름과 정확히 저장되어야 하는 경우

오류 데이터) 메타데이터에 저장된 파일 이름("image_001.jpg")과 실제 파일 이름("photo_001.jpg")이 다름

정상 데이터) 메타데이터에 기록된 파일 이름과 실제 파일 이름이 "image_001.jpg"로 정확하게 저장됨

이미지 예시 1

잔디 생육환경 다분광 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	50개 (이미지 객체 50장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg, tif	객체 데이터 해상도	512 × 512 이상
메타데이터	이미지ID, 촬영일시, 촬영장비(MultiSpectrum Device), 촬영방식, 파일형식, 사진크기, 비트, ISO			메타데이터 파일 형식	json
어노테이션	segmentation mask, 어노테이션 포인트, x좌표, y좌표, 태그id, 태그명(어노테이션), 어노테이션 면적, 라벨링객체 순번, 잔디 상세분류 설명, 객체 단일여부, 이미지ID, 어노테이션 id, 참조 이미지			어노테이션 파일 형식	


● 데이터 명세서에 표기된 메타데이터 기준

구분	속성명	설명	필수 여부	비고
1	file_format	파일형식	Y	jpg, tif
2	pixel	해상도	Y	2592 × 1944
3	bit	비트 수	Y	24

● 데이터 세부 내용

파일명	구분	내용										
G04_CU_02 21_DJI_202 308261028 20_0002_D. jpg	객체 데이터	<table><tr><th>이름</th><th>사진 크기</th><th>비트 수준</th><th>유형</th><th>크기</th></tr><tr><td> G04_CU_0221_DJI_20230826102820_0002_D</td><td>2592 x 1944</td><td>24</td><td>이미지(jpg) 객체</td><td>1,961KB</td></tr></table>	이름	사진 크기	비트 수준	유형	크기	 G04_CU_0221_DJI_20230826102820_0002_D	2592 x 1944	24	이미지(jpg) 객체	1,961KB
이름	사진 크기	비트 수준	유형	크기								
 G04_CU_0221_DJI_20230826102820_0002_D	2592 x 1944	24	이미지(jpg) 객체	1,961KB								
G04_CU_02 21_DJI_202 308261028 20_0002_D. json	메타데이터	<pre>"film_info": { "file format": "JPG", "pixel": "2592x1944", "bit": 24, "iso": "ISO-100" },</pre>										

● 오류 예시

파일명	구분	내용
G04_CU_02 21_DJI_202 308261030 02_0054_D. jpg	객체 데이터	 720 x 383 24 이미지(png) 파일
G04_CU_02 21_DJI_202 308261030 02_0054_D. json	메타데이터	"film_info": { "file format": "PNG", "pixel": "720x384", "bit": 24, "iso": "ISO-100" },

● 전체 데이터 확인

구분	file_name	file_for mat	pixel	bit	확인 결과
1	G04_CU_0221_DJI_20230826102820_0002_D.jpg	jpg	2592 × 1944	24	정상
2	G04_CU_0221_DJI_20230826102822_0003_D.jpg	jpg	2592 × 1944	24	정상
3	G04_CU_0221_DJI_20230826102824_0004_D.jpg	jpg	2592 × 1944	24	정상
4	G04_CU_0221_DJI_20230826102826_0005_D.jpg	jpg	2592 × 1944	24	정상
5	G04_CU_0221_DJI_20230826102854_0019_D.jpg	jpg	2592 × 1944	24	정상
6	G04_CU_0221_DJI_20230826102856_0020_D.jpg	jpg	2592 × 1944	24	정상
7	G04_CU_0221_DJI_20230826102858_0021_D.jpg	jpg	2592 × 1944	24	정상
8	G04_CU_0221_DJI_20230826102900_0022_D.jpg	jpg	720 × 383	24	오류
9	G04_CU_0221_DJI_20230826103002_0053_D.jpg	jpg	2592 × 1944	24	정상
10	G04_CU_0221_DJI_20230826103002_0054_D.png	png	720 × 383	24	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

$$\begin{aligned}
 \text{메타데이터 정확성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 2 / 10 \\
 &= 0.80
 \end{aligned}$$

비디오 예시 1

비디오 장면 설명문 데이터

● 데이터 구조

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (동영상 객체 10개, json 파일 10개)				
객체 데이터 유형	비디오	객체 데이터 형식	mp4	객체 데이터 해상도	512 × 512 이상
메타데이터	비디오ID, 촬영일시, 촬영장비, 촬영방식, 파일형식, 사진크기, 비트, ISO			메타데이터 파일 형식	json
어노테이션	어노테이션 포인트, x좌표, y좌표, 태그id, 태그명(어노테이션), 타임스탬프,			어노테이션 파일 형식	

● 데이터 명세서에 표기된 메타데이터 기준

구분	속성명	설명	필수 여부	기준
1	type	파일형식	Y	mp4
2	frame_rate	프레임률 (fps)	Y	30fps 이상
3	length	영상 시간(초 단위)	Y	60s 이상

● 데이터 세부 내용

파일명	구분	내용
news_onair_0029.mp4	객체 데이터	
news_onair_0029.json	메타데이터	<pre>"metadata": { "file_name": "news_onair_0029.mp4", "type": "mp4", "length": 339.505833, "frame_rate": "30", "annotator_id": 7579 }</pre>

● 오류 예시

파일명	구분	내용
news_onair_0030.mp4	객체 데이터	
news_onair_0030.json	메타데이터	<pre>"metadata": { "file_name": "news_onair_0030.mp4", "type": "mp4", "length": 43.505833, "frame_rate": "26.79", "annotator_id": 7579 }</pre>

- 전체 데이터 확인

구분	file_name	type	length	frame_rate	확인 결과
1	news_onair_0021.mp4	mp4	600.775588	30	정상
2	news_onair_0022.mp4	mp4	282.928283	30	정상
3	news_onair_0023.mp4	mp4	594.162497	30	정상
4	news_onair_0024.mp4	mp4	770.259776	30	정상
5	news_onair_0025.mp4	mp4	526.827930	30	정상
6	news_onair_0026.mp4	mp4	256.830135	30	정상
7	news_onair_0027.mp4	mp4	178.929647	30	정상
8	news_onair_0028.mp4	mp4	41.125823	30	오류
9	news_onair_0029.mp4	mp4	339.505833	30	정상
10	news_onair_0030.mp4	mp4	43.505833	26.79	오류

- 진단 총 데이터 수: 10

- 오류 데이터 수: 2

- 메타데이터 정확성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 2 / 10$
 $= 0.80$

오디오 예시 1

고객응대 오디오 데이터

● 데이터 구조

데이터 구조	오디오 객체, 오디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일		
데이터 수량	10개 (오디오 객체 10개, json 파일 10개)		
객체 데이터 유형	오디오	객체 데이터 형식	wav
메타데이터	오디오ID, 녹취일시, 파일형식, 발화 길이(초), 주파수, 비트수, 인코딩방식	메타데이터 파일 형식	json
어노테이션	어노테이션 포인트, 태그id, 태그명(어노테이션), 타임스탬프, 발화시작점, 발화 끝점, 화자 정보, 대화내용, 문장 시작 시간, 문장 종료 시간	어노테이션 파일 형식	

● 데이터 명세서에 표기된 메타데이터 기준

구분	속성명	설명	필수 여부	기준
1	type	파일형식	Y	wav
2	SamplingRate	주파수	Y	48000
3	length	재생 시간(초 단위)	Y	10s 이상

● 데이터 세부 내용

파일명	구분	내용
1_A651G1A 1_A644G1A 1_T2_1D09 T0360C000 310_04715 4.wav	객체 데이터	
1_A651G1A 1_A644G1A 1_T2_1D09 T0360C000 310_04715 4.json	메타데이터	<pre> "metadata": { "file_name": "1_A651G1A1_A644G1A1_T2_1D09T0360C000310_047154", "type": "wav", "length": 339.505833, "SamplingRate": "48000", "NumberOfBit": "16" } </pre>

● 오류 예시

파일명	구분	내용
1_A178G2A 1_A164G2A 1_T2_1D05 T0191C000 138_04509 7.json	메타데이터	<pre>"metadata": { "file_name": "1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045097", "type": "mp3", "length": 41.125823, "SamplingRate": "48000", "NumberOfBit": "16" }</pre>

● 전체 데이터 확인

구분	file_name	type	length	frame_rate	Sampling Rate	확인 결과
1	1_A651G1A1_A644G1A1_T2_1D09T0360C000310_047154	wav	339.505833	16	48000	정상
2	1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045091	wav	282.928283	16	48000	정상
3	1_A161G1A1_A518G1A1_T2_1D09T0393C000223_046592	wav	594.162497	16	48000	정상
4	1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045093	wav	770.259776	16	48000	정상
5	1_A161G1A1_A518G1A1_T2_1D09T0393C000223_046594	wav	526.827930	16	48000	정상
6	1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045095	wav	256.830135	16	48000	정상
7	1_A161G1A1_A518G1A1_T2_1D09T0393C000223_046596	wav	178.929647	16	48000	정상
8	1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045097	mp3	41.125823	16	48000	오류
9	1_A161G1A1_A518G1A1_T2_1D09T0393C000223	wav	600.775587	16	48000	정상

구분	file_name	type	length	frame_rate	Sampling Rate	확인 결과
	_046598					
10	1_A178G2A1_A164G2A1 _T2_1D05T0191C000138 _045099	wav	20.841304	16	48000	정상

- 진단 총 데이터 수: 10
- 오류 데이터 수: 1
- 메타데이터 정확성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 1 / 10$
 $= 0.90$

(선택) 어노테이션 정확성

객체데이터(원천데이터)의 어노테이션(라벨/비라벨 데이터)이 의미적·사실적으로 정확한지 심사하는 항목이다. 예를 들어, 이미지의 객체 라벨링 정보가 실제 객체와 일치하는지를 확인한다.

- ▶ **적용 대상:** 비정형 객체에 대한 가공을 통해 어노테이션 작업을 한 데이터 속성
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 어노테이션이 정확하지 않은 비정형 객체 데이터
 - 진단 데이터: 어노테이션 정확성이 요구되는 비정형 객체 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 객체에 대한 바운딩 박스의 경우

오류 데이터) 바운딩 박스가 객체를 정확히 포함하지 못함

정상 데이터) 바운딩 박스가 객체를 정확히 포함하고 경계를 벗어나지 않음

예시 2: 객체에 대한 어노테이션 라벨의 경우

오류 데이터) 어노테이션 라벨이 기준에 맞지 않게 잘못 기입됨

정상 데이터) 어노테이션 라벨이 명세서 기준에 맞게 정확히 기입됨

예시 3: 객체의 위치 대한 point 좌표인 경우

오류 데이터) 객체의 위치 좌표가 이미지의 경계를 벗어난 경우

정상 데이터) 객체의 위치 좌표가 이미지의 경계 내에 정확히 포함됨

예시 4: 텍스트 감정 어노테이션의 경우

오류 데이터) 텍스트 감정 어노테이션이 기준에 맞지 않게 잘못 기입됨

정상 데이터) 텍스트 감정 어노테이션이 기준에 맞게 기입됨

예시 5: 객체에 대한 keypoint인 경우

오류 데이터) 객체에 대한 keypoint가 어긋남


정상 데이터) 객체에 대한 keypoint가 정확함

예시 6: 비디오 데이터의 시간 범위 어노테이션인 경우

오류 데이터) 비디오 데이터에서 어노테이션 시간 범위가 실제 동작 시간과 맞지 않음

정상 데이터) 비디오 데이터에서 어노테이션 시간 범위가 실제 동작 시간과 정확히 일치함

어노테이션 종류별 오류 예시

1	바운딩 박스(Bounding-box) 오류 - 강아지 영역 전체를 포함하지 않는 바운딩 박스					
2	폴리곤(Polygon) 오류 이미지의 폴리곤 영역이 정확하지 않은 경우 - 고양이 영역 폴리곤 영역 오류 예시					
3	키폰트(Keypoint) 오류 특정 지점 라벨링 영역이 정확하지 않은 경우 - 고양이 앞다리 뒷다리 시점 좌표 명확하지 않은 경우					
4	세그멘테이션(segmentation) 오류 - 도로 주행부를 벗어난 세그멘테이션					
5	음성 데이터 전사(Transcription) 어노테이션 오류 - 발화내용을 전사 및 전사한 문장의 화자의 감정 태깅 불일치	<table><tr><td>전사 문장</td><td>제품 크기와 가격 모두 마음에 들고 매일 사용하기 좋네요!</td></tr><tr><td>감정 태그</td><td>슬픔</td></tr></table>	전사 문장	제품 크기와 가격 모두 마음에 들고 매일 사용하기 좋네요!	감정 태그	슬픔
전사 문장	제품 크기와 가격 모두 마음에 들고 매일 사용하기 좋네요!					
감정 태그	슬픔					
6	비디오 데이터 문장 어노테이션 오류	<table><tr><td>실제 비디오 내용</td><td>여자가 정자에 앉는다</td></tr><tr><td>어노테이션 문장</td><td>여자가 걸어가고 있다</td></tr></table>	실제 비디오 내용	여자가 정자에 앉는다	어노테이션 문장	여자가 걸어가고 있다
실제 비디오 내용	여자가 정자에 앉는다					
어노테이션 문장	여자가 걸어가고 있다					

이미지 예시 1

반려동물 구분을 위한 동물 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	50개 (이미지 객체 50장, json 파일 50개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg, tif	객체 데이터 해상도	512 × 512 이상
메타데이터	이미지ID, 촬영일시, 촬영장비(MultiSpectrum Device), 촬영방식, 파일형식, 이미지밴드, 사진크기, 비트, ISO			메타데이터 파일 형식	json
어노테이션	어노테이션 객체 수, 어노테이션 라벨(동물명, 동물 모양, 동물 크기, 동물 분류, 행동 유형)			어노테이션 파일 형식	


● 데이터 세부 내용

파일명	구분	내용
20201029/cat-footp ush-000231.jpg	객체 데이터	
20201029/cat-footp ush-000231.json	어노테이션	<pre> "annotations": [{ "frame_number": 187, "species": "CAT", "bounding_box": { "x": 223, "y": 367, "width": 496, "height": 512 } }, ...]</pre>

● 오류 예시

어노테이션 라벨 기입 오류

▶ 고양이(CAT)가 개(DOG)로 잘못 기입된 경우

파일명	구분	내용
20201029/cat-footpush-000240.jpg	객체 데이터	
20201029/cat-footpush-000240.json	어노테이션	<pre> "annotations": [{ "frame_number": 157, "species": "DOG", "bounding_box": { "x": 646, "y": 168, "width": 823, "height": 898 } }, ...] </pre>

● 전체 데이터 확인

구분	file_name	species	확인 결과
1	20201029/cat-footpush-000231.jpg	CAT	정상
2	20201029/cat-footpush-000232.jpg	CAT	정상
3	20201029/cat-footpush-000233.jpg	CAT	정상
4	20201029/cat-footpush-000234.jpg	CAT	정상
5	20201029/cat-footpush-000235.jpg	CAT	정상
6	20201029/cat-footpush-000236.jpg	CAT	정상
7	20201029/cat-footpush-000237.jpg	CAT	정상
8	20201029/cat-footpush-000238.jpg	CAT	정상
9	20201029/cat-footpush-000239.jpg	CAT	정상
10	20201029/cat-footpush-000240.jpg	DOG	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 어노테이션 정확성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 1 / 10$$

$$= 0.90$$

비디오 예시 1

비디오 장면 설명문 데이터

● 데이터 구조

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (동영상 객체 10개, json 파일 10개)				
객체 데이터 유형	비디오	객체 데이터 형식	mp4	객체 데이터 해상도	512 × 512 이상
메타데이터	비디오ID, 촬영일시, 촬영장비, 촬영방식, 파일형식, 프레임 크기, 비트, ISO			메타데이터 파일 형식	json
어노테이션	어노테이션 포인트, 태그id, 태그명(어노테이션), 타임스탬프, 행동구간, 행동 구간 국문 캡션, 국문 영상 캡션			어노테이션 파일 형식	

● 데이터 세부 내용

파일명	구분	내용
D3_DR_092_2_000380.mp4	객체 데이터	
D3_DR_092_2_000380.json	어노테이션	<pre> { "sentences": [{ "timestamps": ["00:05.00000", "00:15.00000"], "sentences_ko": "여자가 정자에 앉는다.", },], } </pre>

- 오류 예시
구간 시작 시간(초 구간), 구간 종료 시간(초 구간) 불일치

파일명	구분	내용
D3_DR_092 2_000389. mp4	객체 데이터	
D3_DR_092 2_000389.js on	어노테이션	<pre> : "sentences": [{ "timestamps": ["00:39.00000", "00:44.00000"], "sentences_ko": "여자가 정자에 앉는다.", },] : </pre>

- 전체 데이터 확인

구분	file_name	timestamps 일치 여부	확인 결과
1	D3_DR_0922_000380.mp4	일치	정상
2	D3_DR_0922_000381.mp4	일치	정상
3	D3_DR_0922_000382.mp4	일치	정상
4	D3_DR_0922_000383.mp4	일치	정상
5	D3_DR_0922_000384.mp4	일치	정상
6	D3_DR_0922_000385.mp4	일치	정상
7	D3_DR_0922_000386.mp4	일치	정상
8	D3_DR_0922_000387.mp4	일치	정상
9	D3_DR_0922_000388.mp4	일치	정상
10	D3_DR_0922_000389.mp4	불일치	오류

- 진단 총 데이터 수: 10
- 오류 데이터 수: 1
- 어노테이션 정확성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$

$$= 1 - 1 / 10$$

$$= 0.90$$

오디오 예시 1

고객응대 오디오 데이터

데이터 구조

데이터 구조	오디오 객체, 오디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (오디오 객체 10개, json 파일 10개, txt 파일 10개)				
객체 데이터 유형	오디오	객체 데이터 형식	wav	전사 데이터 파일 형식	txt
메타데이터	오디오ID, 녹취일시, 파일형식, 발화 길이(초), 주파수, 비트수, 인코딩방식			메타데이터 파일 형식	json
어노테이션	어노테이션 포인트, 태그id, 태그명(어노테이션), 타임스탬프, 발화시작점, 발화 끝점, 화자 정보, 대화내용, 문장 시작 시간, 문장 종료 시간			어노테이션 파일 형식	

데이터 세부 내용

파일명	구분	내용										
1_A651G1A 1_A644G1A 1_T2_1D09 T0360C000 310_04715 4.wav	객체 데이터	<table><tr><th>이름</th><th>유형</th><th>길이</th><th>비트 전송률</th><th>크기</th></tr><tr><td>1_A651G1A1_A644G1A1_T2_1D09T0360C000310_047154</td><td>WAV 파일</td><td>00:19:51</td><td>512kbps</td><td>74,497KB</td></tr></table>	이름	유형	길이	비트 전송률	크기	1_A651G1A1_A644G1A1_T2_1D09T0360C000310_047154	WAV 파일	00:19:51	512kbps	74,497KB
이름	유형	길이	비트 전송률	크기								
1_A651G1A1_A644G1A1_T2_1D09T0360C000310_047154	WAV 파일	00:19:51	512kbps	74,497KB								
1_A651G1A 1_A644G1A 1_T2_1D09 T0360C000 310_04715 4.json	어노테이션	<pre>{ "dataSet": { "version": "1.0", "date": "20210106", "typeInfo": { "category": "생활", "subcategory": "옷수선", "place": null, "speakers": [{ "id": "1035739_1_0_0", "gender": "남", "type": "고객", "age": "10대", "residence": "세종" }] }, "inputType": "모바일" }, "dialogs": [{</pre>										

파일명	구분	내용
		<pre> "speaker": "1035739_1_0_0", "audioPath": "KresSpeech/D52/J12/S00000001/0001.wav", "textPath": "KresSpeech/D52/J12/S00000001/0001.txt" } } } </pre>
.txt	전사 데이터	n/ 가쪽웃 자르는 것도 수선했을 수 있어요?

● 오류 예시

발화 내용과 전사 데이터가 일치하지 않는 경우

- 화자의 실제 발화: "무료 배송이 맞나요?"
- 전사 데이터: "무료 배송이 없나요?"

● 전체 데이터 확인

구분	file_name	발화 내용 - 전사 데이터 일치 여부 (Y/N)	확인 결과
1	1_A161G1A1_A518G1A1_T2_1D09T0393C000223_046590	Y	정상
2	1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045091	Y	정상
3	1_A161G1A1_A518G1A1_T2_1D09T0393C000223_046592	Y	정상
4	1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045093	Y	정상
5	1_A161G1A1_A518G1A1_T2_1D09T0393C000223_046594	Y	정상
6	1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045095	Y	정상
7	1_A161G1A1_A518G1A1_T2_1D09T0393C000223_046596	Y	정상
8	1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045097	N	오류
9	1_A161G1A1_A518G1A1_T2_1D09T0393C000223_046598	Y	정상
10	1_A178G2A1_A164G2A1_T2_1D05T0191C000138_045099	Y	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

- 어노테이션 정확성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
- $$= 1 - 1 / 10$$
- $$= 0.90$$

텍스트 예시 1

도서자료 텍스트 데이터

● 데이터 구조

데이터 구조	도서자료 정제 텍스트 객체, 텍스트 객체별 메타데이터와 어노테이션으로 구성된 json 파일		
데이터 수량	10개 (txt 객체 10개, json 파일 10개)		
객체 데이터 유형	도서 자료 정제 데이터	객체 데이터 형식	txt
메타데이터	문서 ID, 문서 유형, 문서명, 발행자, 발행처, 발행일, 주제 분류, 분류기호	메타데이터 파일 형식	json
어노테이션	챕터, 원문, 요약문	어노테이션 파일 형식	

● 데이터 세부 내용

파일명	구분	내용
PCY_20171 122064535 821_0.txt	객체 데이터	
PCY_20171 122064535 821_0.json	메타데이터	<pre> "metadata": { "doc_id": "PCY_20171122064535821", "doc_type": "도서", "doc_name": "브라질 속의 한국인 : 한국-브라질 수교 55주년·이민 51주년 기념 특별전", "author": null, "publisher": "대한민국역사박물관,주한브라질문화원", "published_year": "2014", "kdc_label": "외교", "kdc_code": "300" } </pre>
PCY_20171 122064535 821_0.json	어노테이션	<pre> "chapter": null, "passage": "한국인에게 브라질은 지구 반대편에 있으며, 12시간의 시차(時差)가 있는 먼나라이다. 그러나 한편으로 이러한 물리적 거리를 넘어 삼바축제, 아마존, 축구 나라로 기억되는 친근한 나라이기도 하다. 브라질 월드컵이 개최되는 올해는 한국-브라질 수교 55주년이며, 브라질 한인 공식 이민 51주년이 되는 뜻 깊은 해이다. 브라질 이민은 1948년 대한민국 정부가 수립된 이후에 최초로 추진된 공식 이민이었다. 그러나 거슬러 올라가 보면 한국과 브라질의 교류는 공식 이민이 실시되기 훨씬 이전인 일제강점기 때부터이다. 일본인들과 같이 이민을 갔던 사람들이 있었고, 6.25전쟁 후에는 반공포로들이 제3국을 택해 떠났던 곳이기도 했다. 또한 조선 후기(1770년)에는 '백서이(伯西爾)'라는 국명으로 조선 지식인들에게 소개되기도 했다.", "summary": "한국인에게 브라질은 거리상 먼 나라로 인식되지만 친근한 문화들로 기 </pre>

파일명	구분	내용
		억되는 나라이다. 또한 한국과 브라질은 일제강점기 때부터 오랜기간 교류해 온 사이이기도 하다."
		}

● 오류 예시

원문-요약문 간의 키워드 불일치

파일명	구분	내용
PCY_201410290945430171_30.json	어노테이션	"chapter": null, "passage": "새롭게 출범한 정부는 '투명하고 유능한 서비스 정부' 구현으로 국민행복을 증대하고 자 정부 운영 패러다임을 '정부3.0'으로 수립하고 비전을 선포하였으며, 부처간의 칸막이를 없애고 소통 · 협력함으로써 국정과제에 대한 추진동력을 확보하고자 하였다. 이에 새롭게 출범하는 미래창조과학부와 방송통신 규제기관인 방송통신위원회는 정책의 원활한 협조를 위해 부처간 정책협력 양해각서(MOU)를 체결하였다. 그러나 부처간 MOU 체결은 두 부처가 처음이고 논쟁 소지가 있는 해당 분야별로 실무협의회를 구성하여 해당 문제의 협업 방안을 논의하고 있으나 구체적인 방법이나 협업체계는 미비한 실정이다.", "summary": "교육부는 이미 체육 교육 과정에 야외교육 경험 프로그램을 도입하여 초·중·고등학교 학생들이 다양한 야외 교육을 통한 배움이 있도록 하고 있고, 지금은 다른 학교와 연합하여 진행하기도 한다" }

● 전체 데이터 확인

구분	file_name	kdc_label 일치 여부 (Y / N)	확인 결과
1	PCY_201410230944171811_10.json	Y	정상
2	PCY_201410231003565911_61.json	Y	정상
3	PCY_201410280908492191_40.json	Y	정상
4	PCY_201410280908492191_93.json	Y	정상
5	PCY_201410280912578921_36.json	Y	정상
6	PCY_201410290907332351_46.json	Y	정상
7	PCY_201410290907332351_78.json	Y	정상
8	PCY_201410290945430171_30.json	N	오류
9	PCY_201410290950144231_32.json	Y	정상
10	PCY_201410290950448361_11.json	Y	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 어노테이션 정확성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 1 / 10
 = 0.90

생성형 예시 1

도로 침수 상황 영상 데이터

● 데이터 구조

데이터 구조	비디오 객체, 비디오 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (비디오 객체 10개, json 파일 10개)				
객체 데이터 유형	비디오	객체 데이터 형식	mp4	객체 데이터 해상도	1280 × 720 이상
메타데이터	파일명, 이미지 너비, 이미지 높이, 프레임 수, 데이터 전송 속도, 비트 수, CCTV 설치 구간, 촬영 일자, 야간 촬영 여부			메타데이터 파일 형식	json
어노테이션	설명 캡션(event_caption)			어노테이션 파일 형식	

● 정확성 판단 대상

대상	속성명	기준
어노테이션	event_caption	도로 침수 데이터 셋의 정확성 판단 기준에 부합하여야 함

● 정확성 판단 기준

평가항목	세부내용
1. 정보 추출 적절성	객체(사람/차량) 수량, 침수 진행 상태, 도로 유형이 캡션에 적절히 표현되어 있는지 확인
2. 정보 표현 적절성	문법적 오류가 없고, 내용이 사실적이며 결함·환각 표현이 없는지 확인
3. 정보 내용 일치성	문장 구성 성분, 객체·상황의 내용이 실제 영상과 일치하는지 확인

● 데이터 세부 내용

파일명	구분	내용
A_0601_0 01.mp4	객체 데이터	
A_0601_0 01.json	어노테이 션	"annotations": { "event_caption": "하천 다리와 출입 도로가 흙탕물에 침수되어 한 대의 차량 진입에 애로사항이 발생함" }

● 정확성 판단 기준 검증

- 1. 정보 추출 적절성

평가항목	판정	세부내용
객체(사람/차량)의 수량 표현 여부 (※ 객체가 존재할 때만 확인)	O	한 대(차량)
침수 상태 표현 여부	O	도로가 흙탕물에 침수되어 (진행 여부 표현됨)
도로 유형 포함 여부	O	하천 다리, 출입 도로

- 2. 정보 표현 적절성

평가항목	판정	세부내용
문법적 완전성 여부	O	문법·어순 오류 없음
내용 신뢰성 여부	O	사실 기반 표현, 과장·환각 없음

- 3. 정보 내용 일치성

평가항목	판정	세부내용
문장 구성 성분 완전 여부	O	주어·서술어 완전함
객체 일치 여부	O	차량 객체 존재
상황 일치 여부	O	차량 진입 곤란 상황 발생

● 오류 데이터 예시

- "event_caption": "도로 위에 차 한 대가 있다."

- 1. 정보 추출 비율

평가항목	판정	세부내용
객체(사람/차량)의 수량 표현 여부 (※ 객체가 존재할 때만 확인)	O	차 한 대
침수 상태 표현 여부	X	침수 표현 불충분
도로 유형 포함 여부	X	도로 유형 불충분

- 2. 정보 표현 적절성

평가항목	판정	세부내용
문법적 완전성 여부	O	문법·어순 오류 없음
내용 신뢰성 여부	X	사실 기반 결여(진입 곤란 등의 상세 표현 누락)

- 3. 정보 내용 일치성

평가항목	판정	세부내용
문장 구성 성분 완전 여부	O	주어·서술어 완전함
객체 일치 여부	O	차량 객체 존재
상황 일치 여부	X	영상은 침수되어 진입 곤란, 캡션은 진입 곤란 표현 없음

● 전체 데이터 확인

객체	정보 추출 적절성	정보 표현 적절성	정보 내용 일치성	확인 결과
A_0601_001.mp4	O	O	O	정상
A_0602_011.mp4	O	O	O	정상
A_0603_021.mp4	O	O	X	오류
A_0604_031.mp4	O	O	O	정상
A_0605_041.mp4	O	O	O	정상
A_0606_051.mp4	O	O	O	정상
A_0607_061.mp4	O	O	O	정상
A_0608_071.mp4	O	O	O	정상
A_0609_081.mp4	O	O	O	정상
A_0610_091.mp4	X	X	X	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

$$\begin{aligned}
 \text{어노테이션 정확성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 2 / 10 \\
 &= 0.80
 \end{aligned}$$

■ (선택) 주제 정확성

비정형 객체가 정의된 주제·도메인과 일치하는지를 심사하는 항목이다. 예를 들어, "자동차 데이터셋"에 포함된 객체가 실제 자동차와 관련 있는지를 심사한다.

▶ **적용 대상:** 특정 주제가 있는 데이터

▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$

- 오류 데이터: 주어진 주제(컨텍스트)에 적절하지 않은 비정형 객체 데이터
- 진단 데이터: 주제 정확성이 요구되는 비정형 객체 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 고양이 이미지 데이터셋

오류 데이터) 고양이 이미지 데이터셋에 강아지 이미지가 포함됨

정상 데이터) 고양이 이미지 데이터셋에 고양이 이미지만 포함됨

예시 2: 여름 풍경 데이터셋

오류 데이터) 여름 풍경 데이터셋에 겨울 풍경 이미지가 포함됨

정상 데이터) 여름 풍경 데이터셋에 여름 풍경 이미지만 포함됨

예시 3: 영어 문장 데이터셋

오류 데이터) 영어 문장 데이터셋에 다른 언어의 문장이 포함됨

정상 데이터) 영어 문장 데이터셋에 영어 문장만 포함됨

예시 4: 비디오 데이터에서 "운동" 주제의 클립

오류 데이터) "운동" 주제의 클립에 "요리" 관련 영상이 포함됨

정상 데이터) "운동" 주제의 클립에 "운동" 관련 영상만 포함됨

예시 5: 음악 감정 분석 데이터셋

오류 데이터) "기쁨" 태그를 가진 곡이 "슬픔" 데이터셋에 포함됨

정상 데이터) "기쁨" 태그를 가진 곡이 "기쁨" 데이터셋에만 포함됨

이미지 예시 1

생활환경 로봇 협업 작업 데이터


● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	PNG	객체 데이터 해상도	1080 × 1920 이상
메타데이터	파일 이름, 깊이 파일 이름, 높이, 너비, 카메라 정보, 이미지ID, 환경, 작업단계, 조도, 각도조건			메타데이터 파일 형식	json
어노테이션	주제, 영역, 그룹 라벨링 여부, 바운딩 박스, 카테고리 ID			어노테이션 파일 형식	

● 데이터 세부 내용


파일명	구분	내용
H_k5110_1.jpg	객체 데이터	
H_k5110_1.json	어노테이션	<pre> "annotations": [{ "subject": "생활환경", "area": 3120.0, "iscrowd": 0, "image_id": "H_k5110_1", "bbox": [1320, 628, 1380, 680], "category_id": 60 }] </pre>

● 오류 예시 데이터

파일명	구분	내용
H_k5110_3.jpg	객체 데이터	
H_k5110_3.json	어노테이션	<pre> "annotations": [{ "subject": "제조환경", "area": 3320.0, "iscrowd": 0, "image_id": "H_k5110_3", "bbox": [1120, 738, 780, 680], "category_id": 62 }] </pre>

● 전체 데이터 확인

구분	file_name	객체 이미지	subject	확인 결과
1	H_k5110_1.jpg		생활환경	정상
2	H_k5110_2.jpg		생활환경	정상
3	H_k5110_3.jpg		제조환경	오류
4	H_k5110_4.jpg		생활환경	정상

구분	file_name	객체 이미지	subject	확인 결과
5	H_k5110_5.jpg		생활환경	정상
6	H_k5110_6.jpg		생활환경	정상
7	H_k5110_7.jpg		생활환경	정상
8	H_k5110_8.jpg		생활환경	정상
9	H_k5110_9.jpg		생활환경	정상
10	H_k5110_10.jpg		제조환경	오류

● 진단 총 데이터 수: 10
 ● 오류 데이터 수: 2
 ● 주제 정확성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 2 / 10$
 $= 0.80$


이미지 예시 2

고양이 이미지 데이터


● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg	객체 데이터 해상도	512 × 512 이상
메타데이터	이미지파일명, 이미지 높이, 이미지 너비, 파일 사이즈, 기상 정보, 촬영날짜시간, 촬영 장비명, 촬영위치, 해상도 등			메타데이터 파일 형식	json
어노테이션	어노테이션 객체 수, 어노테이션 라벨(동물명, 동물 모양, 동물 크기, 동물 분류, 행동 유형)			어노테이션 파일 형식	

● 데이터 세부 내용





파일명	구분	내용
20201029/c at-footpush -000231.jpg	객체 데이터	
20201029/c at-footpush -000231.js on	어노테이션	<pre> "annotations": [{ "frame_number": 187, "species": "CAT", "bounding_box": { "x": 223, "y": 367, "width": 496, "height": 512 } }] </pre>

● 오류 예시

파일명	구분	내용
20201029/c at-footpush -000240.jp g	객체 데이터	

파일명	구분	내용
20201029/cat-footpush-000240.json	어노테이션	<pre> "annotations": [{ "frame_number": 157, "species": "DOG", "bounding_box": { "x": 646, "y": 168, "width": 823, "height": 898 } }] </pre>

● 전체 데이터 확인

구분	file_name	객체 이미지	species	확인 결과
1	20201029/cat-footpush-000231.jpg		CAT	정상
2	20201029/cat-footpush-000232.jpg		CAT	정상
3	20201029/cat-footpush-000233.jpg		CAT	정상
4	20201029/cat-footpush-000234.jpg		CAT	정상
5	20201029/cat-footpush-000235.jpg		CAT	정상
6	20201029/cat-footpush-000236.jpg		CAT	정상

구분	file_name	객체 이미지	species	확인 결과
7	20201029/cat-footpush-000237.jpg		CAT	정상
8	20201029/cat-footpush-000238.jpg		CAT	정상
9	20201029/cat-footpush-000239.jpg		CAT	정상
10	20201029/cat-footpush-000240.jpg		DOG	오류

- 진단 총 데이터 수: 10
- 오류 데이터 수: 1
- 주제 정확성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 1 / 10$
 $= 0.90$

4.5 접근성

접근성은 데이터를 용이하게 사용할 수 있는지 진단하는 기준으로 비정형 데이터에 대해 다음과 같은 심사 항목으로 평가한다.

■ (선택) 데이터 포맷 접근성

비정형 객체 데이터가 일반적으로 사용되는 데이터 포맷(예: jpg, png, bmp)으로 제공되는지를 확인하는 항목이다.

▶ 비정형 객체 데이터 유형별 일반적인 데이터 포맷

데이터 유형	데이터 포맷
이미지	BMP, RLE, DIB, JPG, JPEG, PNG, TIF, TIFF
동영상	WEBM, MPG, MP2, MPEG, MPE, MPV, OGG, MP4, M4P, M4V, AVI, WMV, MOV, QT, FLV, SWF
오디오	MP3, M4A, AAC, OGA, OGG, FLAC, PCM, WAV, AIFF
텍스트	DOC, DOCX, HTML, HTM, ODT, PDF, XLS, XLSX, ODS, PPT, PPTX, TXT, HWP

* TTA.KO-10.1344-Part1_유통·활용 데이터 점검 방법_제1부 정형 반정형 데이터 준용

▶ 적용 대상: 비정형 객체 데이터

▶ 정량화 수식: $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$

- 오류 데이터: 일반적으로 사용되는 포맷을 따르지 않는 비정형 객체 데이터
- 진단 데이터: 데이터 포맷 접근성이 요구되는 비정형 객체 데이터



심사기준을 영상으로
확인하세요!

데이터 예시

예시 1: 이미지 데이터의 포맷이 일반적인 데이터 포맷이 아닌 경우

오류 데이터) 이미지 데이터의 포맷이 BMP, RLE, DIB, JPG, JPEG, PNG, TIF, TIFF에 해당하지 않음

정상 데이터) 이미지 데이터의 포맷이 BMP, RLE, DIB, JPG, JPEG, PNG, TIF, TIFF에 해당함

예시 2: 동영상 데이터의 포맷이 일반적인 데이터 포맷이 아닌 경우

오류 데이터) 동영상 데이터의 포맷이 WEBM, MPG, MP2, MPEG, MPE, MPV, OGG, MP4, M4P, M4V, AVI, WMV, MOV, QT, FLV, SWF에 해당하지 않음

정상 데이터) 동영상 데이터의 포맷이 WEBM, MPG, MP2, MPEG, MPE, MPV, OGG, MP4, M4P, M4V, AVI, WMV, MOV, QT, FLV, SWF에 해당함

예시 3: 오디오 데이터의 포맷이 일반적인 포맷이 아닌 경우

오류 데이터) 오디오 데이터의 포맷이 MP3, M4A, AAC, OGA, OGG, FLAC, PCM, WAV, AIFF에 해당하지 않음

정상 데이터) 오디오 데이터의 포맷이 MP3, M4A, AAC, OGA, OGG, FLAC, PCM, WAV, AIFF에 해당함

예시 4: 텍스트 데이터의 포맷이 일반적인 데이터 포맷이 아닌 경우

오류 데이터) 텍스트 데이터의 포맷이 DOC, DOCX, HTML, HTM, ODT, PDF, XLS, XLSX, ODS, PPT, PPTX, TXT, HWP에 해당하지 않음

정상 데이터) 텍스트 데이터의 포맷이 DOC, DOCX, HTML, HTM, ODT, PDF, XLS, XLSX, ODS, PPT, PPTX, TXT, HWP에 해당함


이미지 예시 1

고해상도 도로노면 이미지 데이터

● 데이터 요약

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (jpg 객체 10개, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	jpg	객체 데이터 해상도	512 × 512 이상
메타데이터	원천데이터별 라벨링정보, 어노테이션 식별자, 다중 객체 라벨 시 사용되는 변수, 이미지 번호, 라벨 유형, 세그멘테이션 정보, 바운딩박스 정보, 바운딩박스 전체면적			파일 형식	json
어노테이션	원시데이터 정보, 승인년도, 저작권, 도로 종류, 촬영 방법, 원천데이터 정보, 이미지 번호, 이미지 폭, 이미지 높이, 원천데이터 파일명				

● 객체 데이터 파일 포맷 확인



〈일반적인 데이터 포맷인지 확인〉

- 진단 데이터 파일 수: 10
- 오류 데이터 파일 수: 0
- 데이터 포맷 접근성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 0 / 10$
 $= 1.00$

■ (선택) 표준기반 데이터 접근성

데이터가 국제 표준, 협약 또는 규정을 준수하고 있는지를 심사하는 항목이다. 예를 들어, 우편번호가 국가의 우편번호 체계를 준수하는지 확인한다.

- ▶ **적용 대상:** 데이터의 표준, 협약 또는 규정 준수 여부
- ▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수
 - 오류 데이터: 표준, 협약 또는 규정을 준수하지 않은 데이터
 - 진단 데이터: 표준기반 데이터 접근성이 요구되는 데이터



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 날짜가 국제 표준 ISO 8601 형식(YYYY-MM-DD)으로 정의되어 있는 경우
오류 데이터) "12/31/2024"
정상 데이터) "2024-12-31"

예시 2: 해상도가 국가별 국제 표준(예: 1920*1080, 3840*2160)으로 정의되어 있는 경우
오류 데이터) "2000*3000", "4000*2000"
정상 데이터) "1920*1080", "3840*2160"

예시 3: 언어가 국제 표준 ISO 639-1 언어 코드(en, ko)로 정의되어 있는 경우
오류 데이터) "English", "Korean"
정상 데이터) "en", "ko"

예시 4: 국가명이 ISO 3166-1 표준 국가 코드(Alpha-2 코드)로 정의되어 있는 경우
오류 데이터) "USA", "United States"
정상 데이터) "US", "KR"

예시 5: 화면비율이 국제 표준(16:9, 4:3, 21:9)으로 정의되어 있는 경우
오류 데이터) "20:10", "17:1"
정상 데이터) "16:9", "21:9"

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	PNG	객체 데이터 해상도	1920 × 1080 이상
메타데이터	파일명, 파일ID, 이미지 가로길이, 이미지 세로길이, 촬영 날짜, 촬영 위치, 촬영 각도, 작물 번호			메타데이터 파일 형식	json
어노테이션	객체 ID, 바운딩박스, 카테고리(카테고리명, 카테고리 값)			어노테이션 파일 형식	

※ 날짜 국제 표준 ISO 8601 형식 (YYYY-MM-DD)

● 데이터 세부 내용

파일명	구분	내용
CA_L5_D2024_001.json	메타데이터	{ ""IMAGES"": { "ID": 6700, "FILE_NAME": "CA_L5_D2024_001.jpg", "WIDTH": 1920, "HEIGHT": 1080, "DATE": "2024-09-24", "SHOOT_LOCATION": "경기-유리온식", "SHOOT_VIEW": "윗면", "CROP_NUM": "1" } },

● 오류 데이터

파일명	구분	내용
CA_L5_D2024_003.json	메타데이터	{ ""IMAGES"": { "ID": 6702, "FILE_NAME": "CA_L5_D2024_003.jpg", "WIDTH": 1920, "HEIGHT": 1080, "DATE": "2024/10/14", "SHOOT_LOCATION": "경기-유리온식", "SHOOT_VIEW": "윗면", "CROP_NUM": "3" } },

● 전체 데이터 확인

구분	file_name	DATE	확인 결과
1	CA_L5_D2024_001.json	2024-09-24	정상
2	CA_L5_D2024_002.json	2024-08-07	정상
3	CA_L5_D2024_003.json	2024/10/14	오류
4	CA_L5_D2024_004.json	2024-09-21	정상
5	CA_L5_D2024_005.json	2024-05-24	정상
6	CA_L5_D2024_006.json	2024-06-12	정상
7	CA_L5_D2024_007.json	2024-03-14	정상
8	CA_L5_D2024_008.json	2024-07-05	정상
9	CA_L5_D2024_009.json	2024-09-22	정상
10	CA_L5_D2024_010.json	2024/11/23	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

● 표준기반 데이터 접근성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 $= 1 - 2 / 10$
 $= 0.80$

이미지 예시 2

하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일명, 이미지 높이, 이미지 너비, 파일 사이즈, 기상 정보, 촬영장소, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 지역코드			메타데이터 파일 형식	json
어노테이션	어노테이션 객체 수, 어노테이션 유형(폴리곤), 어노테이션 라벨(산업 구분, 축사 유형, 축사 종류)			어노테이션 파일 형식	

※ 동경, 북위는 위도, 경도의 표준값으로 표기

● 데이터 세부 내용

파일명	구분	내용
L01_41220_130_20230831_N11_01340.tif	객체 데이터	
L01_41220_130_20230831_N11_01340.json	메타데이터	{ "IMAGES": { "ID": "304059", "FILE_NAME": "L01_41220_130_20230831_N11_01340.tif", "SEQUENCE": "01340", "HEIGHT": "512", "WIDTH": "512", "FILE_SIZE": "791338", "WEATHER": "맑음", "LOCATION": "한강", "DT_CD": "비점오염원", "REFSYS_NM": "GRS80", "EST_LONGITUDE": "126.9413958", "NOR_LATITUDE": "36.6439261", "FLG_ALTITUDE": "130", "FLG_DE": "202308311045", "FLH_MAN": "전동권", "FLG_MODEL": "EVO2PROV3", "RESOLUTION": "512", "INST_CD": "A04N", "CTPRVN_NM": "41220",

파일명	구분	내용
		"LABELCOUNT": "1"
	어노테이션	<pre> }, "ANNOTATIONS": [{ "DRAWING": "polygon", "SEGMENTATION": [0, 0, 0, 512, 512, 512, 512, 0, 175, 0], "CATEGORY_1": "농업계", "CATEGORY_2": "과수원", "CATEGORY_3": "해당없음" }] } </pre>

● 전체 데이터 확인

구분	file_name	EST_LONGITUDE	NOR_LATITUDE	확인 결과
1	L01_41220_130_2023 0831_N11_022240.tif	126.9413958	36.6439261	정상
2	L01_41220_132_2023 0831_N11_01110.tif	165.9413958	43.6439261	정상
3	L01_41330_130_2023 0831_N21_01340.tif	112.9413958	34.4439261	정상
4	L01_41233_130_2023 0831_N11_01340.tif	123.9413958	32.6768261	정상
5	L01_41110_130_2023 0831_N12_01340.tif	145.9413958	36.6345261	정상
6	L01_41110_130_202 30831_N21_54340.tif	136.9413958	36.6435361	정상
7	L01_41220_1770_202 30831_N11_08840.tif	166.9413958	36.6112261	정상
8	L01_41220_130_2023 0831_N11_01670.tif	126.9413958	36.6498266	정상
9	L01_41220_130_2023 0831_N11_01540.tif	116.9413958	36.6098261	정상
10	L01_41230_130_2023 0831_N11_01398.tif	1.995	36.261	오류

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 표준기반 데이터 접근성 = 1 - 오류 데이터 수 / 진단 총 데이터 수
 = 1 - 1 / 10
 = 0.90

4.6 유일성

유일성은 유일성이 요구되는 데이터가 유일한지 진단하는 기준으로 비정형 데이터에 대해 다음과 같은 심사 항목으로 평가한다.

■ (필수) 객체 유일성

비정형 객체가 중복되지 않고 유일한지를 확인하는 항목이다. 예를 들어, 동일한 이미지 파일이 데이터 셋에 중복 포함되지 않았는지를 확인한다. 파일명이 아닌 데이터의 내용의 동일성을 측정한다.

※ 파일명이 아닌 데이터의 내용의 동일성 측정

- ▶ **적용 대상:** 비정형 객체 데이터
- ▶ **정량화 수식:** $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 - 오류 데이터: 내용이 중복된 비정형 객체 데이터
 - 진단 데이터: 객체 유일성이 요구되는 비정형 객체 데이터



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 내용이 동일한 이미지 파일이 각각 다른 파일명으로 저장된 경우

오류 데이터) {파일1: sample_1.png, 내용: 태극기}, {파일2: sample_2.png, 내용: 태극기}

정상 데이터) {파일1: sample_1.png, 내용: 태극기}, {파일2: sample_2.png, 내용: 오륜기}

예시 2: 내용이 동일한 동영상 파일이 각각 다른 파일명으로 저장된 경우

오류 데이터) {파일1: sample_1.mp4, 내용: 태권도 1장}, {파일2: sample_2.mp4, 내용: 태권도 1장}

정상 데이터) {파일1: sample_1.mp4, 내용: 태권도 1장}, {파일2: sample_2.mp4, 내용: 복싱 스텝}

예시 3: 내용이 동일한 오디오 파일이 각각 다른 파일명으로 저장된 경우

오류 데이터) {파일1: sample_1.wav, 내용: 선언문 1p}, {파일2: sample_2.wav, 내용: 선언문 1p}

정상 데이터) {파일1: sample_1.wav, 내용: 선언문 1p}, {파일2: sample_2.wav, 내용: 선언문 3p}

예시 4: 내용이 동일한 텍스트 파일이 각각 다른 파일명으로 저장된 경우

오류 데이터) {파일1: 01.txt, 내용: "안녕하세요"}, {파일2: 02.txt, 내용: "안녕하세요"}

정상 데이터) {파일1: 01.txt, 내용: "안녕하세요"}, {파일2: 02.txt, 내용: "안녕하세요, 반갑습니다."}

이미지 예시 1

하천 유입 농축 산계 비점오염원 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	Tiff	객체 데이터 해상도	512 × 512 이상
메타데이터	파일명, 이미지 높이, 이미지 너비, 파일 사이즈, 기상 정보, 촬영장소, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 지역코드			메타데이터 파일 형식	json
어노테이션	어노테이션 객체 수, 어노테이션 유형(폴리곤), 어노테이션 라벨(산업 구분, 축사 유형, 축사 종류)			어노테이션 파일 형식	

● 객체 데이터



● 진단 총 데이터 수: 10

● 오류 데이터 수: 2

$$\begin{aligned}
 \text{객체 유일성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 2 / 10 \\
 &= 0.80
 \end{aligned}$$


이미지 예시 2

반려동물 보행 기반 건강 모니터링 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	12개 (이미지 객체 12장, json 파일 12개)				
객체 데이터 유형	이미지	객체 데이터 형식	JPG	객체 데이터 해상도	1920 × 1080 이상
메타데이터	파일이름, 수집병원, 파일형식, 이미지 크기, 수집장치, 해상도			메타데이터 파일 형식	json
어노테이션	KeyPoint 라벨링(x좌표, y좌표, 라벨명), 진료정보(발 위치, 중증도), 센서값, 타임스탬프, 강아지 크기, 연령, 강아지 종류			어노테이션 파일 형식	

● 객체 데이터



● 진단 총 데이터 수: 12

● 오류 데이터 수: 1

$$\begin{aligned}
 \text{객체 유일성} &= 1 - \text{오류 데이터 수} / \text{진단 총 데이터 수} \\
 &= 1 - 1 / 12 \\
 &= 0.92
 \end{aligned}$$

생성형 예시 1

공공 상담 대화 모델 학습 데이터

● 데이터 구조

– 문장 유사도 기준: 0.85 이상

데이터 구조	텍스트 객체, 텍스트 객체별 메타데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	5개 (텍스트 객체 5장, json 파일 5개)				
객체 데이터 유형	텍스트	객체 데이터 형식	json	문장 유사도 기준	0.85 이상
메타데이터	원천대상, 원천데이터 일련번호, 상담일시, 수집기관별 업무 유형, 상담자 유형, 상담자 연령대, 상담 시간, 상담 내용, 대화턴 수, 상담 내용 길이			메타데이터 파일 형식	json
어노테이션	tuning_type(분류/요약/질의응답), 지시문 아이디, 지시문 길이(어절 수), input 데이터 길이(어절 수), output 데이터 길이(어절 수), 지시문/질문, 원천데이터 상담 내용 전체 또는 일부			어노테이션 파일 형식	

※ 텍스트 문장 유사도는 ‘코사인 알고리즘’ 사용 (near-duplicate 탐지)

● 텍스트 객체 데이터 세부 내용

파일명	구분	내용
nn_410_card_1090.json	객체 데이터	<pre>[{ "source_id" : "nn_410_card_1090", "source" : "혜택카드", "consulting_date" : "", "consulting_category" : "선결제\즉시출금", "client_gender" : "여자", "client_age" : "50대", "consulting_turns" : "12", "consulting_length" : 160, "consulting_content" : "상담사: 상담원 ▲▲▲입니다. 무엇을 도와드릴까요?\n손님: 아 네, 그 제가 카드로 대출받은 거를 지금 인출 좀 해주셨으면 좋겠는데 계좌 번호가 ▲▲은행이 아니어서 혹시 다른,\n상담사: 그러세요? 지금 ▲▲▲ 님 본인 맞으실까요?\n손님: 네, 네.\n상담사: 네, 손님 지금 저희 쪽에 장기 카드 대출을 이용하신 금액이 있으신데요, 이 금액을 전액 상환하시겠습니까? 네, 그러시면 혹시 제가 즉시 출금을 바로 도와드릴까요? \n손님: 네,요청 건이 맞으십니까?\n손님: 네.\n상담사: 네, 출금 처리하겠습니다.\n손님: 예.\n상담사: 네, 완료되었습니다. 손님.\n손님: 네, 고맙습니다.\n상담사: 네, 상담원 ▲▲▲이었습니다.\n손님: 네." }]</pre>

● 오류 데이터

- 기존 객체 데이터와 비교했을 때, 임계값 0.85 이상인 데이터는 오류 데이터로 확인.

이름	유형	크기
nn_410_card_1094.json	JSON 원본 파일	3KB
nn_410_card_1093.json	JSON 원본 파일	3KB
nn_410_card_1092.json	JSON 원본 파일	3KB
nn_410_card_1091.json	JSON 원본 파일	3KB
nn_410_card_1090.json	JSON 원본 파일	3KB

- nn_410_card_1091.json 파일과 nn_410_card_1094.json 파일의 유사도가 0.944로 nn_410_card_1094.json 파일이 오류 데이터임.

코사인 유사도 행렬 (TF-IDF, char 3~5-gram)

	nn_410_card_1090.json	nn_410_card_1091.json	nn_410_card_1092.json	nn_410_card_1093.json	nn_410_card_1094.json
nn_410_card_1090.json	1.000	0.561	0.494	0.671	0.555
nn_410_card_1091.json	0.561	1.000	0.488	0.545	0.944
nn_410_card_1092.json	0.494	0.488	1.000	0.497	0.485
nn_410_card_1093.json	0.671	0.545	0.497	1.000	0.557
nn_410_card_1094.json	0.555	0.944	0.485	0.557	1.000

상위 유사 파일쌍 (threshold=0.85 이상 near-duplicate 의심)
nn_410_card_1091.json + nn_410_card_1094.json : 0.944

● 전체 데이터 확인

구분	객체명	유일성 여부 (Y/N)	확인 결과
1	nn_410_card_1090.json	Y	정상
2	nn_410_card_1091.json	Y	정상
3	nn_410_card_1092.json	Y	정상
4	nn_410_card_1093.json	Y	정상
5	nn_410_card_1094.json	N	오류

● 진단 총 데이터 수: 5

● 오류 데이터 수: 1

● 객체 유일성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 1 / 5$$

$$= 0.80$$

■ (선택) 레코드 유일성

데이터 레코드(논리적으로 연결된 하나의 단위로, 객체, 메타데이터, 어노테이션 등이 통합된 최소 단위)가 중복 없이 유일한지 심사하는 항목이다. 예를 들어, 모든 필드 값이 동일한 레코드가 있는지 확인한다.

▶ **적용 대상:** 데이터 레코드

▶ **정량화 수식:** 1 - 오류 데이터 수 / 진단 총 데이터 수

- 오류 데이터: 중복된 데이터 레코드
- 진단 데이터: 레코드 유일성이 요구되는 레코드



심사기준을 영상으로
확인하세요

데이터 예시

예시 1: 데이터 레코드가 객체 데이터와 어노테이션으로 구성된 경우

오류 데이터) 레코드가 다른 레코드와 객체 데이터와 어노테이션이 완전히 동일함
정상 데이터) 레코드가 다른 레코드와 객체 데이터, 어노테이션이 동일하지 않음

예시 2: 데이터 레코드가 객체 데이터와 메타데이터로 구성된 경우

오류 데이터) 레코드가 다른 레코드와 객체 데이터와 메타데이터가 완전히 동일함
정상 데이터) 레코드가 다른 레코드와 객체 데이터, 메타데이터가 동일하지 않음

예시 3: 데이터 레코드가 객체 데이터와 어노테이션, 메타데이터로 구성된 경우

오류 데이터) 레코드가 다른 레코드와 객체 데이터와 어노테이션, 메타데이터가 전부 완전히 동일함
정상 데이터) 레코드가 다른 레코드와 객체 데이터, 어노테이션, 메타데이터가 동일하지 않음

공공 상담 대화 모델 학습 데이터

텍스트 예시 1

● 데이터 구조

데이터 구조	텍스트 객체, 텍스트 객체별 메타데이터와 어노테이션으로 구성된 json 파일		
데이터 수량	10개 (텍스트 객체 10장, json 파일 10개)		
객체 데이터 유형	텍스트	객체 데이터 형식	JSON
메타데이터	상담일시, 소관부서, 업무 유형, 상담자 유형, 상담자 연령대, 상담시간, 상담내용	메타데이터 파일 형식	json
어노테이션	TuningType(분류/요약/질의응답), 카테고리, 지시문, 지시문/질문, 상담 내용, Output(분류명/요약문/답변)	어노테이션 파일 형식	

● 데이터 세부 내용

파일명	구분	내용
K_102007.json	객체 데이터	[{ "source_id": "K_102007", "source": "고용노동부", "consulting_date": "20220623", "consulting_category": "안전과", "client_gender": "", "client_age": "", "consulting_turns": "2", "consulting_length": 23, "consulting_content": "Q : 1. 「산업안전보건기준에 관한 규칙」 제13조제2호에서 중간의 기준이 딱 가운데 부분을 말하는 것인지, 예를 들어 100센티미터의 안전난간을 설치하려고 하면 50센티미터 지점에 중간 난간대를 설치해야 하는지? ", }]
분류_01_K_102007.json	메타데이터	"metadata": { "source": "고용노동부", "source_id": "K_102007", "consulting_date": "20220623", "consulting_category": "안전과", "consulting_time": "", "consulting_turns": "2", "consulting_length": "23", "consulting_content": "Q : 1. 「산업안전보건기준에 관한 규칙」 제13조제2호에서 중간의 기준이 딱 가운데 부분을 말하는 것인지, 예를 들어 100센티미터의 안전난간을 설치하려고 하면 50센티미터 지점에 중간 난간대를 설치해야 하는지? ", }
분류_01_K_102007.json	어노테이션	"instructions": [{ "tuning_type": "분류", "data": [{

파일명	구분	내용
		<pre>"task_category" : "상담 주제", "input_length" : "23", "output_length" : "1", "instruction" : "output" : "안전" }}</pre>

● 오류 예시

- 객체 데이터와 메타데이터, 어노테이션이 중복되는 레코드 존재

● 전체 데이터 확인

구분	file_name	객체 데이터, 메타 데이터, 어노테이션 중복 여부 (Y / N)	확인 결과
1	K_102001.json	N	정상
2	K_102002.json	N	정상
3	K_102003.json	N	정상
4	K_102004.json	N	정상
5	K_102005.json	N	정상
6	K_102006.json	N	정상
7	K_102007.json	N	정상
8	K_102008.json	Y	오류
9	K_102009.json	N	정상
10	K_102010.json	N	정상

● 진단 총 데이터 수: 10

● 오류 데이터 수: 1

● 레코드 유일성 = 1 - 오류 데이터 수 / 진단 총 데이터 수

$$= 1 - 1 / 10$$

$$= 0.90$$

이미지 예시 1

반려동물 구분을 위한 동물 이미지 데이터

● 데이터 구조

데이터 구조	이미지 객체, 이미지 객체별 메타 데이터와 어노테이션으로 구성된 json 파일				
데이터 수량	10개 (이미지 객체 10장, json 파일 10개)				
객체 데이터 유형	이미지	객체 데이터 형식	JPG	객체 데이터 해상도	512 × 512 이상
메타데이터	파일명, 이미지 높이, 이미지 너비, 파일 사이즈, 기상 정보, 촬영장소, 데이터명, 기준계명, 동경, 북위, 촬영고도, 촬영일시, 촬영자, 촬영기기, 촬영화질, 지역코드			메타데이터 파일 형식	json
어노테이션	어노테이션 객체 수, 어노테이션 유형(폴리곤), 어노테이션 라벨(산업 구분, 축사 유형, 축사 종류)			어노테이션 파일 형식	

● 데이터 세부 내용



파일명	구분	내용
20201029/cat-footpush-000239.jpg	객체 데이터	
20201029/cat-footpush-000239.json	어노테이션	<pre> "annotations": [{ "frame_number": 187, "species": "CAT", "bounding_box": { "x": 223, "y": 367, "width": 496, "height": 512 } },] </pre>



● 오류 데이터 예시

- 두 개 이상의 이름이 서로 다른 데이터에 대해서 이미지 파일과 어노테이션 파일의 내용이 완전하게 동일한 경우

구분	file_name	객체 이미지	species	확인 결과
1	20201029/cat-footpush-000231.jpg		CAT	정상
2	20201029/cat-footpush-000232.jpg		CAT	오류

● 전체 데이터 확인

구분	file_name	객체 이미지	species	확인 결과
1	20201029/cat-footpush-000231.jpg		CAT	정상
2	20201029/cat-footpush-000232.jpg		CAT	오류
3	20201029/cat-footpush-000233.jpg		CAT	정상
4	20201029/cat-footpush-000234.jpg		CAT	정상
5	20201029/cat-footpush-000235.jpg		CAT	정상

구분	file_name	객체 이미지	species	확인 결과
6	20201029/cat-footpush-000236.jpg		CAT	정상
7	20201029/cat-footpush-000237.jpg		CAT	정상
8	20201029/cat-footpush-000238.jpg		CAT	정상
9	20201029/cat-footpush-000239.jpg		CAT	정상
10	20201029/dog-footpush-000240.jpg		DOG	정상

● 진단 총 데이터 수: 10
 ● 오류 데이터 수: 1
 ● 레코드 유일성 = $1 - \text{오류 데이터 수} / \text{진단 총 데이터 수}$
 = $1 - 1 / 10$
 = 0.90

Ⅲ

인증 판정

1. 인증 판정 기준

III

인증 판정

1 인증 판정 기준

데이터 내용 인증은 데이터 구조 유형과 인증 등급 두 가지 기준을 조합하여 판정한다. 데이터 구조 유형은 데이터의 구조적 복잡도에 따라 구분하며, 인증 등급은 인증 데이터에 대해 수행한 심사 결과, 즉 품질기준 충족 수준에 따라 부여한다.

1.1 데이터 구조 유형 판정

데이터 구조 유형은 심사에 실제로 적용된 심사 항목을 기준으로 데이터의 복잡도를 평가하여 판정한다. 즉, 어떤 심사 항목들이 적용되었는지, 필수·선택 항목이 얼마나 포함되었는지를 종합적으로 판단하여 구조 유형을 결정한다. 데이터 구조 유형에 대한 판정 기준은 아래와 같다.

데이터 구조 유형	판정 기준
Complex-Type	적용 가능 필수 항목 모두 적용, 선택 항목 3개 이상 적용
Normal-Type	적용 가능 필수 항목 모두 적용, 선택 항목 3개 미만 적용
Simple-Type	필수 항목 일부 적용

정형 데이터의 필수 심사 항목 및 선택 심사 항목

정형 데이터의 심사 항목은 총 14개이며, 필수 심사 항목 7개, 선택 심사 항목 7개로 구성한다.

구분	데이터 품질기준	심사 항목
필수 심사 항목 (7개)	완전성(2개)	데이터 레코드 완전성, 데이터 값 완전성
	유효성(4개)	구문 유효성, 의미 유효성, 범위 유효성, 관계 유효성
	일관성(1개)	참조 무결 일관성
선택 심사 항목 (7개)	유효성(1개)	데이터 값 정밀성
	일관성(2개)	공통 어휘 일관성, 데이터 포맷 일관성
	정확성(2개)	메타데이터 정확성, 데이터 값 정확성
	접근성(1개)	표준기반 데이터 접근성
	유일성(1개)	데이터 값 유일성

정형 데이터 구조 유형 판정 예시

Complex-Type

● 데이터 명세서

테이블명	행정 인구 조사		분류	공공행정		
레코드 수	1000건		인증심사 환경	MySQL		
컬럼명	NOT NULL	범위		유효한 값	규칙(도메인,업무등)	중복 허용
		Min	Max			
기준년도	0	20210101	20221231	-	• YYYYMMDD	0
행정구코드	0			-	• 행정구 정보 테이블과 참조관계	0
행정구구분	0	-	-	시, 군, 구, 동		0
통계청 구역	0	-	-	-	• 숫자 13자리 • 업무 규칙: 통계청 구역 앞 2자리는 행정구 코드와 동일 • 표준 적용: 통계청 코드 사용	0
총인구수	0	0	100000	-	• 총인구수=취약 계층 수+ 취약계층 제외 수	0
취약 계층 수	0	0	100000	-	-	0
취약계층 제외 수	0	0	100000	-	-	0

테이블명	행정구 정보		분류	공공행정		
레코드 수	100건		인증심사 환경	MySQL		
컬럼명	NOT NULL	범위		유효한 값	규칙(도메인,업무등)	중복 허용
		Min	Max			
행정구코드	0	-	-	-	• 숫자 2자리	X
행정구명	0	-	-	-	-	0

● 심사 항목 적용 및 데이터 구조 유형 판정

데이터 구조 유형				Complex-Type	
필수항목			7개	선택항목	10개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	심사대상
1	필수	완전성	데이터 값 완전성	Y	기준년도, 행정구코드, 행정구, 통계청 구역, 총인구수, 취약 계층 수, 취약계층 제외 수,
2			데이터 레코드 완전성	Y	전체 레코드
3		유효성	구문 유효성	Y	기준년도, 행정구코드, 통계청 구역
4			의미 유효성	Y	행정구
5			범위 유효성	Y	기준년도, 총인구수, 취약 계층 수, 취약계층 제외 수
6			관계 유효성	Y	통계청 구역
7	선택	일관성	참조 무결 일관성	Y	행정 인구 조사 테이블의 행정구 코드
8		정확성	데이터 값 정확성	Y	총인구수
9		접근성	표준 기반 데이터접근성	Y	통계청 구역
10		유일성	데이터 값 유일성	Y	행정 인구 조사 테이블의 행정구 코드

정형 데이터 구조 유형 판정 예시

Normal-Type

● 데이터 명세서

테이블명		행정 인구 조사		분류		공공행정
레코드 수		1000건		인증심사 환경		MySQL
컬럼명	NOT NULL	범위		유효한 값	규칙(도메인,업무등)	중복 허용
		Min	Max			
기준년도	O	20210101	20221231	-	• YYYYMMDD	O
행정구코드	O			-	• 행정구 정보 테이블과 참조관계	O
행정구구분	O	-	-	시, 군, 구, 동		O
통계청 구역	O	-	-	-	• 숫자 13자리 • 업무 규칙: 통계청 구역 앞 2자리는 행정구 코드와 동일	O
총인구수	O	0	100000	-	• 총인구수=취약 계층 수+ 취약계층 제외 수	O
취약 계층 수	O	0	100000	-	-	O
취약계층 제외 수	O	0	100000	-	-	O

테이블명		행정구 정보		분류		공공행정
레코드 수		100건		인증심사 환경		MySQL
컬럼명	NOT NULL	범위		유효한 값	규칙(도메인,업무등)	중복 허용
		Min	Max			
행정구코드	O	-	-	-	• 숫자 2자리	X
행정구명	O	-	-	-	-	O

● 심사 항목 적용 및 데이터 구조 유형 판정

데이터 구조 유형				Normal-Type	
필수항목		7개	선택항목		2개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	심사대상
1	필수	완전성	데이터 값 완전성	Y	기준년도, 행정구코드, 행정구, 통계청 구역, 총인구수, 취약 계층 수, 취약계층 제외 수,
2			데이터 레코드 완전성	Y	전체 레코드
3		유효성	구문 유효성	Y	기준년도, 행정구코드, 통계청 구역
4			의미 유효성	Y	행정구
5			범위 유효성	Y	기준년도, 총인구수, 취약 계층 수, 취약계층 제외 수
6			관계 유효성	Y	통계청 구역
7		일관성	참조 무결 일관성	Y	행정 인구 조사 테이블의 행정구 코드
8	선택	정확성	데이터 값 정확성	Y	총인구수
9		유일성	데이터 값 유일성	Y	행정 인구 조사 테이블의 행정구 코드

정형 데이터 구조 유형 판정 예시

Simple-Type

● 데이터 명세서

데이터 명	행정 인구 조사		분류		공공행정	
레코드 수	1000건		인증심사 환경		MySQL	
컬럼명	NOT NULL	범위		유효한 값	규칙(도메인,업무등)	중복 허용
		Min	Max			
기준년도	O	20210101	20221231	-	• YYYYMMDD	O
행정구코드	O			-	• 숫자 2자리	O
행정구	O	-	-	행정구 목록		O
통계청 구역	O	-	-	-	• 숫자 13자리	O
총인구수	O	0	100000	-	• 총인구수=취약 계층 수+취약계층 제외 수	O
취약 계층 수	O	0	100000	-	-	O
취약계층 제외 수	O	0	100000	-	-	O

● 심사 항목 적용 및 데이터 구조 유형 판정

데이터 구조 유형				Simple-Type	
필수항목		5개		선택항목	1개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	심사대상
1	필수	완전성	데이터 값 완전성	Y	기준년도, 행정구코드, 행정구, 통계청 구역, 총인구수, 취약 계층 수, 취약계층 제외 수,
2			데이터 레코드 완전성	Y	전체 레코드
3		유효성	구문 유효성	Y	기준년도, 행정구코드, 통계청 구역
4			의미 유효성	Y	행정구
5			범위 유효성	Y	기준년도, 총인구수, 취약 계층 수, 취약계층 제외 수
6	선택	정확성	데이터 값 정확성	Y	총인구수

● 비정형 데이터의 필수 심사 항목 및 선택 심사 항목

비정형 데이터의 심사 항목은 총 24개이며, 필수 심사 항목 9개, 선택 심사 항목 15개로 구성한다.

구분	데이터 품질기준	심사 항목
필수 심사 항목 (9개)	완전성(3개)	데이터 파일 완전성, 레코드 완전성, 메타데이터 값 완전성
	유효성(3개)	데이터 구조 구문 유효성, 데이터 포맷 유효성, 객체 유효성
	정확성(2개)	구문 정확성, 메타데이터 정확성
	유일성(1개)	객체 유일성
선택 심사 항목 (15개)	완전성(2개)	어노테이션 완전성, 특징 완전성
	유효성(6개)	관계 유효성, 데이터 값 정밀성, 데이터 속성 유효성, 범위 유효성, 시간 유효성, 어노테이션 유효성
	일관성(2개)	공통 어휘 일관성, 데이터 포맷 일관성
	정확성(2개)	어노테이션 정확성, 주제 정확성
	접근성(2개)	데이터 포맷 접근성, 표준기반 데이터 접근성
	유일성(1개)	레코드 유일성

비정형 데이터 구조 유형 판정 예시

Complex-Type

● 데이터 명세서

객체 데이터 구조 유형	이미지	데이터 형식	*.png,	파일수	1000개
라벨링 유형	클래스 분류	라벨링 형식	json	파일수	1000개
메타 데이터 정보	이미지 해상도, 컬러심도	메타 데이터 형식	csv	파일수	1개
객체 데이터 기준		해상도 1024*1024 이상, 컬러심도 24			

● 어노테이션 구조

어노테이션 구조					
속성명	타입	필수 여부	설명	규칙, 범위, 유효한 값	비고
folder	string	Y	파일 경로		
filename	string	Y	파일명		
time	string	Y	시간	hh:mm:ss	
motion	string	Y	모션	앞기, 서기, 눕기	

● 메타데이터 구조

메타데이터 구조						
컬럼명	NOT NULL	범위		유효한 값	규칙(도메인,업무등)	중복 허용
		Min	Max			
파일명	O	0				O
확장자	O	0		png		O
해상도	O	0				O
컬러심도	O	0				O

● 심사 항목 적용 및 데이터 구조 유형 판정

데이터 구조 유형				Complex-Type	
필수항목		9개		선택항목	5개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	심사대상
1	필수	완전성	데이터 파일 완전성	Y	객체데이터 파일, 어노테이션 데이터 파일, 메타데이터 파일
2			레코드 완전성	Y	객체데이터 파일, 어노테이션 데이터 파일, 메타데이터 파일
3			메타데이터 값 완전성	Y	메타 데이터의 파일명, 확장자, 해상도, 컬러심도
4		유효성	데이터 구조 구문 유효성	Y	어노테이션 데이터 파일, 메타데이터 파일
5			데이터 포맷 유효성	Y	객체데이터 파일
6			객체 유효성	Y	객체데이터 파일
7		정확성	구문 정확성	Y	어노테이션의 time
8			메타데이터 정확성	Y	메타데이터의 파일명, 확장자, 해상도, 컬러심도
9		유일성	객체 유일성	Y	객체데이터 파일
10	선택	완전성	어노테이션 완전성	Y	어노테이션 데이터의 folder, filename, time, motion
11		유효성	데이터 속성 유효성	Y	객체데이터 해상도, 컬러심도
12		정확성	어노테이션 정확성	Y	유효한 어노테이션의 motion
13		접근성	데이터 포맷 접근성	Y	객체데이터 파일 포맷
14		유일성	레코드 유일성	Y	객체데이터 파일

비정형 데이터 구조 유형 판정 예시

Normal-Type

● 데이터 명세서

객체 데이터 구조 유형	이미지	데이터 형식	png, jpg	파일수	1000개
메타데이터 정보	이미지 해상도, 컬러심도	메타데이터 형식	csv	파일수	1개

● 메타데이터 구조

메타데이터 구조						
컬럼명	NOT NULL	범위		유효한 값	규칙(도메인,업무등)	중복 허용
		Min	Max			
파일명	O	0				O
확장자	O	0		png, jpg		O
해상도	O	0				O
컬러심도	O	0				O

● 심사 항목 적용 및 데이터 구조 유형 판정

데이터 구조 유형				Normal-Type		
필수항목		9개		선택항목		2개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	심사대상	
1	필수	완전성	데이터 파일 완전성	Y	객체데이터 파일, 어노테이션 데이터 파일, 메타데이터 파일	
2			레코드 완전성	Y	객체데이터 파일, 어노테이션 데이터 파일, 메타데이터 파일	
3			메타데이터 값 완전성	Y	메타데이터의 파일명, 확장자, 해상도, 컬러심도	
4		유효성	데이터 구조 구문 유효성	Y	어노테이션 데이터 파일, 메타데이터 파일	
5			데이터 포맷 유효성	Y	객체데이터 파일	
6			객체 유효성	Y	객체데이터 파일	
7		정확성	구문 정확성	Y	메타데이터의 확장자	
8			메타데이터 정확성	Y	메타데이터의 파일명, 확장자, 해상도, 컬러심도	
9		유일성	객체 유일성	Y	객체데이터 파일	
10	선택	접근성	데이터 포맷 접근성	Y	객체데이터 파일 포맷	
11		유일성	레코드 유일성	Y	객체데이터 파일	

비정형 데이터 구조 유형 판정 예시

Simple-Type

● 데이터 명세서

객체 데이터 구조 유형	이미지	데이터 형식	*.png,	파일수	1000개
메타데이터 정보	이미지 해상도, 컬러심도	메타데이터 형식	csv	파일수	1개

● 메타데이터 구조

메타데이터 구조						
컬럼명	NOT NULL	범위		유효한 값	규칙(도메인,업무등)	중복 허용
		Min	Max			
파일명	O	0				O
확장자	O	0		png		O
해상도	O	0				O
컬러심도	O	0				O

● 심사 항목 적용 및 데이터 구조 유형 판정

데이터 구조 유형			Simple-Type		
필수항목		8개	선택항목		2개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	심사대상
1	필수	완전성	데이터 파일 완전성	Y	객체데이터 파일, 어노테이션 데이터 파일, 메타 데이터 파일
2			레코드 완전성	Y	객체데이터 파일, 어노테이션 데이터 파일, 메타 데이터 파일
3			메타데이터 값 완전성	Y	메타데이터의 파일명, 확장자, 해상도, 컬러심도
4		유효성	데이터 구조 구문 유효성	Y	어노테이션 데이터 파일, 메타데이터 파일
5			데이터 포맷 유효성	Y	객체데이터 파일
6			객체 유효성	Y	객체데이터 파일
7		정확성	메타데이터 정확성	Y	메타데이터의 파일명, 확장자, 해상도, 컬러심도
8		유일성	객체 유일성	Y	객체데이터 파일
9	선택	접근성	데이터 포맷 접근성	Y	객체데이터 파일 포맷
10		유일성	레코드 유일성	Y	객체데이터 파일

1.2 데이터 등급 판정

데이터 등급은 데이터 내용에 대한 심사 결과를 바탕으로 결정한다. 먼저 각 심사 항목에 대해 데이터 품질 점수를 산정하고, 품질 점수에 따라 최종 등급(Class A, B, C)을 판정한다.

▶ 심사 결과 데이터 품질에 따라 등급 구분

인증 등급	기준
Class A	모든 개별 심사 항목이 최소 0.95 이상이고, 데이터 품질 점수 0.99 이상
Class B	모든 개별 심사 항목이 최소 0.95 이상이고, 데이터 품질 점수 0.97 이상
Class C	모든 개별 심사 항목이 최소 0.95 이상이고, 데이터 품질 점수 0.95 이상

정형 데이터 인증 등급 판정 예시

Class A

데이터 구조 유형		Complex-Type			인증 등급	Class A
필수항목		7개			선택항목	3개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	정량화 수식	점 수
1	필수	완전성	데이터 값 완전성	Y	$X = 1 - (A / B)$ - A = 'NULL'이 포함된 데이터 아이템의 수 - B = 'NOT NULL'로 선언된 전체 데이터 아이템의 수	1.00
2			데이터 레코드 완전성	Y	$X = 1 - (A / B)$ - A = 모든 데이터 아이템 값이 비어있는 레코드의 수 - B = 전체 데이터 파일 안의 레코드의 수	1.00
3	필수	유효성	구문 유효성	Y	$X = 1 - (A / B)$ - A = 구문적으로 유효한 관련 값을 갖지 않는 데이터 아이템 개수 - B = 구문의 유효성이 요구되는 전체 데이터 아이템 개수	1.00
4			의미 유효성	Y	$X = 1 - (A / B)$ - A = 의미상으로 유효하지 않는 값이 있는 데이터 아이템의 개수 - B = 의미론적 유효성이 요구되는 전체 데이터 아이템의 개수	1.00

5			범위 유효성	Y	• $X = 1 - (A / B)$ • A = 지정된 범위(숫자) 안에 벗어난 값이 있는 데이터 아이템의 개수 • B = 범위(숫자)가 정의된 전체 데이터 아이템의 개수	1.00	
6			관계 유효성	Y	• $X = 1 - (A / B)$ • A = 올바른 관계를 갖지 않는 값이 있는 데이터 아이템의 개수 • B = 컬럼과 컬럼간의 관계 규칙이 정의된 전체 데이터아이템의 개수	1.00	
7			일관성	참조 무결 일관성	Y	• $X = 1 - (A / B)$ • A = 참조 무결성에 위배되는 데이터 아이템의 개수 • B = 참조 무결성이 정의된 전체 데이터 아이템의 개수	1.00
8	선택	정확성	데이터 값 정확성	Y	• $X = 1 - (A / B)$ • A = 기대에 위배되는 값이 있는 데이터 아이템의 개수 • B = 기대되는 값이 정의된 전체 데이터 아이템의 개수	0.98	
9		접근성	표준 기반 데이터접 근성	Y	• $X = 1 - (A / B)$ • A = 표준, 협약 또는 규정을 위배하는 포맷을 갖는 데이터 아이 템의 개수 • B = 표준, 협약 또는 규정에 부합해야 하는 전체 데이터 아이템 의 개수	1.00	
10		유일성	데이터 값 유일성	Y	• $X = 1 - (A / B)$ • $A = \sum k1 (Ak-1)$ • B = 해당 컬럼에서 값이 있는 전체 데이터 아이템의 개수 ※ k는 값의 종류 수이고 Ak는 특정 값으로 중복 값이 있는 데이터 아이템의 개수	0.95	
데이터 품질 점수							0.99

정형 데이터 인증 등급 판정 예시					Class B	
데이터 구조 유형			Simple-Type		인증 등급	Class B
필수항목			5개		선택항목	1개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	정량화 수식	점수
1	필수	완전성	데이터 값 완전성	Y	• $X = 1 - (A / B)$ • A = 'NULL'이 포함된 데이터 아이템의 수 • B = 'NOT NULL'로 선언된 전체 데이터 아이템의 수	1.00
2			데이터 레코드 완전성	Y	• $X = 1 - (A / B)$ • A = 모든 데이터 아이템 값이 비어있는 레코드의 수 • B = 전체 데이터 파일 안의 레코드의 수	1.00
3		유효성	구문 유효성	Y	• $X = 1 - (A / B)$ • A = 구문적으로 유효한 관련 값을 갖지 않는 데이터 아이템 개수 • B = 구문의 유효성이 요구되는 전체 데이터 아이템 개수	0.98
4			의미 유효성	Y	• $X = 1 - (A / B)$ • A = 의미상으로 유효하지 않는 값이 있는 데이터 아이템의 개수 • B = 의미론적 유효성이 요구되는 전체 데이터 아이템의 개수	0.95
5			범위 유효성	Y	• $X = 1 - (A / B)$ • A = 지정된 범위(숫자) 안에 벗어난 값이 있는 데이터 아이템의 개수 • B = 범위(숫자)가 정의된 전체 데이터 아이템의 개수	0.98
6	선택	정확성	데이터 값 정확성	Y	• $X = 1 - (A / B)$ • A = 기대에 위배되는 값이 있는 데이터 아이템의 개수 • B = 기대되는 값이 정의된 전체 데이터 아이템의 개수	0.98
데이터 품질 점수						0.98

정형 데이터 인증 등급 판정 예시

Class C

데이터 구조 유형			Normal-Type		인증 등급	Class C
필수항목			7개		선택항목	1개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	정량화 수식	점수
1	필수	완전성	데이터 값 완전성	Y	$X = 1 - (A / B)$ - A = 'NULL'이 포함된 데이터 아이템의 수 - B = 'NOT NULL'로 선언된 전체 데이터 아이템의 수	0.95
2			데이터 레코드 완전성	Y	$X = 1 - (A / B)$ - A = 모든 데이터 아이템 값이 비어있는 레코드의 수 - B = 전체 데이터 파일 안의 레코드의 수	0.95
3		유효성	구문 유효성	Y	$X = 1 - (A / B)$ - A = 구문적으로 유효한 관련 값을 갖지 않는 데이터 아이템 개수 - B = 구문의 유효성이 요구되는 전체 데이터 아이템 개수	0.95
4			의미 유효성	Y	$X = 1 - (A / B)$ - A = 의미상으로 유효하지 않는 값이 있는 데이터 아이템의 개수 - B = 의미론적 유효성이 요구되는 전체 데이터 아이템의 개수	0.95
5			범위 유효성	Y	$X = 1 - (A / B)$ - A = 지정된 범위(숫자) 안에 벗어난 값이 있는 데이터 아이템의 개수 - B = 범위(숫자)가 정의된 전체 데이터 아이템의 개수	0.95
6			관계 유효성	Y	$X = 1 - (A / B)$ - A = 올바른 관계를 갖지 않는 값이 있는 데이터 아이템의 개수 - B = 컬럼과 컬럼간의 관계 규칙이 정의된 전체 데이터 아이템의 개수	0.95
7		일관성	참조 무결 일관성	Y	$X = 1 - (A / B)$ - A = 참조 무결성에 위배되는 데이터 아이템의 개수 - B = 참조 무결성이 정의된 전체 데이터 아이템의 개수	0.95
8	선택	정확성	데이터 값 정확성	Y	$X = 1 - (A / B)$ - A = 기대에 위배되는 값이 있는 데이터 아이템의 개수 - B = 기대되는 값이 정의된 전체 데이터 아이템의 개수	0.95
데이터 품질 점수						0.95

비정형 데이터 인증 등급 판정 예시					Class A	
데이터 구조 유형			Normal-Type		인증 등급	Class A
필수항목			9개		선택항목	1개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	정량화 수식	점수
1	완전성	완전성	데이터 파일 완전성	Y	• $X = 1 - A / B$ • A = 명시된 데이터에 부족한 파일 수 • B = 요구명세서나 상품 설명서 등 명세서에 명시된 파일 수	1.00
2			레코드 완전성	Y	• $X = 1 - A / B$ • A = 빈 데이터 아이템이 없는 데이터셋의 데이터 레코드 수 • B = 데이터셋의 총 레코드 수	1.00
3			메타데이 터 값 완전성	Y	• $X = 1 - A / B$ • A = 메타데이터가 존재하지 않거나 메타데이터 내 필수 항목이 NULL인 데이터 객체 데이터 수 • B = 비정형 객체 데이터 수	1.00
4	필수	유효성	데이터 구조 구문 유효성	Y	• $X = 1 - A / B$ • A = 비정형 객체의 메타데이터나 라벨링 데이터의 구조가 정의된 구조에 적합하지 않은 레코드 수 • B = 비정형 객체 데이터(레코드) 수	1.00
5			데이터 포맷 유효성	Y	• $X = 1 - A / B$ • A = 정의된 파일 포맷을 준수하지 않는 데이터 파일 개수 • B = 전체 데이터 개수	1.00
6			객체 유효성	Y	• $X = 1 - A / B$ • A = 실제 활용할 수 없는 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	1.00
7	정확성	정확성	구문 정확성	Y	• $X = 1 - A / B$ • A = 구문적으로 정확한 관련 값을 갖지 않는 데이터 아이템 수 • B = 구문의 정확성이 요구되는 데이터 아이템 수	1.00
8			메타데이 터 정확성	Y	• $X = 1 - A / B$ • A = 메타데이터가 정확하지 않은 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.99
9	유일성	유일성	객체 유일성	Y	• $X = 1 - A / B$ • A = 중복 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	1.00
10	선택	접근성	데이터 포맷 접근성	Y	• $X = 1 - A / B$ • A = 일반적인 데이터 포맷 아닌 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
데이터 품질 점수						0.99

비정형 데이터 인증 등급 판정 예시

Class B

데이터 구조 유형			Simple-Type		인증 등급	Class B
필수항목			8개		선택항목	2개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	정량화 수식	점수
1	필수	완전성	데이터 파일 완전성	Y	• $X = 1 - A / B$ • A = 명시된 데이터에 부족한 파일 수 • B = 요구명세서나 상품 설명서 등 명세서에 명시된 파일 수	1.00
2			레코드 완전성	Y	• $X = 1 - A / B$ • A = 빈 데이터 아이템이 있는 데이터셋의 데이터 레코드 수 • B = 데이터셋의 총 레코드 수	1.00
3			메타데이터 값 완전성	Y	• $X = 1 - A / B$ • A = 메타데이터가 존재하지 않거나 메타데이터 내 필수 항목이 NULL인 데이터 객체 데이터 수 • B = 비정형 객체 데이터 수	1.00
4		유효성	데이터 구조 구문 유효성	Y	• $X = 1 - A / B$ • A = 비정형 객체의 메타데이터나 라벨링 데이터의 구조가 정의된 구조에 적합하지 않은 레코드 수 • B = 비정형 객체 데이터(레코드) 수	1.00
5			데이터 포맷 유효성	Y	• $X = 1 - A / B$ • A = 정의된 파일 포맷을 준수하지 않는 데이터 파 일 개수 • B = 전체 데이터 개수	1.00
6			객체 유효성	Y	• $X = 1 - A / B$ • A = 실제 활용할 수 없는 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
7		정확성	메타데이터 정확성	Y	• $X = 1 - A / B$ • A = 메타데이터가 정확하지 않은 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
8		유일성	객체 유일성	Y	• $X = 1 - A / B$ A = 중복 비정형 객체 데이터 수 B = 비정형 객체 데이터 수	0.96
9	선택	접근성	데이터 포맷 접근성	Y	• $X = 1 - A / B$ • A = 일반적인 데이터 포맷 아닌 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	1.00
10		유일성	레코드 유일성	Y	• $X = 1 - A / B$ • A = 중복되는 데이터 레코드 수 • B = 데이터 레코드 수	0.96
데이터 품질 점수						0.98

비정형 데이터 인증 등급 판정 예시

Class C

데이터 구조 유형			Complex-Type		인증 등급	Class C
필수항목			9개		선택항목	5개
심사 번호	지표 구분	심사 기준	심사 항목	심사 여부	정량화 수식	점수
1	완전성	완전성	데이터 파일 완전성	Y	• $X = 1 - A / B$ • A = 명시된 데이터에 부족한 파일 수 • B = 요구명세서나 상품 설명서 등 명세서에 명시된 파일 수	0.95
2			레코드 완전성	Y	• $X = 1 - A / B$ • A = 빈 데이터 아이템이 있는 데이터셋의 데이터 레코드 수 • B = 데이터셋의 총 레코드 수	0.95
3			메타데이터 값 완전성	Y	• $X = 1 - A / B$ • A = 메타데이터가 존재하지 않거나 메타데이터 내 필수 항목이 NULL인 데이터 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
4	필수	유효성	데이터 구조 구문 유효성	Y	• $X = 1 - A / B$ • A = 비정형 객체의 메타데이터나 라벨링 데이터의 구조가 정의된 구조에 적합하지 않은 레코드 수 • B = 비정형 객체 데이터(레코드) 수	0.95
5			데이터 포맷 유효성	Y	• $X = 1 - A / B$ • A = 정의된 파일 포맷을 준수하지 않는 데이터 파일 개수 • B = 전체 데이터 개수	0.95
6			객체 유효성	Y	• $X = 1 - A / B$ • A = 실제 활용할 수 없는 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
7	정확성	정확성	구문 정확성	Y	• $X = 1 - A / B$ • A = 구문적으로 정확한 관련 값을 갖지 않는 데이터 아이템 수 • B = 구문의 정확성이 요구되는 데이터 아이템 수	0.95

8		메타데이터 정확성	Y	• $X = 1 - A / B$ • A = 메타데이터가 정확하지 않은 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
9	유일성	객체 유일성	Y	• $X = 1 - A / B$ • A = 메타데이터가 정확하지 않은 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
10	완전성	어노테이션 완전성	Y	• $X = 1 - A / B$ • A = 어노테이션 데이터가 누락된 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
11	유효성	데이터 속성 유효성	Y	• $X = 1 - A / B$ • A = 명시된 기준에 부합하지 않는 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
12	선택	정확성	Y	• $X = 1 - A / B$ • A = 어노테이션이 정확하지 않은 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
13	접근성	데이터 포맷 접근성	Y	• $X = 1 - A / B$ • A = 일반적인 데이터 포맷이 아닌 비정형 객체 데이터 수 • B = 비정형 객체 데이터 수	0.95
14	유일성	레코드 유일성	Y	• $X = 1 - A / B$ • A = 중복되는 데이터 레코드 수 • B = 데이터 레코드 수	0.95
데이터 품질 점수					0.95

IV

인증심의

1. 인증심의위원회

2. 인증심의 기준 및 의결

IV 인증심의

1 인증심의위원회

1.1 구성 및 역할

■ 심의위원회 구성

심의위원회는 3인 이상 10인 이내의 위원으로 구성하며 위원장은 위원 중에서 호선(互選)한다. 심의위원은 학계, 산업계, 연구계, 정부기관 등 데이터 품질인증 관련 분야에서 학식·경력·경험이 풍부한 자 중에서 인증기관의 장이 위촉 또는 임명한다.

■ 심의위원회 역할

심의위원회는 다음과 같은 사항을 심의·조정·의결한다.

- ▶ 심사 절차 및 심사 과정의 적합 여부 심의
- ▶ 인증 결과에 따른 인증 취소 및 이의신청 관련 사항
- ▶ 그 밖에 데이터 품질인증과 관련하여 심의·조정·의결이 필요한 사항

1.2 운영 및 제척

■ 심의위원회 운영

심의위원회는 매월 1회 정기적으로 개최하며, 인증기관의 요청에 따라 수시로 임시회의를 개최할 수 있다. 인증기관의 장은 회의를 소집할 때, 회의 안건·일시·장소 등을 회의 개최 7일 전까지 위원에게 통지해야 하며 심의위원회는 재적 위원 과반수 출석으로 개의하고, 출석 위원 과반수의 찬성으로 의결한다.

■ 심의위원 제척 사유

심의위원은 다음 사유에 해당하는 경우 심의에서 제척된다.

- ▶ 최근 3년 이내 신청인 회사에 재직한 경력이 있는 경우
- ▶ 최근 3년 이내 신청인의 데이터 품질 관련 컨설팅을 수행한 경우
- ▶ 신청인의 대표 또는 운영진과 친족관계에 있거나 있었던 경우
- ▶ 그 외 공정하고 객관적인 심의 수행이 어렵다고 판단되는 경우

2

인증심의 기준 및 의결

데이터 품질인증의 객관성과 공정성을 확보하기 위해, 심사 결과를 인증심의위원회의 인증심의를 통해 최종 인증 가부를 결정한다.

2.1 인증심의

■ 인증심의 내용

인증심의위원회는 심의 대상 자료를 바탕으로 심사 기준의 적정성, 심사 방법의 적정성, 심사 결과의 타당성을 심의한다.

- ▶ 심사 기준의 적정성: DQ인증대상별로 적합한 품질기준이 적용되었는지 검토
- ▶ 심사 방법의 적정성: 심사 과정에서 사용된 방법이 인증대상의 특성, 데이터의 구조 및 용도, 인증 목적에 부합하는지 검토
- ▶ 심사 결과의 타당성: 심사 결과가 객관적 기준과 근거에 따라 도출되었는지 확인
- ▶ 기타 검토 사항: 공정성 확보를 위해 추가적으로 필요한 사항 심의

2.2 인증심의 절차 및 기준

■ 인증심의 대상 자료

- (인증심의) 심사결과보고서*, 심사종합의견서**
- (인증정지·정지해제·취소) 신청인의 근거 자료
- (이의신청) 이의제기 신청서, 이의제기 신청에 대한 인증기관 검토 의견

* 심사결과보고서 : 공정성, 객관성 확보를 위해 심의 상정 시 업체명, 의뢰 대상명은 비식별(무기명) 처리하여 상정

** 심사종합의견서: 인증대상 개요, 신청 및 심사 과정의 일정, 심사 결과 인증 기준에 따라 환산한 심사 점수, 심의 과정에서 확인된 품질 이슈 등 보고서

■ 인증심의 절차

정족수 확인 및 개회 선언 → 심사결과보고서 상정 → 심의 및 질의 응답 → 의결 진행

■ 인증심의 개회 및 판정 기준

재적 위원 과반수 출석 시 회의를 개최할 수 있다. 인증 여부는 출석 위원 과반수의 찬성으로 판정한다.

2.3 인증심의 중 자주 나오는 의견 및 질의

인증심의 과정에서는 다음과 같은 사항에 대한 질문과 논의가 자주 이루어진다.

- ▶ 데이터 오류에 대해 신청기관과 어떤 합의가 이루어졌는지
- ▶ 남아 있는 오류 데이터의 구체적인 현황과 향후 수정 계획
- ▶ 특정 오류 데이터에 대해 예외 처리가 허용된 사유와 타당성
- ▶ 수정이 불가능한 데이터에 대한 상세 정보와 사유

이러한 질의와 논의는 인증의 공정성을 확보하고, 향후 유사 사례에 대한 판단 기준을 축적하기 위한 과정이기도 하다.

2.4 인증심의 부결 사례

다음과 같은 경우에는 인증심의위원회에서 인증 부결로 판정될 수 있다.

- ▶ 심사 대상 컬럼이 심사 과정에서 누락된 사실이 확인된 경우
- ▶ 수정이 불가능하거나 현실적으로 시정이 어려운 오류가 치명적 또는 중대한 영향을 미치는 경우
- ▶ 필수 심사 항목이 누락되어, 정해진 심사 기준을 충족하지 못한 경우
- ▶ 남아 있는 오류 데이터가 데이터 활용 목적에 중대한 문제를 일으키거나, 안전성·신뢰성·법적 리스크 등에 치명적인 결과를 초래할 우려가 있는 경우

이와 같은 사유가 발생하면, 인증심의위원회는 신청기관에 보완을 권고하거나, 추가 심사 또는 재심의를 조건으로 부결 결정을 내릴 수 있다.

부 록

1. 자주하는 질문(FAQ)
2. 용어집
3. 참고문헌

부록

① 자주하는 질문(FAQ)

Q.1 DQ인증은 어떻게 활용할 수 있나요?

데이터 품질인증은 다음과 같은 용도로 활용할 수 있습니다.

- ▶ 유통 목적의 제3자 품질 검수: 데이터 거래 시 품질을 보장하는 근거 자료로 활용 가능
- ▶ 데이터 기반 서비스의 품질 확보: 내부 데이터 품질진단과 개선 활동에 활용
- ▶ 정부 지원 사업 가점: 데이터 바우처 사업 등에서 추가 점수를 받을 수 있음

Q.2 필수 심사 항목을 적용하는 기준은 무엇인가요?

인증제도의 품질기준에 따라 명세서에 정의된 내용이나, 데이터 특성이 선정 기준을 충족하면 반드시 심사해야 하는 항목입니다. 데이터의 완전성, 유효성, 일관성 등 핵심 품질기준을 평가하며, 데이터 품질의 기본 요건을 충족하는지를 확인합니다.

Q.3 데이터의 유형은 어떻게 적용되나요?

데이터는 정형 데이터와 비정형 데이터로 구분됩니다. 정형 데이터는 표, 데이터베이스 등의 구조화된 데이터를 대상으로 심사합니다. 비정형 데이터는 이미지, 동영상, 오디오, 텍스트와 같은 비구조화된 데이터로, 관련 품질기준에 따라 평가됩니다.

Q.4 비정형 데이터도 심사하나요?

네, 비정형 데이터도 심사대상에 포함됩니다. ISO/IEC 5259-2, TTA.KO-10.1344-Part2, NIA 학습용 데이터 품질 관리 가이드를 기반으로 품질기준과 심사 항목을 적용합니다.

Q.5 비정형 데이터의 경우, 의미 정확성을 샘플링하는 기준은 무엇인가요?

비정형 데이터의 의미 정확성은 표본 크기와 데이터의 다양성을 고려하여 샘플링합니다. 샘플링 크기는 데이터 셋의 크기, 데이터 유형, 활용 목적에 따라 다르며, 국제 표준 및 인증기관의 가이드라인을 준수합니다.

Q.6 DQ인증 신청 시 제출서류는 무엇인가요?

데이터 내용 인증은 DQ인증 신청 시 다음과 같은 서류를 제출합니다.

구분	세부 내용
테이블 정의서	테이블명, 엔티티 정보 등을 정의한 문서
항목 정의서	데이터 항목 정보를 정의한 문서
코드 정의서	컬럼에 기재된 각 코드 정보를 정의한 문서
ERD(객체관계도)	각 엔티티 간의 관계도
항목에 적용된 도메인 규칙 및 업무규칙	각 항목 별로의 연관성을 분석할 수 있는 문서
메타데이터 정의서(작업지시서)	데이터(비정형 객체 등) 수집, 정제, 라벨링, 전처리 수행을 위한 기준, 방법 등을 정의한 문서

데이터 관리체계 인증은 신청 시 다음과 같은 서류를 제출합니다.

구분	세부 내용
데이터 품질관리지침 또는 업무 매뉴얼	인증대상 프로젝트(조직)의 데이터 품질관리 기준, 수행 절차 및 방법을 정의한 지침 또는 업무 매뉴얼 등 문서
조직 정보	인증대상 조직을 정의한 조직도, 데이터 품질관리 업무 분장표 등 문서

다만, 제출 서류 목록은 인증 관련 안내·상담 과정에서 심사대상의 특성에 따라 협의하여 변경 가능합니다.

Q.7 DQ인증심사 기간은 얼마나 되나요?

데이터 내용 인증심사 기간은 평균 7일~11일 정도 소요되며, 데이터의 컬럼수와 복잡도에 따라 변경될 수 있습니다. 데이터 관리체계 심사 기간은 관리체계 조직의 규모에 따라 5일~15일 정도 소요됩니다.

Q.8 심사 기간에 부적합이나 오류 데이터가 발견되면, 어떻게 하나요?

1차 심사 과정에서 부적합 항목이나 오류 데이터가 발견될 경우, 신청기관은 오류 수정 기회를 제공받아 개선 작업을 수행할 수 있습니다. 데이터 오류 수정은 원칙적으로는 1회(수정 기간 14일 이내)이며, 추가 수정은 인증기관과 협의 후 가능합니다.

Q.9 인증심의위원회는 어떻게 구성되나요?

인증심의위원회는 데이터 관리 및 데이터 품질 분야의 학계와 산업계 등 외부 전문가들로 구성되어 독립적이고 공정한 심사를 보장합니다. 또한, 과학기술정보통신부를 비롯한 외부 기관은 인증기관의 인증심의위원 위촉에 직접 관여하지 않습니다.

Q.10 데이터 품질인증의 유효기간은 얼마인가요?

데이터 내용 인증의 유효기간은 1년입니다. 데이터 관리체계 인증의 유효기간은 3년이며, 최초 인증 후 매년 사후심사를 통해 관리됩니다.

Q.11 DQ인증 마크는 어떻게 사용할 수 있나요?

인증 마크 사용에 관한 내용은 다음과 같습니다.

인증마크 사용이 가능한 경우	● 인증받은 데이터를 활용하는 온라인 서비스 웹 페이지 및 해당 서비스를 홍보하는 온오프라인 홍보물 ● DB로 인증을 받은 경우, 해당 DB로 운영되는 정보시스템 ● 데이터 및 DB 등의 인증 사실을 알리는 온오프라인 안내 홍보물 ● 인증받은 데이터가 유통 데이터 상품인 경우, 해당 데이터를 판매하는 온라인 상품 사이트, 오프라인 상품 안내 팸플릿 등 홍보물
인증마크 사용이 제한되는 경우	● 인증을 받은 데이터 또는 DB와 전혀 상관없는 기업의 제품 또는 사업 안내 온오프라인 홍보물, 건물 또는 차량

Q.12 인증표시 사용 기준과 인증마크와 표시 오용시 조치는 어떻게 되나요?

인증표시 사용 기준	● 인증받은 데이터 또는 DB를 활용하는 서비스에 인증을 홍보하는 경우 링크를 통해 인증서 팝업, 인증기관의 인증 정보 페이지로 링크 ● 인증 획득 사실 안내에 인증마크 활용 시 인증받은 데이터(또는 DB) 명칭, 인증서를 발행한 인증기관명칭을 병기
인증마크 및 표시 오용 시 조치	● 데이터산업법 제48조제1항에 따라 인증을 받지 아니하고 인증을 표시하거나 유사한 표시를 한 자에게 3천만원 이하의 과태료 부과

2 용어집

- **객체 데이터:** 데이터를 구성하는 개별 단위 아이템(레코드, 샘플)으로, 데이터 품질 측정의 기본 평가 대상 객체이다. 예를들어 이미지 1개, 텍스트 1개, 센서값 1개 등 하나의 최소 기본 단위이다.
- **데이터 구조:** 데이터의 효율적인 처리를 위한 개념적, 논리적, 물리적 데이터 모델과 저장 형식을 의미한다.
- **데이터 기본키(Primary Key):** 관계형 데이터베이스에서 테이블 내 특정 레코드를 고유하게 식별할 수 있는 키 필드(key field)로, 주 키(major key)라고도 한다. 기본키는 파일에서 특정 레코드를 검색하거나 정렬할 때 가장 우선적으로 참조된다. 관계 내 키 필드가 하나만 있을 경우, 자동으로 해당 키가 일차 키(primary key)로 지정되나 관계 내 복수의 키가 존재하는 경우, 하나를 일차 키로 지정해야 하며, 일차 키로 지정되지 않은 키는 대체 키(alternate key)라고 한다.
- **데이터 레코드:** 단위로 처리되는 관련 데이터 항목의 집합이다.
 - ※ 학습용 데이터의 경우, 비정형 데이터와 그에 대한 라벨링 데이터를 데이터 레코드로 볼 수 있음
 - ※ 학습용 데이터 중 의료 관련 멀티모달 데이터의 경우, 한 개인에 대한 혈액검사 데이터, 엑스레이 사진, 초음파 영상들을 데이터 레코드로 볼 수 있음
 - ※ 비정형 데이터의 경우, 비정형 데이터와 그에 대한 메타데이터 또는 라벨링 데이터를 데이터 레코드로 볼 수 있음
- **데이터 유형 (Data Type):** 속성에 대한 가능한 값, 특성 및 작업 집합의 추상적인 분류이다.
 - ※ 참고 1: 문자열, 텍스트, 날짜, 숫자, 이미지, 소리 등이 데이터 유형의 예시임
- **데이터 프레임 (Data Frame):** 특정 도메인 또는 목적으로 동일한 데이터 항목을 가지며, 분석 및 머신러닝에 사용되는 데이터 레코드 집합으로 데이터 분석 및 머신러닝(ML)에서 데이터를 구성하고, 조작하는 데 사용되는 표 형식의 데이터 구조이다.
- **데이터 항목 (Data Item):** 특정 맥락 내에서 정의, 식별, 허용 값 및 기타 정보가 속성 집합을 통해 지정되는 식별 가능한 가장 작은 데이터 단위이다.
 - ※ 참고 1: 필드는 데이터 항목과 동의어로 간주됨
 - ※ 참고 2: 데이터 항목은 데이터를 담는 물리적 객체 "컨테이너"임
 - ※ 비정형 데이터의 경우, 한 개의 파일
 - 데이터 집합의 요소. 파일은 레코드와 같은 몇 개의 항목에서 이루어지고, 그 위에 레코드는 다른 항목으로 이루어진다. 정보처리의 목적에서 한 단위로 취급되는 일련의 문자 또는 단어의 집합을 말할 때도 있다.
- **비정형 객체:** 스키마가 없는 어노테이션되지 않은 원천데이터 상태의 객체 데이터로 이미지, 영상, 음성, 텍스트 등 자유 형식의 데이터이다.
- **라벨:** 입력 데이터의 각 샘플에 부여된 정답 값으로, 클래스(범주), 수치 값, 상태 등 명시적인 정답 값이다.

- **라벨 데이터:** 데이터 입력 값과 대응하는 정답 값을 가지는 데이터셋으로, 입력-라벨 쌍으로 구성되며, 지도학습에서 사용되는 데이터이다.
- **라벨링 데이터:** 원천데이터에 부여한 ‘참값’, 파일형식이나 해상도 등의 속성, 그리고 설명이나 주석 등이 포함된 ‘어노테이션’의 집합이다.
- **메타데이터:** 데이터에 관한 구조화된 데이터를 의미하는 것으로, 다른 데이터를 설명해주는 데이터이다. 즉, 실제 데이터는 다른 곳에 위치해 있고, 메타데이터라고 하는 또 다른 데이터를 이용해 콘텐츠의 위치, 내용, 작성자 정보, 권리 조건, 이용 조건, 이용 내역 등을 기록으로 일련의 데이터를 정의하고 설명해 주는 데이터이다. 컴퓨터에서는 데이터 사전의 내용, 스키마 등을 의미하고, 하이퍼텍스트 마크업 언어(HTML) 문서에서는 메타 태그 내의 내용이 메타데이터이다. 방송에서는 방대한 분량의 저작물을 신속하게 검색하기 위해서 프로그램 제작 시 촬영 일시, 장소, 작가, 출연자 등과 음원의 경우 작곡자나 가수명 등을 메타데이터로 처리한다. 메타데이터는 여러 용도로 사용되나 주로 빠른 검색과 내용을 간략하고 체계적으로 하기 위해 많이 사용된다. 엠펙(MPEG)에서는 메타데이터에 대한 표준으로 엠펙-7(MPEG-7) 표준을 제정했다.
- **비라벨 데이터:** 고정된 정답 값이 없는 데이터로, 비지도학습, 자기지도학습, 생성형 모델 사전학습 등에서 입력만 사용하거나 생성된 타겟을 참조 값으로 활용하는 데이터이다.
- **어노테이션:** 원천데이터에 의미, 범주, 구조, 참조 정보를 부여하는 행위 및 결과로 태그, 바운딩 박스, 세그멘테이션 마스크, 캡션, QA 쌍, 주석 등 원본 데이터를 변경하지 않고 추가 정보를 부착하는 모든 형태를 포함한다.
- **업무규칙(무결성 제약조건, integrity constraints):** 데이터베이스에서 데이터를 추가, 수정, 삭제하는 과정에 부적절한 자료가 입력되는 것을 방지하기 위해서 테이블을 생성할 때 각 컬럼에 대해서 정의하는 규칙. 이 규칙을 위배 하지 않는 한 데이터베이스가 무결성을 유지하고 있는 것으로 간주한다. 무결성 규칙은 트리거 조건, 제약 조건, 위반 조치로 구성되며 그 종류는 도메인 무결성 규칙과 개체 무결성 규칙, 참조 무결성 규칙 등으로 대별된다.
- **참조 데이터:** 데이터의 분류, 식별, 유효성 검증 등을 위해 기준으로 삼는 데이터(코드, 목록 등) 또는 AI 모델 평가의 기준이 되는 데이터로, 생성형 모델(요약, 번역, 캡션 등)의 출력 평가 시 비교·검증을 위한 기준 데이터이다.
- **컬러심도(Color Depth):** 1개의 화소에서 표현할 수 있는 색의 수. RGB(red, green, blue) 각각에 대해 몇 비트씩 할당해서 이의 조합으로 여러 가지 색을 나타내는, 즉 비트 수로 색의 수를 표현하는 것을 말한다. RGB 각 8비트인 경우에 24비트이므로 색심도는 24비트가 된다. 경우에 따라서는 RGB 외에 투명도 8비트를 추가하여 RGBA 32비트가 되는 경우도 있다. 24비트로 표현할 수 있는 색의 수는 16,777,216색이며, 이것을 ‘24비트 컬러’라 부르기도 한다.
- **프레임 레이트(Frame Rate):** 초당 전송하는 프레임의 개수. 텔레비전 신호 등의 영상 신호를 전송할 때 인간의 시각 특성을 이용하여 1초에 적당한 개수의 화면(프레임)만을 전송하는데, 기존의 컬러 텔레비전의 경우 프레임률은 NTSC 시스템에서는 30프레임/초이고 PAL, SECAM 시스템에서는

25프레임/초이다.

- **해상도(Resolution):** 화상의 섬세한 부분이 어느 정도 세밀하게 재현되는지를 나타내는 정도. 수직 해상도와 수평 해상도로 나누어 표시한다. 텔레비전에서는 화면의 높이 사이에 같은 간격으로 번갈아 그은 흑백 수평 방향의 선을 몇 개까지 나타낼 수 있는지로 수직 해상도를 나타내며, 높이와 같은 길이 사이에 번갈아 그은 흑백 수직 방향의 선이 몇 개가 재현되는지로 수평 해상도를 나타낸다. 팩스의 경우에는 단위 길이 속에 번갈아 그은 흑백의 줄무늬 선이 몇 개나 기록되는지로 해상도를 나타낸다.

3

참고문헌

- 데이터 관리 인증심사원 양성 교재, 한국데이터산업진흥원, 2015년
- 데이터베이스 보안 가이드라인(II권), 한국데이터베이스진흥원, 2011년
- 데이터 품질관리 가이드라인(III권), 한국데이터베이스진흥원, 2012년
- 빅데이터 플랫폼 및 센터 데이터 품질관리 가이드, 한국지능정보사회진흥원, 2022년 6월
- 인공지능 학습용 데이터 품질관리 가이드라인 v3.1, 한국지능정보사회진흥원, 2021년 2월
- TTA.KO-10.1343-Part1_비정형 데이터 추출 및 조합, 2021년 12월
- TTA.KO-10.1343-Part2_비정형 데이터 태깅 및 라벨링, 2021년 12월
- TTA.KO-10.1344-Part1 유통·활용 데이터 점검 방법 - 제1부 정형·반정형 데이터, 2021년 12월
- TTA.KO-10.1344-Part2_유통·활용 데이터 점검 방법_제2부 비정형 데이터 품질지표, 2021년 6월
- 데이터 거래지원 가이드라인, 한국데이터베이스진흥원, 2020년
- ISMS-P 인증제도 안내서, 한국인터넷진흥원, 2024년 7월
- Control Objectives for Information Technologies 2019, ISACA, 2019년
- Data Management Body of Knowledge 2nd Edition, DAMA International, 2018년
- ISO 8000-61 Data quality management: Process reference model
- ISO 8000-62 Data quality management: Organizational process maturity assessment: Application of standards relating to process assessment
- ISO/IEC 17021-1 Conformity assessment — Requirements for bodies providing audit and certification of management systems
- ISO/IEC 33020 Information technology — Process assessment — Process measurement framework for assessment of process capability

DQ인증 가이드라인

발행 2026년 2월

발행처 과학기술정보통신부, 한국데이터산업진흥원

기획/작성 한국데이터산업진흥원 데이터유통지원단 유통기획팀, (주)와이즈스톤, (주)씨에이에스

본 가이드 내용에 대한 무단 전재를 금하여, 가공 및 인용할 때는 반드시 출처를 명기하여 주시기를 바랍니다.
(비매품)

